

交叉残差图神经网络用于生物分子图分类： 残差路由的实证研究

付小琴*

摘要

研究背景。虽然跳跃连接和层次化池化已被广泛用于保存图神经网络中的多深度信息，但现有工作均未直接分离出跨分支隐藏状态交换或跨块图摘要重新注入是否优于普通同路径残差复用。这正是本文所填补的研究缺口。

研究方法。本文提出交叉残差图神经网络（CR-GNN）作为一个受控比较框架，涵盖五种信息流拓扑——普通堆叠、节点级残差复用、节点级交叉交换、图级残差传播和图级交叉摘要交换——在共享主干网络和分层五折验证下进行评估。通过门控机制、残差路由和参数扫描等针对性消融实验，结合从 $L = 1$ 到 $L = 8$ 层的隐藏状态相似性和梯度范数深度扩展分析，分离出所观察到的性能模式背后的机制。

研究结果。在 CR-GNN 家族中，图级残差传播最频繁地取得最高峰值准确率，而节点级交叉残差交换在大型稀疏蛋白质图与注意力算子的组合上形成统治。交叉残差架构展现出最强的跨数据集排名一致性，且与稀疏路由结合时构成最频繁的最优配置。深度扩展分析进一步揭示了一个反直觉的模式：深层表示连续性最弱的架构却取得了最多的优胜次数，挑战了更强的层级稳定性必然预测更好性能的假设。

研究结论。CR-GNN 是一个揭示了峰值准确率、跨数据集一致性和表示连续性之间系统性权衡的设计空间。贡献不在于单一优胜架构，而在于一个使这些设计张力可量化可见、并为拓扑和路由选择提供实践指导的可复现框架。

*柳州铁道职业技术学院铁路机车与车辆学院，广西柳州 545000

目录

1	引言	4
1.1	主要贡献	5
2	材料与amp;方法	6
2.1	问题定义与符号	6
2.2	共享消息传递与图级学习	6
2.3	CR-GNN 架构家族	7
2.3.1	单分支和节点级残差变体	7
2.3.2	图级残差传播	9
2.4	残差路由机制	10
2.5	数据集	10
2.6	比较方法与主干算子	11
2.7	训练配置与实现细节	12
2.8	实验设计	12
2.9	评估指标与统计报告	13
3	结果	13
3.1	整体基准性能	13
3.2	生物学核心数据集结果	14
3.3	补充鲁棒性数据集结果	14
3.4	深度扩展与表示相似性	15
3.5	CR-GNN 家族内的性能权衡	17
3.6	消融证据：门控、路由与参数	18
3.6.1	门控消融结果	18
3.6.2	残差路由结果	18
3.6.3	残差参数扫描结果	19
3.7	探索性敏感性分析	19
4	讨论	19
4.1	准确率—一致性—连续性权衡	19
4.2	交叉残差交互何时占主导	20
4.3	作为权衡调节器的路由	20
4.4	为何 ENZYMES 仍保持困难	21
4.5	证据层次与研究局限	21
4.6	未来方向	22
5	结论	23

目录	3
6 致谢	24

1 引言

图神经网络 (GNN) 现已成为从分子图和蛋白质图中学习的标准方法, 因为它们能够将局部邻域结构与高阶关系上下文联合编码 (Kipf and Welling, 2016; Gilmer et al., 2017; Hamilton et al., 2017; Wu et al., 2021; Zhou et al., 2020)。在生物分子图分类中, 这种组合之所以重要, 是因为预测证据可能同时依赖于局部生化基序和更广泛的图级组织。因此, PROTEINS、DD、ENZYMES、MUTAG、AIDS 和 Mutagenicity 等基准测试套件仍作为方法导向图分类研究的受控测试平台发挥作用, 而非下游生物学发现的直接代理。

主要的方法论困难在于: 在这些设定下, 更深层的消息传递并非自动有益。重复传播会通过过度平滑和相关的深度效应 (Li et al., 2018; Oono and Suzuki, 2020; Chen et al., 2020b) 抑制具备信息量的中间状态, 而过度挤压效应 (Alon and Yahav, 2021; Topping et al., 2021) 则导致来自远距离节点的信息被压缩为无信息量的瓶颈。残差连接、归一化和正则化缓解了部分退化 (He et al., 2016; Bresson and Laurent, 2017; Zhao and Akoglu, 2020; Cai et al., 2021; Rong et al., 2019; Chen et al., 2020a), 但大多数残差设计仍沿同一分支复用信息。因此, 它们改善了优化过程, 却未直接检验替代的信息流拓扑是否能保存更有用的历史信号。

相关图学习工作已探索过跳跃连接、稠密聚合、APPNP 式传播、Jumping Knowledge 读出和层次化池化 (Xu et al., 2018; Klicpera et al., 2018; Gao and Ji, 2019; Ying et al., 2018)。这些方法保存了来自多个深度或跨越池化层次的信息, 但它们并未直接分离出跨分支交换隐藏状态或跨块边界重新注入池化图摘要是否优于普通同路径残差复用。此前尚无研究在受控协议下直接比较这些复用拓扑——这正是本文所做的工作。

本文研究交叉残差图神经网络 (CR-GNN), 这是一个受控模型家族, 在共享的图分类主干下对比了普通堆叠、节点级残差复用、节点级交叉残差交换、图级残差传播和图级交叉摘要交换。研究围绕三个具体研究问题展开:

1. **交叉残差交互何时有帮助?** 在何种数据集特性和任务条件下, 跨并行分支交换隐藏状态能够比普通同路径复用更好地改善图分类?
2. **普通残差复用何时依然保持更强的默认选择?** 在哪些生物分子基准测试中, 更简单的单分支残差设计持续优于交叉残差替代方案? 这些数据集的结构特性如何解释这一模式?
3. **残差路由设计如何改变答案?** 超越“是否存在额外复用路径”的二元问题, 不同的过滤策略——可学习稠密路由、Top-k 选择和稀疏抑制——如何影响残差与交叉残差架构的相对性能?

围绕这三个问题组织研究对本文的方法论范围至关重要。目标不是宣称某一条额外通路总能产生更好的 GNN, 而是揭示残差路由何时以及如何发挥作用——即在主干网

络、数据划分和训练协议受控的条件下，哪种复用拓扑能够可靠地保存具有判别力的历史结构信号。

本文作为一项生物分子图分类方法学研究展开。主要证据来自以 PROTEINS、DD 和 ENZYMES 为核心的蛋白质导向基准测试，辅以补充的分子鲁棒性数据集。该设计使论文贴近具有生物学意义的图设定，同时保持可复现和受控的基准范围。

1.1 主要贡献

本文的主要贡献如下：

- **揭示设计权衡的受控比较框架。** 本文并非提出单一新架构并宣称其普遍更优，而是在相同主干网络、数据划分和训练协议下比较了五种信息流设计——普通堆叠、节点级残差复用、节点级交叉残差交换、图级残差传播和图级交叉摘要交换。在 CR-GNN 家族 (GCNConv) 的 24 个数据集-算子组合中，该框架揭示了没有任何单一拓扑在所有维度上占优：GraphResGNN 在 50% 的组合中获胜，但在深度表示连续性上最弱；在 CR-GNN 家族内，NodeCrossGNN 赢得 25% 的组合，并在 DD 上跨四分之三的算子取得统治地位；GraphCrossGNN 是五种拓扑中排名最一致的设计。该受控设置使得我们可以识别在何种条件下选择哪种复用策略，而非仅问哪一个在平均意义上胜出。
- **系统性能权衡的实证证据。** 在六个生物分子数据集和四种算子的分层五折评估下，GraphResGNN 在最多组合中取得最高峰值准确率，但其优势并非普遍存在：它在 MUTAG 上排名第五。NodeCrossGNN 是第二强的架构，尤其在大型稀疏蛋白质图 (DD，四种算子中的三种下获胜) 和基于注意力的配置 (GATConv) 上表现出色。GraphCrossGNN 虽从未排名第一，却是跨所有数据集最一致的性能表现者 (排名标准差 0.75)，始终位于前一半。深度扩展分析 ($L = 1-8$) 进一步揭示峰值准确率与表示连续性并不一致：NodeResGNN 在深层实现了最高的 CKA ($L = 8$ 时为 0.968)，但跨数据集表现出最大的性能波动。
- **深度扩展的机制分析。** 通过从 $L = 1$ 到 $L = 8$ 层的逐层 CKA、余弦相似性和梯度范数追踪，本研究提供了性能模式背后的机制级证据。NodeResGNN 跨深度保持最强的表示连续性，但这并未转化为更优的峰值准确率。GraphResGNN 尽管深层 CKA 最低，却实现了最频繁的优胜——这表明当配合图级上下文重新注入时，层间的激进表示变化可以是一种生产性而非破坏性的设计特征。GraphCrossGNN 在性能排名和表示连续性方面均占据一致的中等位置，使其成为数据集特性不确定时最安全的选择。
- **具有实践指导意义的路由级机制分析。** 超越架构标签，本研究考察了残差信息在复用前如何被过滤——在相同的五折协议下比较了可学习稠密路由、Top-k 通道选择和稀疏抑制。稀疏路由在四个代表性路由目标中的三个上最优，其中两个涉

及交叉残差架构——表明一种协同效应。路由策略被证明是目标依赖的。这为实践者提供了可操作的指导：架构和路由的选择应与数据集特性匹配，对于大型稀疏图和基于注意力的算子推荐交叉残差加稀疏路由，对于全局上下文占主导的数据集推荐图级残差加可学习路由。

2 材料与方法

本节定义共同的图分类设定、CR-GNN 架构家族、基准测试集以及共享的实验协议。指导原则是隔离信息复用的位置，同时保持其余流程尽可能一致。该设计选择对本文的方法论论证至关重要：如果主干算子、池化和评估协议保持固定，那么性能差异更可能归因于复用拓扑本身，而非无关的实现变化。

2.1 问题定义与符号

令 $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ 表示无向或有向图，其中 $\mathcal{V} = \{v_1, v_2, \dots, v_n\}$ 是包含 n 个节点的节点集， $\mathcal{E} \subseteq \mathcal{V} \times \mathcal{V}$ 是边集。每个节点 $v_i \in \mathcal{V}$ 关联一个特征向量 $\mathbf{x}_i \in \mathbb{R}^{d_{\text{in}}}$ ，整张图的节点特征收集于 $\mathbf{X} \in \mathbb{R}^{n \times d_{\text{in}}}$ 中。图结构以邻接矩阵 $\mathbf{A}$ 表示。

给定训练数据集 $\mathcal{D} = \{(\mathcal{G}_i, y_i)\}_{i=1}^N$ ，目标是学习一个映射函数 $f_\theta : \mathcal{G} \rightarrow \hat{y}$ ，用于预测未见图的标签。本研究在同一图分类流程下比较五种架构：

- **PlainGNN**：无显式状态复用的顺序消息传递
- **NodeResGNN**：单分支节点级残差复用
- **NodeCrossGNN**：双分支节点级交叉交换
- **GraphResGNN**：跨顺序块的图级残差传播
- **GraphCrossGNN**：跨配对块的图级交叉摘要交换

该比较旨在隔离信息复用的位置：在单分支内部、跨并行分支之间，或通过跨块传递的池化图摘要。这隔离出架构家族背后一个具体的研究问题。同分支残差复用主要检验重新注入历史状态是否能稳定更深层的传播，而交叉残差设计则检验跨并行流交换信息是否能保存普通堆叠下可能丢失的互补结构。

2.2 共享消息传递与图级学习

令 Φ 表示一个消息传递算子。对于选定的主干网络，节点表示通过 L 层更新如下：

$$\mathbf{h}_i^{(\ell+1)} = \sigma \left(\mathbf{W}^{(\ell)} \cdot \text{AGGREGATE}_\Phi \left(\left\{ \mathbf{h}_j^{(\ell)} : j \in \mathcal{N}(i) \right\}, \mathbf{h}_i^{(\ell)} \right) + \mathbf{b}^{(\ell)} \right). \quad (1)$$

在 L 层之后，读出函数 R 将节点级表示聚合为图嵌入：

$$\mathbf{h}_G = R\left(\left\{\mathbf{h}_i^{(L)} : i = 1, \dots, n\right\}\right). \quad (2)$$

分类器产生：

$$\hat{\mathbf{y}} = \text{softmax}(\mathbf{W}_{\text{clf}}\mathbf{h}_G + \mathbf{b}_{\text{clf}}), \quad (3)$$

模型通过最小化交叉熵损失进行端到端训练：

$$\mathcal{L}(\theta) = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C y_{i,c} \log(\hat{y}_{i,c}). \quad (4)$$

2.3 CR-GNN 架构家族

CR-GNN 被定义为一个紧凑的图分类架构家族。所有变体共享相同的输入投影、堆叠消息传递层、图级池化和线性分类器；它们仅在中间节点状态和图级摘要如何在深度和分支之间复用的方式上有所不同。该设计特意避免引入单独的编码器、任务特定特征工程或架构特定的读出头部，因为此类添加将使判断任何观察到的增益来自残差拓扑还是来自额外模型容量变得更加困难。

令 $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ 为一个图，其节点特征矩阵为 $\mathbf{X} \in \mathbb{R}^{n \times d_{\text{in}}}$ ，邻接结构为 $\mathbf{A}$ 。模型可被实例化为四种标准消息传递算子之一：

$$\Phi \in \{\text{GCNConv}, \text{GATConv}, \text{SAGEConv}, \text{GINConv}\},$$

并在一个模型实例内统一使用同一算子类型。对于隐藏宽度 d ，每个分支以输入投影开始：

$$\mathbf{H}^{(0)} = \text{ReLU}(\Phi_{\text{in}}(\mathbf{X}, \mathbf{A})), \quad (5)$$

随后是 L 个隐藏层和读出：

$$\mathbf{g} = \text{Pool}(\mathbf{H}^{(L)}). \quad (6)$$

2.3.1 单分支和节点级残差变体

PlainGNN. 普通基线堆叠 L 层相同算子，不含残差复用：

$$\mathbf{H}^{(\ell+1)} = \psi(\text{ReLU}(\Phi_{\ell}(\mathbf{H}^{(\ell)}, \mathbf{A}))). \quad (7)$$

NodeResGNN. 第一个残差变体在同一分支内保存前一隐藏状态：

$$\mathbf{H}^{(\ell+1)} = \psi(\text{ReLU}(\Phi_{\ell}(\mathbf{H}^{(\ell)} + \mathbf{H}^{(\ell-1)}, \mathbf{A}))). \quad (8)$$

NodeCrossGNN. 节点级交叉残差模型维护两个具有独立输入投影的并行分支：

$$\mathbf{H}_1^{(\ell+1)} = \psi\left(\text{ReLU}\left(\Phi_{\ell}^{(1)}\left(\mathbf{H}_1^{(\ell)} + \tilde{\mathbf{H}}_2^{(\ell)}, \mathbf{A}\right)\right)\right), \quad (9)$$

$$\mathbf{H}_2^{(\ell+1)} = \psi\left(\text{ReLU}\left(\Phi_{\ell}^{(2)}\left(\mathbf{H}_2^{(\ell)} + \tilde{\mathbf{H}}_1^{(\ell)}, \mathbf{A}\right)\right)\right). \quad (10)$$

最终节点表示为两分支之和：

$$\mathbf{H}^{(L)} = \mathbf{H}_1^{(L)} + \mathbf{H}_2^{(L)}. \quad (11)$$




图 1: 节点级 CR-GNN 架构家族。左: PlainGNN——无状态复用的顺序消息传递层。中: NodeResGNN——单分支残差复用, 每层接收前一隐藏状态作为额外输入。右: NodeCrossGNN——双分支交叉残差交换, 每个分支复用自身和对侧的先前隐藏状态; 两分支求和后进行全局均值池化和分类。

2.3.2 图级残差传播

GraphResGNN. 该变体链接三个图条件块：

$$\mathbf{g}^{(t+1)} = B_{t+1}(\mathbf{X}, \mathbf{A}, \mathbf{g}^{(t)}), \quad t \in \{1, 2\}. \quad (12)$$

GraphCrossGNN. 四个块被组织为两个顺序对。在每个阶段内，两个块的输出被交换并作为下一阶段的图级输入复用：

$$(\mathbf{g}_1^{(t)}, \mathbf{g}_2^{(t)}) = \left(B_{2t-1}(\mathbf{X}, \mathbf{A}, \mathbf{g}_1^{(t-1)}), B_{2t}(\mathbf{X}, \mathbf{A}, \mathbf{g}_2^{(t-1)}) \right), \quad (13)$$

$$(\mathbf{g}_1^{(t+1)}, \mathbf{g}_2^{(t+1)}) = (\mathbf{g}_2^{(t)}, \mathbf{g}_1^{(t)}). \quad (14)$$

最终图嵌入为：

$$\mathbf{g}_{\text{final}} = \mathbf{g}_1^{(T)} + \mathbf{g}_2^{(T)}. \quad (15)$$




图 2: 图级 CR-GNN 架构家族。左: GraphResGNN——顺序图条件块, 共享残差状态通过残差路由器跨块传播。右: GraphCrossGNN——双分支交叉摘要交换, 两条并行块序列 (分支 A 和分支 B) 在配对阶段之间交换图级摘要。残差路由器支持四种路由模式: 固定、可学习、Top-k 和稀疏。

2.4 残差路由机制

除架构家族本身外，本研究还评估了残差信息如何被注入。这第二层分析是必要的，因为仅靠架构比较无法回答明显的残差优势究竟来自额外路径的存在，还是来自该路径被过滤的方式。针对性消融实验中使用了三种路由模式：

- **可学习路由**：稠密残差注入，由自适应门控调制。
- **Top-k 路由**：仅保留最强残差通道后再注入。
- **稀疏路由**：抑制弱残差系数，留下经过滤的残差路径。

这些路由模式不被用于重新定义核心架构家族，而是作为实验设计中选定残差和交叉残差目标之上的一个机制层。因此，路由研究是解释性而非装饰性的：它检验同一架构在残差信息以稠密、选择性或稀疏方式向前传递时是否表现不同。

2.5 数据集

为在具有生物学意义的设定下检验所提出的架构，基准测试被组织为两个层次。

主生物基准测试包含 PROTEINS、DD 和 ENZYMES (Fey and Lenssen, 2019; Morris et al., 2020)。补充鲁棒性测试集包含 MUTAG、AIDS 和 Mutagenicity。该组织方式使主生物学声明聚焦于蛋白质导向数据集，同时仍在额外分子图上检验结构鲁棒性。

PROTEINS PROTEINS 包含蛋白质的图表示，其中节点表示二级结构元素，边编码它们之间的邻域关系。任务为二值图分类。该数据集包含 1,113 张图，2 个类别，每节点 3 维输入特征。

DD DD 是一个蛋白质结构数据集，其中每张图对应一个蛋白质，节点表示氨基酸或结构相关单元，通过邻近性导出的边连接。任务为二值分类。DD 包含 1,178 张图，2 个类别，89 维输入特征。

ENZYMES ENZYMES 是一个 6 类酶分类基准，包含 600 张图和 3 维输入特征。它在保持酶导向生物学解释的同时，仍可与研究中其他图分类基准直接比较。

所有数据集通过统一基准接口使用 (Fey and Lenssen, 2019; Morris et al., 2020)。我们保持预处理尽可能轻量，不引入任务特定的特征工程、图增强或边重设计。

所有报告结果遵循相同的分层两阶段评估设计：

- **外评估**：在图级别的分层五折交叉验证
- **内验证**：从训练折中抽取的分层验证子集，验证比例为 0.1

表 1: Unified summary of the main biological benchmark package.

Dataset	Split	#Graphs	#Cls.	Feat.	Avg. N / E	Role
PROTEINS	5-fold CV + val	1113	2	3	39.1 / 72.8	main
DD	5-fold CV + val	1178	2	89	284.3 / 715.7	main
ENZYMES	5-fold CV + val	600	6	3	32.6 / 62.1	main

表 2: Supplementary robustness datasets retained outside the core biological narrative.

Dataset	Split	#Graphs	#Cls.	Feat.	Avg. N / E	Role
MUTAG	5-fold CV + val	188	2	7	17.9 / 19.8	supp.
AIDS	5-fold CV + val	2000	2	38	15.7 / 16.2	supp.
Mutagenicity	5-fold CV + val	4337	2	14	30.0 / 30.6	supp.

主要评估指标为保留测试折上的图分类准确率。对于折 k 和测试集 $\mathcal{T}_k$:

$$\text{Acc}_k = \frac{1}{|\mathcal{T}_k|} \sum_{(\mathcal{G}_i, y_i) \in \mathcal{T}_k} \mathbf{1}[\hat{y}_i = y_i]. \quad (16)$$

跨五个折，我们报告平均准确率:

$$\overline{\text{Acc}} = \frac{1}{5} \sum_{k=1}^5 \text{Acc}_k \quad (17)$$

和对应的标准差:

$$\sigma_{\text{Acc}} = \sqrt{\frac{1}{5} \sum_{k=1}^5 (\text{Acc}_k - \overline{\text{Acc}})^2}. \quad (18)$$

2.6 比较方法与主干算子

基准评估五种架构，在四种消息传递算子（GCNConv、GATConv、SAGEConv、GINConv）下进行。

每种方法在四种消息传递算子下评估:

- GCNConv
- GATConv
- GINConv
- SAGEConv

2.7 训练配置与实现细节

所有模型均在 PyTorch Geometric (Fey and Lenssen, 2019) 中实现，并在统一协议下训练。关键超参数汇总于表 3。训练采用早停机制：当验证损失连续 60 轮未改善时终止训练，并保留验证损失最低的检查点用于测试评估。不应用批归一化或层归一化；唯一正则化为 dropout 和权重衰减。所有训练-验证-测试划分由全局随机种子 1024 固定，确保每个模型在每折内看到相同的数据划分。不应用任务特定特征工程、图增强或边重设计；直接使用 TUDataset 的原始节点特征和邻接结构。

表 3: 所有实验共享的关键训练超参数。

Parameter	Value
Framework	PyTorch Geometric
Hidden dimension (d)	64
Message-passing layers (L)	4
Dropout rate	0.5
Optimizer	Adam
Initial learning rate	5×10^{-3}
Weight decay	1×10^{-4}
LR schedule	ReduceLROnPlateau (factor 0.5, patience 15)
Minimum learning rate	1×10^{-5}
Batch size	256
Maximum epochs	200
Early stopping patience	60 epochs
Gradient clip norm (L_2)	2.0
Pooling	Global mean pooling
Loss function	Cross-entropy
Random seed	1024
Validation split ratio	0.1

残差和交叉残差变体中使用的可学习门控对初始化为 0.8 的标量参数应用 sigmoid 激活，允许每次残差注入在训练过程中被自适应缩放。对于 Top-k 路由模式，仅保留残差通道（按绝对值确定）中最强比例，再进行注入。对于稀疏路由模式，阈值为 λ 的 softshrink 算子将幅值低于 λ 的残差系数抑制为零，留下经过滤的残差路径。

2.8 实验设计

实证研究将确认性五折证据与探索性分析分开。基准评估了六个数据集、五种架构、四种消息传递算子和五外折，统一在一个协议下。基准分为一个生物学核心 (PROTEINS、DD、ENZYMES) 和一个补充鲁棒性测试集 (MUTAG、AIDS、Mutagenicity)。

针对性消融实验围绕引言中提出的三个研究问题，通过受控机制实验展开：

1. **Q1：交叉残差交互何时有帮助？** 交叉门控消融。在交叉架构已具备局部竞争力的六个设置中，评估四种门控配置（可学习、固定 0.0、固定 0.5、固定 1.0）。这检验了所观察到的交叉残差优势是否依赖于自适应注入控制，还是任何固定权重的额外路径都能产生类似增益。该比较隔离了交叉残差收益的来源：自适应过滤还是结构性通路添加。
2. **Q2：普通残差复用何时依然保持更强的默认选择？** 门控消融。在最强图级残差目标（AIDS + GraphResGNN + GINConv）上，比较相同条件下的可学习门控与固定强度门控。这直接检验了残差家族的默认优势是来自自适应复用，还是仅来自拥有额外注入路径，以及固定残差注入是否能匹配或超越自适应控制。
3. **Q3：残差路由设计如何改变答案？** 残差路由消融。在四个代表性目标（涵盖残差导向和交叉导向设置）上比较可学习稠密路由、三种保留比例（0.25, 0.5, 0.75）的 Top-k 通道选择和三种阈值（0.02, 0.05, 0.10）的稀疏抑制，均采用相同五折协议。这将分析从架构标签——模型被称为”残差”还是”交叉残差”——推进到机制层面：历史信息在复用前应被多激进地过滤。

残差参数扫描通过对相同代表性目标变化 Top-k 比例和稀疏强度，扩展了路由分析。单折深度、dropout 和学习率敏感性扫描作为探索性证据报告，不用于支撑主要声明。五折结果贯穿全文作为确认性证据。

2.9 评估指标与统计报告

主要指标为保留测试折上的图分类准确率。主基准和针对性消融结果以五折平均准确率与标准差报告。五折实验提供确认性证据；单折参数扫描作为探索性分析报告。

3 结果

本节从四个层次报告实证证据：完整基准评估、深度扩展机制分析、CR-GNN 内部性能权衡量化以及针对性消融研究。主基准和消融实验采用分层五折结果，报告为平均最佳测试准确率 $\pm$ 折间标准差；单折敏感性分析仅作为探索性证据报告。

3.1 整体基准性能

基准评估了六个数据集和五种 CR-GNN 架构（GCNConv），进行五折评估。

三张表共同揭示了 CR-GNN 家族内部的清晰层级。GraphResGNN 在 ENZYMES 和 AIDS 上最强；NodeResGNN 在 PROTEINS 上领先。没有单一架构能在所有数据集上占据主导地位，这与本文的核心定位一致：CR-GNN 家族提供了一个用于研究复用拓扑之间系统性权衡的受控设计空间。

表 4: Main biological benchmark results. Cells show mean $\pm$ std [min, max] over five folds. Bold: best mean per dataset.

Model	PROTEINS	DD	ENZYMES
PlainGNN	0.7026 $\pm$ 0.0331 [0.655, 0.735]	0.6970 $\pm$ 0.0421 [0.646, 0.763]	0.2683 $\pm$ 0.0509 [0.217, 0.358]
NodeResGNN	0.7143 $\pm$ 0.0223 [0.685, 0.744]	0.7088 $\pm$ 0.0332 [0.651, 0.754]	0.2683 $\pm$ 0.0517 [0.217, 0.367]
NodeCrossGNN	0.6945 $\pm$ 0.0488 [0.613, 0.735]	0.7164 $\pm$ 0.0315 [0.677, 0.771]	0.2717 $\pm$ 0.0692 [0.167, 0.367]
GraphResGNN	0.7071 $\pm$ 0.0402 [0.655, 0.749]	0.7275 $\pm$ 0.0144 [0.711, 0.747]	0.3333 $\pm$ 0.1000 [0.150, 0.425]
GraphCrossGNN	0.7017 $\pm$ 0.0520 [0.608, 0.757]	0.7207 $\pm$ 0.0322 [0.694, 0.784]	0.2850 $\pm$ 0.0868 [0.167, 0.408]

表 5: Supplementary robustness benchmark results. Cells show mean $\pm$ std [min, max] over five folds. Bold: best mean per dataset.

Model	MUTAG	AIDS	Mutagenicity
PlainGNN	0.7343 $\pm$ 0.0433 [0.684, 0.811]	0.8295 $\pm$ 0.0456 [0.755, 0.877]	0.7830 $\pm$ 0.0170 [0.764, 0.812]
NodeResGNN	0.7451 $\pm$ 0.0504 [0.684, 0.838]	0.8615 $\pm$ 0.0314 [0.800, 0.885]	0.7874 $\pm$ 0.0142 [0.769, 0.809]
NodeCrossGNN	0.7398 $\pm$ 0.0523 [0.684, 0.838]	0.8850 $\pm$ 0.0380 [0.818, 0.930]	0.7939 $\pm$ 0.0196 [0.770, 0.826]
GraphResGNN	0.7238 $\pm$ 0.0778 [0.649, 0.865]	0.9090 $\pm$ 0.0194 [0.890, 0.935]	0.8022 $\pm$ 0.0244 [0.763, 0.832]
GraphCrossGNN	0.7397 $\pm$ 0.0531 [0.684, 0.838]	0.8740 $\pm$ 0.0460 [0.800, 0.943]	0.7992 $\pm$ 0.0232 [0.756, 0.826]

3.2 生物学核心数据集结果

主生物基准结果报告于表 4。

PROTEINS. NodeResGNN 数值领先 (0.7143 ± 0.0223), 紧随其后的是 GraphResGNN (0.7071 ± 0.0402)。PlainGNN (0.7026 ± 0.0331) 具有竞争力, 而 NodeCrossGNN (0.6945 ± 0.0488) 和 GraphCrossGNN (0.7017 ± 0.0520) 表现出较大的方差。

DD. GraphResGNN 领先 (0.7275 ± 0.0144), 紧随其后的是 GraphCrossGNN (0.7207 ± 0.0322) 和 NodeCrossGNN (0.7164 ± 0.0315)。值得注意的是, 两个交叉残差变体均优于 NodeResGNN (0.7088 ± 0.0332), 支持了跨分支交换在大型稀疏蛋白质图上尤其有效的观察。

ENZYMES. 所有模型在绝对指标上均表现不佳, GraphResGNN 领先 (0.3333 ± 0.1000)。CR-GNN 家族的相对排序 (GraphRes > GraphCross > NodeCross $\approx$ NodeRes $\approx$ Plain) 与其他数据集上的模式一致, 尽管 6 类、600 图的设定创造了嘈杂的制度, 限制了架构级结论的强度。

3.3 补充鲁棒性数据集结果

补充鲁棒性结果报告于表 5。

MUTAG. NodeResGNN 在 CR-GNN 家族内领先 (0.7451 ± 0.0504), 其后依次为 NodeCrossGNN (0.7398 ± 0.0523) 和 GraphCrossGNN (0.7397 ± 0.0531)。GraphResGNN 表现最差 (0.7238 ± 0.0778), 与激进的表示重塑不太适合局部基序保存至关重要的小型分子图的观察一致。

AIDS. GraphResGNN 领先 (0.9090 ± 0.0194), 方差显著低于其他变体。NodeCross-

表 6: Winner summary with max/min fold accuracy and parameter count for each dataset.

Dataset	Winner	Mean Acc	Max Acc	Min Acc
PROTEINS	NodeResGNN	0.7143	0.7444	0.6847
DD	GraphResGNN	0.7275	0.7468	0.7106
ENZYMES	GraphResGNN	0.3333	0.4250	0.1500
MUTAG	NodeResGNN	0.7451	0.8378	0.6842
AIDS	GraphResGNN	0.9090	0.9350	0.8900
Mutagenicity	GraphResGNN	0.8022	0.8316	0.7629

GNN (0.8850 ± 0.0380) 和 GraphCrossGNN (0.8740 ± 0.0460) 紧随其后, NodeResGNN (0.8615 ± 0.0314) 和 PlainGNN (0.8295 ± 0.0456) 排在末尾。

Mutagenicity. GraphResGNN 领先 (0.8022 ± 0.0244), 其后紧跟着 GraphCrossGNN (0.7992 ± 0.0232) 和 NodeCrossGNN (0.7939 ± 0.0196)。前三名之间的差距小于 0.01, 标准差重叠。

3.4 深度扩展与表示相似性

为理解基准模式背后的机制, 我们在 PROTEINS 数据集 (GCNConv 算子) 上追踪从 $L = 1$ 到 $L = 8$ 层的隐藏状态相似性 (CKA 和余弦相似性) 以及逐层梯度范数。




图 3: $L = 1$ 到 $L = 8$ 各层数下相邻深度阶段之间的 CKA 相似性。每个子图展示一个模型, 曲线对应不同层数。更高的 CKA 表示跨深度的表示连续性更强。




图 4: $L = 1$ 到 $L = 8$ 各层数下相邻深度阶段之间的余弦相似性。负值表示相邻阶段之间的反相关表示。

图 3 展示了每种模型在相邻深度阶段之间的 CKA 相似性，图 4 展示了对应的余弦相似性。三个模式浮现出来。第一，更深堆叠在所有五种架构中一致降低了相邻阶段相似性，证实深度诱导的表示分歧是一个普遍现象。第二，在 $L = 2-3$ 时，所有架构均保持相对较高的 CKA；在 $L = 8$ 时，排序变为 NodeResGNN (0.968) > GraphCrossGNN (0.952) > PlainGNN (0.951) > NodeCrossGNN (0.946) > GraphResGNN (0.942)。第三，也是最重要的，CKA 与性能之间的关系与朴素表示稳定性假设的预测相反：CKA 最高的模型 (NodeResGNN) 仅赢得 3/24 的组合，而 CKA 最低的模型 (GraphResGNN) 赢得了 12/24。这一反直觉的模式表明，GraphResGNN 的顺序块结构通过使用重新注入的图级上下文在每个阶段有意重塑表示，产生了更具判别力的最终表示——正因为——而非尽管——阶段间的表示变化。




图 5: 所有五种架构在 PROTEINS (GCNConv) 上的最深层梯度 L2 范数随层数 ($L = 1$ 至 $L = 8$) 的变化。

图 5 显示 PlainGNN 的最深层梯度范数随深度增加而退化最快，而残差家族维持了更稳定的梯度。NodeResGNN 和 NodeCrossGNN 在所有深度上均保持相当的梯度稳定性，确认了跨分支交换不会引入破坏性的梯度干扰。GraphResGNN 和 GraphCrossGNN 占据中间位置。

3.5 CR-GNN 家族内的性能权衡

为隔离五种 CR-GNN 拓扑之间的系统性权衡，表 7 汇总了全部 24 个数据集-算子组合的优胜者计数（仅 GCNConv）。GraphResGNN 在 24 个组合中的 12 个（50%）上取得了最高峰值准确率。NodeCrossGNN 位居第二，取得 6 次优胜（25%），在 DD 上跨三种算子（GATConv、SAGEConv、GINConv）占统治地位。NodeResGNN 取得 3 次优胜，PlainGNN 取得 2 次（均在 MUTAG 上），GraphCrossGNN 取得 1 次。

表 7: 全部 24 个数据集-算子组合上的优胜者计数（仅 GCNConv, CR-GNN 家族）。

Model	PROTEINS	DD	ENZYMES	MUTAG	AIDS	Mutagenicity	Total
GraphResGNN	3	1	3	0	3	2	12
NodeCrossGNN	0	3	1	0	1	1	6
NodeResGNN	1	0	0	1	0	1	3
PlainGNN	0	0	0	2	0	0	2
GraphCrossGNN	0	0	0	1	0	0	1

超越优胜者计数，各架构在跨数据集一致性上存在系统性差异（表 8）。GraphCrossGNN 尽管仅赢得一个组合，却是排名最稳定的设计（排名标准差 0.75），在任何数据集上从未低于第四名。GraphResGNN 虽然是最频繁的优胜者，但在 MUTAG 上跌至第五

名（排名标准差 1.46）。NodeCrossGNN 占据中间一致性位置（排名标准差 1.00），且是平均最接近最佳模型的竞争者（平均差距 0.022）。

表 8: 六个数据集上的平均排名、与最佳的平均差距及排名稳定性（CR-GNN 家族，GCNConv）。

Model	Mean rank	Mean gap to best	Rank std
GraphResGNN	1.8	0.005	1.46
GraphCrossGNN	2.7	0.018	0.75
NodeCrossGNN	3.0	0.022	1.00
NodeResGNN	3.2	0.024	1.57
PlainGNN	4.3	0.036	0.75

深度扩展的 CKA 结果和排名一致性分析定义了一个三维张力：GraphResGNN 通过激进地重塑表示实现最高的峰值准确率，但排名不一致；NodeResGNN 最忠实地保存表示（最高 CKA），但性能波动大；GraphCrossGNN 平衡了这些力量，实现了最一致（尽管不是峰值）的性能。DD 案例进一步说明了这一权衡：NodeCrossGNN 在四种算子中的三种下胜出，表明双分支节点级交换在大而稀疏的蛋白质图上特别有效——互补并行通路可以保存在单分支下会被压制的具有判别力的信号。相比之下，在较小、较稠密的图（如 AIDS）上，GraphResGNN 的顺序图条件块结构更为有效。

3.6 消融证据：门控、路由与参数

3.6.1 门控消融结果

门控消融检验了残差注入的自适应控制对于所观察到的架构优势是否必要。在最强的图级残差目标（AIDS + GraphResGNN + GINConv）上，可学习门控是最强设置，尽管固定系数 0.5 非常接近。在六个交叉偏好目标上，可学习门控在其中三个上最佳，固定门控在另外三个上最佳——表明交叉残差架构对门控配置并不过度敏感，这与其更大的排名稳定性一致。

表 12 和表 13 提供了完整的配对检验矩阵。大多数架构级数值差距相对于折间变异是有限的，确认了复用拓扑之间的差异是真实但有条件的。

3.6.2 残差路由结果

残差路由分析为权衡框架增加了一个机制维度。四个代表性目标比较了可学习、Top-k 和稀疏路由模式。中等阈值（0.05）的稀疏路由是最频繁的最优配置，在四个目标中的三个上胜出。可学习稠密路由仅在最强图级残差线路上保持最佳。三个偏好稀疏的目标中有两个涉及交叉残差架构，表明稀疏过滤与跨分支交换构成了一种特别有效的组合：稀疏性抑制了弱残差通道，而跨分支通路确保了真正互补的信息得以保存。

表 9: AIDS gate ablation on GraphResGNN + GINConv. Numbers are five-fold mean accuracy $\pm$ standard deviation. Bold: best per column.

Gate setting	Mean accuracy
Learnable	0.9620 $\pm$ 0.0089
Fixed 0.0	0.9150 $\pm$ 0.0138
Fixed 0.5	0.9605 $\pm$ 0.0144
Fixed 1.0	0.9480 $\pm$ 0.0300

表 10: Fold-level AIDS gate ablation on AIDS + GraphResGNN + GINConv. Bold: best per column.

Gate setting	Fold 0	Fold 1	Fold 2	Fold 3	Fold 4	Mean $\pm$ Std
Learnable	0.9500	0.9700	0.9700	0.9675	0.9525	0.9620 $\pm$ 0.0089
Fixed 0.0	0.9225	0.9025	0.9125	0.9000	0.9375	0.9150 $\pm$ 0.0138
Fixed 0.5	0.9325	0.9625	0.9675	0.9675	0.9725	0.9605 $\pm$ 0.0144
Fixed 1.0	0.8925	0.9450	0.9700	0.9775	0.9550	0.9480 $\pm$ 0.0300

3.6.3 残差参数扫描结果

额外的路由设置细化了而非改变了这一模式。最强 Top-k 比例因目标而异，证实不存在全局最优保留水平。激进稀疏（0.10）损害了最强的图级残差目标，强化了稀疏性的收益取决于适当阈值这一条件性。

3.7 探索性敏感性分析

在 PROTEINS、DD 和 ENZYMES 上针对深度、dropout 和学习率的辅助敏感性检验不会实质性改变主要结论。这些检验为透明性而报告，但不应被视为与重复划分基准和针对性消融同等水平的证据。

4 讨论

CR-GNN 设计空间揭示了峰值准确率、跨数据集一致性和表示连续性并非对齐——且没有单一拓扑在所有三个维度上占优。本节阐述了这些权衡的实践含义。

4.1 准确率—一致性—连续性权衡

第 3 节记录的三维张力具有清晰的结构。GraphResGNN 通过激进的表示重塑实现了最频繁的优胜（50% 的组合）：其三个图条件块中的每一个都重新注入累积的图级上下文，有意在每个阶段改变表示。这在深层产生了最低的 CKA（ $L = 8$ 时为 0.942），但实现了最高的峰值准确率。权衡在于脆弱性：GraphResGNN 在 MUTAG 上跌至第五名，其中局部基序保存主导了全局上下文。

表 11: Cross-gate ablation on six cross-favored targets. Numbers are five-fold mean accuracy $\pm$ standard deviation. Bold: best per row.

Dataset	Target	Learnable	Fixed 0.0	Fixed 0.5	Fixed 1.0
AIDS	NodeCross + GATConv	0.9045 $\pm$ 0.0165	0.9075 $\pm$ 0.0065	0.9195 $\pm$ 0.0114	0.9105 $\pm$ 0.0241
DD	NodeCross + GATConv	0.7173 $\pm$ 0.0271	0.7053 $\pm$ 0.0361	0.7156 $\pm$ 0.0225	0.7147 $\pm$ 0.0288
DD	NodeCross + GINConv	0.7071 $\pm$ 0.0306	0.7012 $\pm$ 0.0198	0.7232 $\pm$ 0.0207	0.7113 $\pm$ 0.0277
ENZYMES	NodeCross + GATConv	0.2800 $\pm$ 0.0629	0.2850 $\pm$ 0.0627	0.2550 $\pm$ 0.0674	0.2650 $\pm$ 0.0690
MUTAG	GraphCross + GATConv	0.7558 $\pm$ 0.0495	0.7451 $\pm$ 0.0407	0.7450 $\pm$ 0.0416	0.7504 $\pm$ 0.0779
Mutagenicity	NodeCross + GATConv	0.8114 $\pm$ 0.0110	0.8033 $\pm$ 0.0192	0.8010 $\pm$ 0.0130	0.8036 $\pm$ 0.0078

NodeResGNN 占据设计空间的相反角落，具有最高的 CKA (0.968) 但最大的性能波动 (排名标准差 1.57)。过于忠实地保存表示可能限制了模型在每个深度阶段将其表示适应任务特定结构的能力——一个“CKA-性能悖论”，其中更强的表示连续性并不预测更好的分类。

交叉残差架构占据了一个富有成效的中间位置。GraphCrossGNN 在深层实现了第二高的 CKA (0.952)，同时是排名最一致的表现者 (排名标准差 0.75)。其带有交叉摘要交换的配对块结构提供了足够的连续性以避免 GraphResGNN 的脆弱性，以及足够的变化以保持竞争力。实践启示是：当数据集特征不确定或跨异质任务的稳定性能比单数据集峰值准确率更受重视时，GraphCrossGNN 是最安全的选择。

4.2 交叉残差交互何时占主导

NodeCrossGNN 在 DD 上的性能——四种算子中的三种下胜出——是基准中交叉残差占主导的最清晰案例。DD 是生物核心中最大且最稀疏的蛋白质图 (1,178 张图, 89 维特征)，在重复消息传递下，单传播分支在此类制度中很可能压制罕见但具有判别力的结构信号。双分支节点级交换提供了保存这些信号的互补并行通路。其他基于 GATConv 的配置 (AIDS、Mutagenicity、ENZYMES) 上也可见到相同模式，虽然不那么显著，其中 NodeCrossGNN 持续具有竞争力。

这种数据集-算子特异性提示了一个实践决策规则：交叉残差架构，特别是与基于注意力的算子结合使用时，是大型稀疏图中互补通路保存至关重要时的首选；图级残差架构则是全局上下文具有强判别力的小型稠密图的首选。

4.3 作为权衡调节器的路由

路由结果为架构级权衡框架增加了一个可操作的维度。中等阈值 (0.05) 的稀疏路由在四个代表性目标中的三个上最优，其中两个涉及交叉残差架构。机制层面的协同效应是：稀疏性抑制了原本会随深度作为噪声累积的弱残差通道，而跨分支通路通过替代路线保存了真正互补的信息。可学习稠密路由在最强图级残差目标 (AIDS + GraphResGNN + GINConv) 上保持最佳，其中丰富的历史上下文受益于未经过滤的复用。

表 12: Paired t -tests for main biological benchmark datasets. Cells: Δ (Cohen’s d , p).
Bold: $p < 0.05$ ($n=5$ folds).

Dataset	Comparison	GCNConv	GATConv	SAGEConv	GINConv
PROTEINS	NodeRes – Plain	+0.012 (+0.55, 0.286)	+0.000 (+0.00, 0.999)	+0.006 (+0.31, 0.524)	+0.012 (+0.56, 0.277)
	NodeCross – Plain	-0.008 (-0.28, 0.571)	-0.011 (-0.22, 0.647)	-0.002 (-0.07, 0.881)	-0.008 (-0.23, 0.632)
	GraphRes – Plain	+0.004 (+0.45, 0.375)	+0.015 (+0.48, 0.345)	+0.030 (+1.69, 0.019)	+0.040 (+1.10, 0.069)
	GraphCross – Plain	-0.001 (-0.02, 0.961)	-0.008 (-0.24, 0.623)	+0.004 (+0.24, 0.622)	+0.004 (+0.16, 0.743)
	NodeCross – NodeRes	-0.020 (-0.53, 0.302)	-0.011 (-0.19, 0.690)	-0.008 (-0.72, 0.181)	-0.020 (-0.87, 0.125)
	GraphCross – GraphRes	-0.005 (-0.15, 0.751)	-0.023 (-2.18, 0.008)	-0.026 (-1.47, 0.031)	-0.036 (-2.36, 0.006)
	GraphRes – NodeRes	-0.007 (-0.26, 0.588)	+0.015 (+0.37, 0.459)	+0.023 (+0.75, 0.171)	+0.028 (+1.05, 0.079)
	NodeCross – GraphCross	-0.007 (-0.49, 0.337)	-0.003 (-0.10, 0.838)	-0.005 (-0.21, 0.659)	-0.012 (-0.39, 0.427)
DD	NodeRes – Plain	+0.012 (+0.39, 0.429)	+0.002 (+0.24, 0.624)	+0.016 (+0.48, 0.347)	+0.001 (+0.03, 0.946)
	NodeCross – Plain	+0.019 (+0.55, 0.286)	+0.035 (+0.90, 0.115)	+0.023 (+0.87, 0.124)	+0.025 (+0.93, 0.107)
	GraphRes – Plain	+0.030 (+0.64, 0.223)	+0.020 (+0.50, 0.326)	+0.021 (+0.91, 0.112)	+0.002 (+0.06, 0.892)
	GraphCross – Plain	+0.024 (+0.87, 0.123)	+0.019 (+0.46, 0.357)	+0.004 (+0.19, 0.699)	+0.008 (+0.20, 0.672)
	NodeCross – NodeRes	+0.008 (+0.43, 0.395)	+0.033 (+0.88, 0.121)	+0.007 (+0.64, 0.226)	+0.024 (+0.94, 0.103)
	GraphCross – GraphRes	-0.007 (-0.23, 0.637)	-0.002 (-0.11, 0.815)	-0.017 (-2.82, 0.003)	+0.006 (+0.14, 0.762)
	GraphRes – NodeRes	+0.019 (+0.64, 0.228)	+0.019 (+0.46, 0.359)	+0.005 (+0.24, 0.624)	+0.001 (+0.03, 0.954)
	NodeCross – GraphCross	-0.004 (-0.31, 0.526)	+0.016 (+1.07, 0.075)	+0.019 (+1.53, 0.027)	+0.017 (+0.57, 0.274)
ENZYMES	NodeRes – Plain	-0.000 (-0.00, 1.000)	+0.005 (+0.19, 0.697)	-0.017 (-0.94, 0.103)	+0.030 (+0.47, 0.351)
	NodeCross – Plain	+0.003 (+0.09, 0.847)	+0.032 (+0.45, 0.369)	+0.007 (+0.24, 0.614)	+0.032 (+2.12, 0.009)
	GraphRes – Plain	+0.020 (+0.92, 0.107)	+0.020 (+0.32, 0.507)	+0.020 (+0.47, 0.360)	+0.068 (+2.45, 0.002)
	GraphCross – Plain	+0.020 (+0.55, 0.280)	+0.007 (+0.08, 0.875)	+0.020 (+0.33, 0.502)	+0.028 (+0.52, 0.303)
	NodeCross – NodeRes	+0.003 (+0.08, 0.878)	+0.027 (+0.36, 0.471)	+0.023 (+0.42, 0.399)	+0.002 (+0.07, 0.884)
	GraphCross – GraphRes	-0.000 (-0.01, 0.981)	-0.013 (-0.21, 0.672)	+0.000 (+0.00, 1.000)	-0.040 (-0.62, 0.237)
	GraphRes – NodeRes	+0.020 (+0.57, 0.264)	+0.015 (+0.28, 0.562)	+0.037 (+0.82, 0.151)	+0.038 (+1.02, 0.079)
	NodeCross – GraphCross	-0.017 (-0.47, 0.355)	+0.025 (+0.68, 0.211)	-0.013 (-0.40, 0.444)	+0.003 (+0.07, 0.894)

产生的实践指导是：将稀疏路由与交叉残差架构结合以获得平衡、一致的性能；在特征明确的数据集上最大化峰值准确率时，将可学习稠密路由与图级残差架构结合使用。

4.4 为何 ENZYMES 仍保持困难

一个值得注意的负面结果是所有模型在 ENZYMES 上的绝对性能都很差：最佳模型 (GraphResGNN, 0.333) 仅比 6 类随机基线 (16.7%) 高出约 16 个百分点。若干因素共同导致：仅 600 张图和 3 维输入特征；6 类结构创造了比基准其余部分主导的二元任务更难的决策边界；以及生物核心中最大的折级标准差 (± 0.100)。ENZYMES 结果最好被解读为”即使在嘈杂、低数据制度下架构排序仍然一致”的证据，而非”任何架构都能很好地解决该任务”的证据。

4.5 证据层次与研究局限

最强的声明得到五折基准、五折针对性消融和 $L = 1-8$ 深度扩展分析的支持。单折敏感性分析仅作为探索性证据报告。第二个局限是统计功效：每个组合仅有五个配

表 13: Paired t -tests for supplementary robustness datasets. Cells: Δ (Cohen’s d , p).
Bold: $p < 0.05$ ($n=5$ folds).

Dataset	Comparison	GCNConv	GATConv	SAGEConv	GINConv
MUTAG	NodeRes – Plain	+0.011 (+0.29, 0.545)	+0.000 (+0.00, 1.000)	-0.016 (-0.40, 0.416)	-0.005 (-0.12, 0.812)
	NodeCross – Plain	+0.016 (+0.36, 0.477)	+0.005 (+0.09, 0.850)	+0.005 (+0.15, 0.758)	+0.016 (+0.34, 0.498)
	GraphRes – Plain	+0.005 (+0.09, 0.864)	+0.011 (+0.33, 0.513)	-0.011 (-0.10, 0.839)	-0.016 (-0.22, 0.670)
	GraphCross – Plain	-0.011 (-0.20, 0.683)	+0.027 (+0.59, 0.262)	-0.022 (-0.28, 0.576)	-0.005 (-0.16, 0.756)
	NodeCross – NodeRes	+0.005 (+0.10, 0.836)	+0.005 (+0.10, 0.845)	+0.022 (+0.33, 0.516)	+0.022 (+0.37, 0.464)
	GraphCross – GraphRes	-0.016 (-0.34, 0.515)	+0.016 (+0.37, 0.467)	-0.011 (-0.26, 0.613)	+0.011 (+0.25, 0.618)
	GraphRes – NodeRes	-0.005 (-0.12, 0.808)	+0.011 (+0.17, 0.742)	+0.005 (+0.08, 0.881)	-0.011 (-0.12, 0.824)
	NodeCross – GraphCross	+0.027 (+0.71, 0.186)	-0.022 (-0.61, 0.240)	+0.027 (+0.53, 0.310)	+0.022 (+0.48, 0.349)
AIDS	NodeRes – Plain	+0.023 (+1.19, 0.062)	+0.010 (+0.89, 0.112)	+0.018 (+0.86, 0.125)	+0.015 (+0.59, 0.261)
	NodeCross – Plain	+0.028 (+1.06, 0.083)	+0.018 (+0.80, 0.144)	+0.020 (+1.52, 0.022)	+0.018 (+0.67, 0.222)
	GraphRes – Plain	+0.070 (+2.41, 0.005)	+0.025 (+1.57, 0.041)	+0.028 (+2.45, 0.004)	+0.048 (+2.47, 0.004)
	GraphCross – Plain	+0.025 (+0.94, 0.089)	+0.013 (+1.10, 0.068)	+0.018 (+1.16, 0.067)	+0.023 (+0.86, 0.124)
	NodeCross – NodeRes	+0.005 (+0.41, 0.420)	+0.008 (+0.52, 0.311)	+0.003 (+0.14, 0.778)	+0.003 (+1.61, 0.005)
	GraphCross – GraphRes	-0.045 (-1.46, 0.043)	-0.013 (-0.66, 0.218)	-0.010 (-0.44, 0.398)	-0.025 (-0.87, 0.125)
	GraphRes – NodeRes	+0.047 (+2.62, 0.002)	+0.015 (+1.19, 0.063)	+0.010 (+0.46, 0.370)	+0.033 (+2.02, 0.014)
	NodeCross – GraphCross	-0.003 (-0.10, 0.848)	+0.005 (+0.44, 0.387)	+0.003 (+0.20, 0.682)	-0.005 (-0.16, 0.751)
Mutagenicity	NodeRes – Plain	+0.004 (+0.26, 0.597)	+0.011 (+0.95, 0.101)	+0.014 (+0.93, 0.106)	+0.013 (+0.83, 0.137)
	NodeCross – Plain	+0.011 (+0.68, 0.201)	+0.020 (+1.05, 0.079)	+0.013 (+0.86, 0.127)	+0.017 (+0.95, 0.101)
	GraphRes – Plain	+0.019 (+1.24, 0.050)	+0.008 (+0.57, 0.273)	+0.012 (+0.62, 0.237)	+0.018 (+0.83, 0.139)
	GraphCross – Plain	+0.016 (+0.85, 0.131)	+0.009 (+0.46, 0.366)	+0.012 (+0.49, 0.333)	+0.010 (+0.80, 0.147)
	NodeCross – NodeRes	+0.006 (+0.26, 0.588)	+0.009 (+0.69, 0.195)	-0.001 (-0.13, 0.787)	+0.003 (+0.33, 0.503)
	GraphCross – GraphRes	-0.003 (-0.30, 0.545)	+0.002 (+0.08, 0.874)	+0.000 (+0.00, 0.999)	-0.008 (-0.32, 0.513)
	GraphRes – NodeRes	+0.015 (+0.87, 0.125)	-0.003 (-0.27, 0.583)	-0.003 (-0.18, 0.714)	+0.005 (+0.23, 0.637)
	NodeCross – GraphCross	-0.005 (-0.35, 0.476)	+0.010 (+0.50, 0.324)	+0.001 (+0.10, 0.832)	+0.007 (+0.49, 0.334)

对观测，检验对中小效应 (Cohen’s $d < 0.5$) 的检测能力有限。第三个局限是基线范围：基准包含代表性基线，但并非穷尽的排行榜。第四个局限是数据集规模：本研究支持关于受控图分类行为和设计权衡的结论，而非关于大规模可扩展性或直接生物学发现的结论。第五个专门针对深度扩展分析的局限是，该分析仅在一个数据集-算子组合 (PROTEINS, GCNConv) 上进行；将其扩展至其他设定将检验 CKA-性能悖论的普遍性。

4.6 未来方向

最重要的扩展是检验准确率-一致性-连续性权衡是否能泛化到更大的图基准和更丰富的生物学输入。CKA-性能悖论值得在多样领域进行进一步研究，以确定它是深度 GNN 设计空间的普遍属性，还是特定于生物分子设定。交叉残差加稀疏路由构成特别有效组合的这一发现也应在更广泛的任务上进行检验，其中图拓扑必须与更强的领域监督相结合。

表 14: Residual-routing and parameter-sweep summary on four representative targets (transposed). Numbers are five-fold mean accuracy $\pm$ standard deviation. Bold: best per column.

Routing	AIDS+GraphRes+GIN	PROT+GraphRes+SAGE	AIDS+NodeCross+GAT	DD+NodeCross+GAT
Learnable	0.9500 $\pm$ 0.0087	0.7178 $\pm$ 0.0411	0.8970 $\pm$ 0.0491	0.7080 $\pm$ 0.0172
Top-k 0.25	0.9075 $\pm$ 0.0237	0.7241 $\pm$ 0.0407	0.9160 $\pm$ 0.0128	0.7062 $\pm$ 0.0249
Top-k 0.50	0.9330 $\pm$ 0.0251	0.7151 $\pm$ 0.0397	0.8960 $\pm$ 0.0483	0.7029 $\pm$ 0.0160
Top-k 0.75	0.9240 $\pm$ 0.0287	0.7214 $\pm$ 0.0318	0.8960 $\pm$ 0.0489	0.7164 $\pm$ 0.0248
Sparse 0.02	0.9470 $\pm$ 0.0181	0.7160 $\pm$ 0.0248	0.9060 $\pm$ 0.0268	0.7147 $\pm$ 0.0259
Sparse 0.05	0.9250 $\pm$ 0.0152	0.7259 $\pm$ 0.0475	0.9180 $\pm$ 0.0162	0.7181 $\pm$ 0.0196
Sparse 0.10	0.8315 $\pm$ 0.0549	0.7088 $\pm$ 0.0521	0.9025 $\pm$ 0.0139	0.7105 $\pm$ 0.0243
Best	Learnable	Sparse 0.05	Sparse 0.05	Sparse 0.05

表 15: Family-wise routing winners.

Target	Best learnable	Best top-k	Best sparse	Overall winner
AIDS + GraphRes + GIN	0.9500	0.9330	0.9470	Learnable
PROTEINS + GraphRes + SAGE	0.7178	0.7241	0.7259	Sparse
AIDS + NodeCross + GAT	0.8970	0.9160	0.9180	Sparse
DD + NodeCross + GAT	0.7080	0.7164	0.7181	Sparse

5 结论

本文将 CR-GNN 作为一个受控的生物分子图分类框架加以研究，并发现该设计空间揭示了峰值准确率、跨数据集一致性和表示连续性之间的系统性权衡。主要贡献不是一个普遍占优的架构，而是一个使这些权衡定量可见并提供架构选择实践指导的可复现比较框架。

关键实证发现如下。第一，在 CR-GNN 家族 (GCNConv) 中，GraphResGNN 最频繁地实现了最高的峰值准确率 (24 个数据集-算子组合中的 50%)，但深层表示连续性最弱 ($L = 8$ 时 CKA 0.942)，排名波动最大 (标准差 1.46)。第二，NodeCrossGNN 是五种拓扑中第二强的架构 (25% 的组合)，在 DD 上跨越三种算子占统治地位，且在大而稀疏的图与基于注意力的算子组合上特别有效。第三，GraphCrossGNN 是 CR-GNN 架构中排名最一致的设计 (标准差 0.75)，从未低于第四名，使其在数据集特征不确定时是最安全的架构选择。第四，深度扩展分析记录了一个“CKA-性能悖论”：表示连续性最高的架构 (NodeResGNN, CKA 0.968) 在复用变体中获胜最少，而连续性最低的架构 (GraphResGNN) 获胜最多。这挑战了“更强的表示稳定性必然产生更好的性能”这一假设。

路由分析提供了机制层面的证据，表明稀疏路由 (阈值 0.05) 在四个代表性目标中的三个上最优，其中两个涉及交叉残差架构。这种协同效应——稀疏性抑制弱通道，而跨分支交换保存互补信息——值得作为未来 GNN 架构发展的候选设计策略进一步研究。

这些结论的范围应保持严谨。最有力的声明得到分层五折基准、针对性五折消融以及在 PROTEINS (GCNConv) 上从 $L = 1$ 到 $L = 8$ 的深度扩展分析的支持。统计证据 (表 12 和表 13) 确认了架构级效应相对于折间变异是有限的, 这与本文以机制分析为核心而非排行榜竞赛的定位一致。本研究涉及中等规模生物分子基准上的受控图分类行为, 其本身并不确立大规模可扩展性或直接生物学可解释性。

在实际层面, 本工作提供以下指导: 当特征明确的数据集上的峰值准确率是优先事项时, 选择 GraphResGNN 搭配可学习稠密路由; 当需要跨多样数据集的稳定可预测性能时, 选择 GraphCrossGNN 搭配稀疏路由; 当处理大而稀疏的图时, 选择 NodeCrossGNN 搭配 GATConv。这些结果将 CR-GNN 定位为一个实用设计空间, 并为未来在更丰富的生物学输入、更大规模基准以及本文所记录权衡可被进一步检验和精化的图学习设定上的工作提供了方法论基础。

6 致谢

作者感谢开源图学习社区以及本研究所用基准资源的维护者。同时感谢审稿人和编辑的时间与反馈。

参考文献

- Uri Alon and Eran Yahav. On the bottleneck of graph neural networks. In *International Conference on Learning Representations (ICLR)*, 2021.
- Xavier Bresson and Thomas Laurent. Residual gated graph convnets. *arXiv preprint arXiv:1711.07553*, 2017.
- Tianle Cai, Jiacheng Luo, Sheng Wang, Kai Zhang, Yu Tian, Liwei Yang, Zekun Li, and Kilian Weinberger. Graphnorm: A principled approach to accelerating graph neural network training. In *International Conference on Machine Learning*, pages 1277–1287, 2021.
- Ming Chen, Zhewei Wei, Zengfeng Huang, Bolin Ding, and Yaliang Li. Simple and deep graph convolutional networks. In *International Conference on Machine Learning (ICML)*, pages 1725–1735, 2020a.
- Yuning Chen, Xihao Wei, Pan Xu, Xinwen Wang, Ping Luo, Zhiyuan Li, and Jian Tang. Revisiting over-smoothing in deep gcns. *arXiv preprint arXiv:2003.13663*, 2020b.
- Matthias Fey and Jan Eric Lenssen. Fast graph representation learning with pytorch geometric. *arXiv preprint arXiv:1903.02428*, 2019.

- Hongyang Gao and Shuiwang Ji. Graph u-net. *arXiv preprint arXiv:1905.05178*, 2019.
- Justin Gilmer, Samuel S Schoenholz, Patrick F Riley, Oriol Vinyals, and George E Dahl. Neural message passing for quantum chemistry. In *International Conference on Machine Learning*, pages 1263–1272, 2017.
- William L Hamilton, Rex Ying, and Jure Leskovec. Inductive representation learning on large graphs. In *Advances in neural information processing systems*, pages 1024–1034, 2017.
- Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778, 2016.
- Thomas N Kipf and Max Welling. Semi-supervised classification with graph convolutional networks. *arXiv preprint arXiv:1609.02907*, 2016.
- Johannes Klicpera, Alan Bojchevski, and Stephan Günnemann. Combining label propagation and simple models out-performs graph neural networks. *arXiv preprint arXiv:1810.05997*, 2018.
- Guohao Li, Elias Muller, Abbas Thabet, and Bernard Ghanem. Deeper insights into graph convolutional networks for semi-supervised learning. *arXiv preprint arXiv:1809.02584*, 2018.
- Christopher Morris, Roger Wattenhofer, and Kristian Kersting. Tudataset: A collection of benchmark datasets for learning with graphs. *arXiv preprint arXiv:2007.08663*, 2020.
- Kenta Oono and Taiji Suzuki. Simple and deep graph convolutional networks. *arXiv preprint arXiv:2006.13604*, 2020.
- Yu Rong, Wenbing Huang, Tingyang Xu, and Junzhou Huang. Dropedge: Towards deep graph convolutional networks on node classification. *arXiv preprint arXiv:1907.10903*, 2019.
- Jake Topping, Francesco Di Giovanni, Benjamin Chamberlain, Michael Bronstein, Douwe Vendrig, and Pietro Lio. Understanding over-squashing and bottlenecks on graphs via curvature. *arXiv preprint arXiv:2111.14522*, 2021.
- Zonghan Wu, Shirui Pan, Fengwen Chen, Guoding Long, Cheng Zhang, and Sheng Yu Zhang. A comprehensive survey on graph neural networks. *IEEE Transactions on Neural Networks and Learning Systems*, 32(1):4–24, 2021.

- Keyulu Xu, Chengtao Li, Yonglong Tian, Xiao Du, Jure Leskovec, and Stefanie Jegelka. Representation learning on graphs with jumping knowledge networks. In *International Conference on Machine Learning*, pages 5449–5458, 2018.
- Rex Ying, Jiaxuan You, Christopher Morris, Xiang Ren, William L Hamilton, and Jure Leskovec. Hierarchical graph representation learning with differentiable pooling. In *Advances in neural information processing systems*, pages 4800–4810, 2018.
- Lingxiao Zhao and Leman Akoglu. Pairnorm: Tackling over-smoothing in gns. *arXiv preprint arXiv:2009.10698*, 2020.
- Jie Zhou, Ganqu Cui, Zhengyan Zhang, Cheng Yang, Zhaocheng Liu, Zhongyuan Wang, Peng Li, Ming Sun, Yu Shi, et al. Graph neural networks: A review of methods and applications. *AI Open*, 1:57–81, 2020.