

交叉残差图神经网络用于生物分子图分类： 残差路由的实证研究

付小琴*

摘要

研究背景。图神经网络广泛用于蛋白质和分子的图分类任务，但更深层的消息传递会模糊具有判别力的局部结构，而标准跳跃连接未能阐明哪种信息流拓扑在峰值性能、跨数据集一致性和表示稳定性三个维度上取得最佳平衡。该问题在生物分子图分类中尤为突出，因为有效的判别证据可能同时依赖于局部结构基序和图级上下文，而复用拓扑的选择会对上述三个维度产生实质性影响。

研究方法。本文将交叉残差图神经网络（CR-GNN）作为一个受控比较框架加以研究，该框架在共享的图分类主干网络下评估了普通堆叠、节点级残差复用、节点级交叉残差交换、图级残差传播和图级交叉摘要交换五种设计。基准测试围绕具有生物学意义的蛋白质导向核心数据集和补充分子鲁棒性数据集展开，所有结果均采用分层五折交叉验证，报告平均最佳测试准确率和折间标准差。此外，我们组织了门控机制、残差路由模式和残差参数扫描等针对性实验，结合从 $L = 1$ 到 $L = 8$ 层的隐藏状态相似性（CKA/余弦）和逐层梯度范数的深度扩展分析。

研究结果。在六个数据集和四种消息传递算子的分层五折评估下（24 个组合），GraphResGNN 在最多组合中取得最高峰值准确率（50%），而 NodeCrossGNN 是第二强的架构（25%），在 DD 数据集上跨四种算子中的三种取得领先，并在若干基于 GATConv 的配置上胜出。深度扩展分析揭示了一个微妙的权衡：GraphResGNN 在原始准确率上领先，但在深层表示连续性上最弱（ $L = 8$ 时平均 CKA 为 0.942）；NodeResGNN 实现了最高的 CKA（0.968），但跨数据集性能波动最大。GraphCrossGNN 是排名最稳定的设计（排名标准差 0.75），在任何数据集上从未低于第四名。路由分析进一步表明，稀疏路由与交叉残差架构的组合是跨代表性目标中最频繁的最优配置。

研究结论。CR-GNN 最好被理解为一个受控的生物分子图分类设计空间，它揭示了峰值准确率、跨数据集一致性和表示连续性之间的系统性权衡。GraphResGNN 是追求原始准确率时的首选，NodeCrossGNN 在大型稀疏图和基于注意力的算子下是更强的选择，而路由策略的选择可进一步调节这些权衡。本文的贡献不在于单一的优胜架构，而在于一个使这些设计张力可量化的可复现比较框架。

*柳州铁道职业技术学院铁路机车与车辆学院，广西柳州 545000

目录	2
----	---

目录

1 引言	3
2 材料与方法	5
3 结果	12
4 讨论	23
5 结论	26

1 引言

图神经网络 (GNN) 现已成为从分子图和蛋白质图中学习的标准方法, 因为它们能够将局部邻域结构与高阶关系上下文联合编码 (Kipf and Welling, 2016; Gilmer et al., 2017; Hamilton et al., 2017; Wu et al., 2021; Zhou et al., 2020)。在生物分子图分类中, 这种组合之所以重要, 是因为预测证据可能同时依赖于局部生化基序和更广泛的图级组织。因此, PROTEINS、DD、ENZYMES、MUTAG、AIDS 和 Mutagenicity 等基准测试套件仍作为方法导向图分类研究的受控测试平台发挥作用, 而非下游生物学发现的直接代理。

主要的方法论困难在于: 在这些设定下, 更深层的消息传递并非自动有益。重复传播会通过过度平滑和相关的深度效应 (Li et al., 2018; Oono and Suzuki, 2020; Chen et al., 2020b) 抑制具备信息量的中间状态, 而过度挤压效应 (Alon and Yahav, 2021; Topping et al., 2021) 则导致来自远距离节点的信息被压缩为无信息量的瓶颈。残差连接、归一化和正则化缓解了部分退化 (He et al., 2016; Bresson and Laurent, 2017; Zhao and Akoglu, 2020; Cai et al., 2021; Rong et al., 2019; Chen et al., 2020a), 但大多数残差设计仍沿同一分支复用信息。因此, 它们改善了优化过程, 却未直接检验替代的信息流拓扑是否能保存更有用的历史信号。

相关图学习工作已探索过跳跃连接、稠密聚合、APPNP 式传播、Jumping Knowledge 读出和层次化池化 (Xu et al., 2018; Klicpera et al., 2018; Gao and Ji, 2019; Ying et al., 2018)。这些方法保存了来自多个深度或跨越池化层次的信息, 但它们并未直接分离出跨分支交换隐藏状态或跨块边界重新注入池化图摘要是否优于普通同路径残差复用。这正是本文所填补的、更具体的研究缺口。

本文研究交叉残差图神经网络 (CR-GNN), 这是一个受控模型家族, 在共享的图分类主干下对比了普通堆叠、节点级残差复用、节点级交叉残差交换、图级残差传播和图级交叉摘要交换。研究围绕三个具体研究问题展开:

1. **交叉残差交互何时有帮助?** 在何种数据集特性和任务条件下, 跨并行分支交换隐藏状态能够比普通同路径复用更好地改善图分类?
2. **普通残差复用何时依然保持更强的默认选择?** 在哪些生物分子基准测试中, 更简单的单分支残差设计持续优于交叉残差替代方案? 这些数据集的结构特性如何解释这一模式?
3. **残差路由设计如何改变答案?** 超越“是否存在额外复用路径”的二元问题, 不同的过滤策略——可学习稠密路由、Top-k 选择和稀疏抑制——如何影响残差与交叉残差架构的相对性能?

围绕这三个问题组织研究对本文的方法论范围至关重要。目标不是宣称某一条额外通路总能产生更好的 GNN, 而是揭示残差路由何时以及如何发挥作用——即在主干网

络、数据划分和训练协议受控的条件下，哪种复用拓扑能够可靠地保存具有判别力的历史结构信号。

本文作为一项以机制为导向的生物分子图分类方法学研究展开。主要证据来自以 PROTEINS、DD 和 ENZYMES 为核心的蛋白质导向基准测试，辅以补充的分子鲁棒性数据集。该设计使论文贴近具有生物学意义的图设定，同时保持可复现和受控的基准范围。因此，后续章节从架构动机出发，进入共同的方法论设定，再到确认性基准结果、针对性消融实验和支持性敏感性分析。这一递进是有意为之：基准测试首先建立实证模式，门控和路由研究随后检验该模式是否可以通过残差信息向前传递的方式来解释。

主要贡献

本文的主要贡献如下：

- **揭示设计权衡的受控比较框架。**本文并非提出单一新架构并宣称其普遍更优，而是在相同主干网络、数据划分和训练协议下比较了五种信息流设计——普通堆叠、节点级残差复用、节点级交叉残差交换、图级残差传播和图级交叉摘要交换。在 24 个数据集-算子组合中，该框架揭示了没有任何单一拓扑在所有维度上占优：GraphResGNN 在 50% 的组合中获胜，但在深度表示连续性上最弱；NodeCrossGNN 赢得 25% 的组合，并在 DD 上跨四分之三的算子取得统治地位；GraphCrossGNN 是排名最一致的设计。该受控设置使得我们可以识别在何种条件下选择哪种复用策略，而非仅问哪一个在平均意义上胜出。
- **系统性性能权衡的实证证据。**在六个生物分子数据集和四种算子的分层五折评估下，GraphResGNN 在最多组合中取得最高峰值准确率，但其优势并非普遍存在：它在 MUTAG 上排名第五。NodeCrossGNN 是第二强的架构，尤其在大型稀疏蛋白质图（DD，四种算子中的三种下获胜）和基于注意力的配置（GATConv）上表现出色。GraphCrossGNN 虽从未排名第一，却是跨所有数据集最一致的性能表现者（排名标准差 0.75），始终位于前一半。深度扩展分析（ $L = 1-8$ ）进一步揭示峰值准确率与表示连续性并不一致：NodeResGNN 在深层实现了最高的 CKA（ $L = 8$ 时为 0.968），但跨数据集表现出最大的性能波动。
- **深度扩展的机制分析。**通过从 $L = 1$ 到 $L = 8$ 层的逐层 CKA、余弦相似性和梯度范数追踪，本研究提供了性能模式背后的机制级证据。NodeResGNN 跨深度保持最强的表示连续性，但这并未转化为更优的峰值准确率。GraphResGNN 尽管深层 CKA 最低，却实现了最频繁的优胜——这表明当配合图级上下文重新注入时，层间的激进表示变化可以是一种生产性而非破坏性的设计特征。GraphCrossGNN 在性能排名和表示连续性方面均占据一致的中等位置，使其成为数据集特性不确定时最安全的选择。

- **具有实践指导意义的路由级机制分析。**超越架构标签，本研究考察了残差信息在复用前如何被过滤——在相同的五折协议下比较了可学习稠密路由、Top-k 通道选择和稀疏抑制。稀疏路由与交叉残差架构的组合成为最频繁的最优配置，且路由策略被证明是目标依赖的。这为实践者提供了可操作的指导：架构和路由的选择应与数据集特性匹配，对于大型稀疏图和基于注意力的算子推荐交叉残差加稀疏路由，对于全局上下文占主导的数据集推荐图级残差加可学习路由。

2 材料与方法

本节定义共同的图分类设定、CR-GNN 架构家族、基准测试包以及共享的实验协议。指导原则是隔离信息复用的位置，同时保持其余流程尽可能一致。该设计选择对本文的方法论论证至关重要：如果主干算子、池化和评估协议保持固定，那么性能差异更可能归因于复用拓扑本身，而非无关的实现变化。

问题定义与符号

令 $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ 表示无向或有向图，其中 $\mathcal{V} = \{v_1, v_2, \dots, v_n\}$ 是包含 n 个节点的节点集， $\mathcal{E} \subseteq \mathcal{V} \times \mathcal{V}$ 是边集。每个节点 $v_i \in \mathcal{V}$ 关联一个特征向量 $\mathbf{x}_i \in \mathbb{R}^{d_{\text{in}}}$ ，整张图的节点特征收集于 $\mathbf{X} \in \mathbb{R}^{n \times d_{\text{in}}}$ 中。图结构以邻接矩阵 $\mathbf{A}$ 表示。

给定训练数据集 $\mathcal{D} = \{(\mathcal{G}_i, y_i)\}_{i=1}^N$ ，目标是学习一个映射函数 $f_\theta : \mathcal{G} \rightarrow \hat{y}$ ，用于预测未见图的标签。本研究在同一图分类流程下比较五种架构：

- **PlainGNN**：无显式状态复用的顺序消息传递
- **NodeResGNN**：单分支节点级残差复用
- **NodeCrossGNN**：双分支节点级交叉交换
- **GraphResGNN**：跨顺序块的图级残差传播
- **GraphCrossGNN**：跨配对块的图级交叉摘要交换

该比较旨在隔离信息复用的位置：在单分支内部、跨并行分支之间，或通过跨块传递的池化图摘要。这隔离出架构家族背后一个具体的研究问题。同分支残差复用主要检验重新注入历史状态是否能稳定更深层的传播，而交叉残差设计则检验跨并行流交换信息是否能保存普通堆叠下可能丢失的互补结构。

共享消息传递与图级学习

令 Φ 表示一个消息传递算子。对于选定的主干网络，节点表示通过 L 层更新如下：

$$\mathbf{h}_i^{(\ell+1)} = \sigma \left(\mathbf{W}^{(\ell)} \cdot \text{AGGREGATE}_\Phi \left(\left\{ \mathbf{h}_j^{(\ell)} : j \in \mathcal{N}(i) \right\}, \mathbf{h}_i^{(\ell)} \right) + \mathbf{b}^{(\ell)} \right). \quad (1)$$

在 L 层之后, 读出函数 R 将节点级表示聚合为图嵌入:

$$\mathbf{h}_G = R\left(\left\{\mathbf{h}_i^{(L)} : i = 1, \dots, n\right\}\right). \quad (2)$$

分类器产生:

$$\hat{\mathbf{y}} = \text{softmax}(\mathbf{W}_{\text{clf}}\mathbf{h}_G + \mathbf{b}_{\text{clf}}), \quad (3)$$

模型通过最小化交叉熵损失进行端到端训练:

$$\mathcal{L}(\theta) = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C y_{i,c} \log(\hat{y}_{i,c}). \quad (4)$$

CR-GNN 架构家族

CR-GNN 被定义为一个紧凑的图分类架构家族。所有变体共享相同的输入投影、堆叠消息传递层、图级池化和线性分类器; 它们仅在中间节点状态和图级摘要如何在深度和分支之间复用的方式上有所不同。该设计特意避免引入单独的编码器、任务特定特征工程或架构特定的读出头部, 因为此类添加将使判断任何观察到的增益来自残差拓扑还是来自额外模型容量变得更加困难。

令 $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ 为一个图, 其节点特征矩阵为 $\mathbf{X} \in \mathbb{R}^{n \times d_{\text{in}}}$, 邻接结构为 $\mathbf{A}$ 。模型可被实例化为四种标准消息传递算子之一:

$$\Phi \in \{\text{GCNConv}, \text{GATConv}, \text{SAGEConv}, \text{GINConv}\},$$

并在一个模型实例内统一使用同一算子类型。对于隐藏宽度 d , 每个分支以输入投影开始:

$$\mathbf{H}^{(0)} = \text{ReLU}(\Phi_{\text{in}}(\mathbf{X}, \mathbf{A})), \quad (5)$$

随后是 L 个隐藏层和读出:

$$\mathbf{g} = \text{Pool}(\mathbf{H}^{(L)}). \quad (6)$$

单分支和节点级残差变体

PlainGNN. 普通基线堆叠 L 层相同算子, 不含残差复用:

$$\mathbf{H}^{(\ell+1)} = \psi(\text{ReLU}(\Phi_{\ell}(\mathbf{H}^{(\ell)}, \mathbf{A}))). \quad (7)$$

NodeResGNN. 第一个残差变体在同一分支内保存前一隐藏状态:

$$\mathbf{H}^{(\ell+1)} = \psi(\text{ReLU}(\Phi_{\ell}(\mathbf{H}^{(\ell)} + \mathbf{H}^{(\ell-1)}, \mathbf{A}))). \quad (8)$$

NodeCrossGNN. 节点级交叉残差模型维护两个具有独立输入投影的并行分支:

$$\mathbf{H}_1^{(\ell+1)} = \psi\left(\text{ReLU}\left(\Phi_{\ell}^{(1)}\left(\mathbf{H}_1^{(\ell)} + \tilde{\mathbf{H}}_2^{(\ell)}, \mathbf{A}\right)\right)\right), \quad (9)$$

$$\mathbf{H}_2^{(\ell+1)} = \psi\left(\text{ReLU}\left(\Phi_{\ell}^{(2)}\left(\mathbf{H}_2^{(\ell)} + \tilde{\mathbf{H}}_1^{(\ell)}, \mathbf{A}\right)\right)\right). \quad (10)$$

最终节点表示为两分支之和:

$$\mathbf{H}^{(L)} = \mathbf{H}_1^{(L)} + \mathbf{H}_2^{(L)}. \quad (11)$$




图 1: 节点级 CR-GNN 架构。三列分别比较普通堆叠（左）、同分支残差复用（中）和双分支交叉残差交换（右）。在交叉残差设计中，每个分支不仅复用自身的先前状态，还复用对侧分支在前一层的状态，残差路由器控制跨分支注入的强度和稀疏度。

图级残差传播

GraphResGNN. 该变体链接三个图条件块：

$$\mathbf{g}^{(t+1)} = B_{t+1}(\mathbf{X}, \mathbf{A}, \mathbf{g}^{(t)}), \quad t \in \{1, 2\}. \quad (12)$$

GraphCrossGNN. 四个块被组织为两个顺序对。在每个阶段内，两个块的输出被交换并作为下一阶段的图级输入复用：

$$(\mathbf{g}_1^{(t)}, \mathbf{g}_2^{(t)}) = \left(B_{2t-1}(\mathbf{X}, \mathbf{A}, \mathbf{g}_1^{(t-1)}), B_{2t}(\mathbf{X}, \mathbf{A}, \mathbf{g}_2^{(t-1)}) \right), \quad (13)$$

$$(\mathbf{g}_1^{(t+1)}, \mathbf{g}_2^{(t+1)}) = (\mathbf{g}_2^{(t)}, \mathbf{g}_1^{(t)}). \quad (14)$$

最终图嵌入为：

$$\mathbf{g}_{\text{final}} = \mathbf{g}_1^{(T)} + \mathbf{g}_2^{(T)}. \quad (15)$$

残差路由机制

除架构家族本身外，本研究还评估了残差信息如何被注入。这第二层分析是必要的，因为仅靠架构比较无法回答明显的残差优势究竟来自额外路径的存在，还是来自该路径被过滤的方式。针对性消融实验中使用了三种路由模式：

- **可学习路由：**稠密残差注入，由自适应门控调制。
- **Top-k 路由：**仅保留最强残差通道后再注入。




图 2: 图级 CR-GNN 架构。三列分别比较普通图级堆叠 (左)、顺序图级残差传播 (中) 和跨配对块的交叉摘要交换 (右)。在交叉残差设计中, 共享残差状态和残差路由器控制并行块序列之间的图级信息交换, 可用四种路由模式: 固定、可学习、Top-k 和稀疏残差。

- **稀疏路由**: 抑制弱残差系数, 留下经过滤的残差路径。

这些路由模式不被用于重新定义核心架构家族, 而是作为实验设计中选定残差和交叉残差目标之上的一个机制层。因此, 路由研究是解释性而非装饰性的: 它检验同一架构在残差信息以稠密、选择性或稀疏方式向前传递时是否表现不同。

数据集

为在具有生物学意义的设定下检验所提出的架构, 基准测试被组织为一个统一的两层体系。

主生物基准测试包含 PROTEINS、DD 和 ENZYMES (Fey and Lenssen, 2019; Morris et al., 2020)。补充鲁棒性测试包包含 MUTAG、AIDS 和 Mutagenicity。该组织方式使主生物学声明聚焦于蛋白质导向数据集, 同时仍在额外分子图上检验结构鲁棒性。

PROTEINS PROTEINS 包含蛋白质的图表示, 其中节点表示二级结构元素, 边编码它们之间的邻域关系。任务为二值图分类。该数据集包含 1,113 张图, 2 个类别, 每节点 3 维输入特征。

DD DD 是一个蛋白质结构数据集, 其中每张图对应一个蛋白质, 节点表示氨基酸或结构相关单元, 通过邻近性导出的边连接。任务为二值分类。DD 包含 1,178 张图, 2 个类别, 89 维输入特征。

ENZYMES ENZYMES 是一个 6 类酶分类基准，包含 600 张图和 3 维输入特征。它在保持酶导向生物学解释的同时，仍可与研究中其他图分类基准直接比较。

所有活跃数据集通过统一基准接口使用 (Fey and Lenssen, 2019; Morris et al., 2020)。我们保持预处理尽可能轻量，在最终协议中不引入任务特定的特征工程、图增强或边重设计。

所有报告结果遵循相同的分层两阶段评估设计：

- **外评估**：在图级别的分层五折交叉验证
- **内验证**：从训练折中抽取的分层验证子集，验证比例为 0.1

主要评估指标为保留测试折上的图分类准确率。对于折 k 和测试集 $\mathcal{T}_k$ ：

$$\text{Acc}_k = \frac{1}{|\mathcal{T}_k|} \sum_{(\mathcal{G}_i, y_i) \in \mathcal{T}_k} \mathbf{1}[\hat{y}_i = y_i]. \quad (16)$$

跨五个折，我们报告平均准确率：

$$\overline{\text{Acc}} = \frac{1}{5} \sum_{k=1}^5 \text{Acc}_k \quad (17)$$

和对应的标准差：

$$\sigma_{\text{Acc}} = \sqrt{\frac{1}{5} \sum_{k=1}^5 (\text{Acc}_k - \overline{\text{Acc}})^2}. \quad (18)$$

比较方法与主干算子

论文面向的完整基准比较了九种方法。CR-GNN 家族包含五个模型：PlainGNN、NodeResGNN、NodeCrossGNN、GraphResGNN 和 GraphCrossGNN。四个外部基线也包含在基准测试包中：GraphSAGEBaseline、GINBaseline、JKNetBaseline 和 APP-NPBaseline。这些基线旨在将受控比较锚定在具有不同传播或聚合行为的代表性图分类家族上，而非宣称穷尽覆盖所有近期排行榜方法。

每种方法在四种消息传递算子下评估：

- **GCNConv**
- **GATConv**
- **GINConv**
- **SAGEConv**

表 1: Unified summary of the main biological benchmark package.

Dataset	Split	#Graphs	#Cls.	Feat.	Avg. N / E	Role
PROTEINS	5-fold CV + val	1113	2	3	39.1 / 72.8	main
DD	5-fold CV + val	1178	2	89	284.3 / 715.7	main
ENZYMES	5-fold CV + val	600	6	3	32.6 / 62.1	main

表 2: Supplementary robustness datasets retained outside the core biological narrative.

Dataset	Split	#Graphs	#Cls.	Feat.	Avg. N / E	Role
MUTAG	5-fold CV + val	188	2	7	17.9 / 19.8	supp.
AIDS	5-fold CV + val	2000	2	38	15.7 / 16.2	supp.
Mutagenicity	5-fold CV + val	4337	2	14	30.0 / 30.6	supp.

训练配置与实现细节

所有模型均在 PyTorch Geometric (Fey and Lenssen, 2019) 中实现，并在统一协议下训练。关键超参数汇总于表 3。不应用批归一化或层归一化；唯一正则化为 dropout 和权重衰减。所有训练-验证-测试划分由全局随机种子 1024 固定，确保每个模型在每折内看到相同的数据划分。不应用任务特定特征工程、图增强或边重设计；直接使用 TUDataset 的原始节点特征和邻接结构。

残差和交叉残差变体中使用的可学习门控对初始化为 0.8 的标量参数应用 sigmoid 激活，允许每次残差注入在训练过程中被自适应缩放。对于 Top-k 路由模式，仅保留残差通道（按绝对值确定）中最强比例，再进行注入。对于稀疏路由模式，阈值为 λ 的 softshrink 算子将幅值低于 λ 的残差系数抑制为零，留下经过滤的残差路径。

实验设计

实证研究旨在将确认性五折证据与探索性支持分析分开。最新基准评估了六个数据集、九种方法、四种消息传递算子和五外折，统一在一个协议下。该完整矩阵提供了贯穿全文的主要比较，基准表格直接放置在对应的结果小节中，使每项实证声明能够在原地得到支持。

基准分为两个层次。生物核心由 PROTEINS、DD 和 ENZYMES 组成，锚定本文的主要生物分子解释。补充鲁棒性包将分析扩展至 MUTAG、AIDS 和 Mutagenicity。该划分使核心声明保持聚焦，同时仍检验结论在额外分子图设置上是否保持稳定。

针对性消融实验围绕引言中提出的三个研究问题，通过受控机制实验展开：

1. **Q1: 交叉残差交互何时有帮助？** 交叉门控消融。在交叉架构已具备局部竞争力的六个设置中，评估四种门控配置（可学习、固定 0.0、固定 0.5、固定 1.0）。这检验了所观察到的交叉残差优势是否依赖于自适应注入控制，还是任何固定权重的

表 3: 所有实验共享的关键训练超参数。

Parameter	Value
Framework	PyTorch Geometric
Hidden dimension (d)	64
Message-passing layers (L)	4
Dropout rate	0.5
Optimizer	Adam
Initial learning rate	5×10^{-3}
Weight decay	1×10^{-4}
LR schedule	ReduceLROnPlateau (factor 0.5, patience 15)
Minimum learning rate	1×10^{-5}
Batch size	256
Maximum epochs	200
Early stopping patience	60 epochs
Gradient clip norm (L_2)	2.0
Pooling	Global mean pooling
Loss function	Cross-entropy
Random seed	1024
Validation split ratio	0.1

额外路径都能产生类似增益。该比较隔离了交叉残差收益的来源：自适应过滤还是结构性通路添加。

2. **Q2: 普通残差复用何时依然保持更强的默认选择？** 门控消融。在最强图级残差目标 (AIDS + GraphResGNN + GINConv) 上，比较相同条件下的可学习门控与固定强度门控。这直接检验了残差家族的默认优势是来自自适应复用，还是仅来自拥有额外注入路径，以及固定残差注入是否能匹配或超越自适应控制。
3. **Q3: 残差路由设计如何改变答案？** 残差路由消融。在四个代表性目标（涵盖残差导向和交叉导向设置）上比较可学习稠密路由、三种保留比例 (0.25, 0.5, 0.75) 的 Top-k 通道选择和三种阈值 (0.02, 0.05, 0.10) 的稀疏抑制，均采用相同五折协议。这将分析从架构标签——模型被称为“残差”还是“交叉残差”——推进到机制层面：历史信息在复用前应被多激进地过滤。

残差参数扫描通过对相同代表性目标变化 Top-k 比例和稀疏强度，扩展了路由分析。旧有的单折深度、dropout 和学习率敏感性扫描仅作为探索性支持分析保留。在最终解释中，五折最新版本运行被视为确认性证据，而单折扫描仅用于描述优化趋势，而非支撑主要声明。

评估指标与统计报告

主要指标为保留测试折上的图分类准确率。主基准和针对性消融结果以五折平均准确率与标准差报告。在最终论文中，五折最新版本实验被视为主要确认性证据，而较旧的单折参数扫描仅作为支持性探索分析使用。

3 结果

本节分四个层次报告最终实证证据：完整基准、对最强残差模式的机制导向解释、针对性门控与残差路由研究，以及探索性敏感性分析。证据层次明确：主基准和针对性消融使用最新的分层五折结果，报告为平均最佳测试准确率 $\pm$ 折间标准差，而较旧的敏感性扫描仅作为支持性趋势分析保留。这一分离至关重要，因为本文的主要声明旨在建立在重复划分证据之上，而非一次有利运行之上。

整体基准性能

最终基准在统一协议下评估了六个数据集、九种方法、四种算子和五个外折。因此，正文将基准表格置于它们所支持的具体声明旁边，而非将表格证据单独列入附录。该呈现方式是有意为之：本文主张有限制的实证结论，所以表格证据被放置在每项声明被提出和解释的位置。

总体而言，三张表显示出一致的层次关系。残差复用仍是蛋白质导向核心中更强的默认家族，交叉残差路由在补充分子数据集上变得选择性有用，而优胜者摘要确认没有任何单一复杂度趋势能单独解释结果。均值和标准差的组合在此处同样重要：若干差距是有限而非巨大，这正说明为何本文将结果解释为受控的相对稳定模式，而非某一设计普遍占优的证据。

表 4: Main biological benchmark results. Cells show mean $\pm$ std [min, max] over five folds. Bold: best mean per dataset.

Model	PROTEINS	DD	ENZYMES
PlainGNN	0.7053 $\pm$ 0.0271 [0.667, 0.735]	0.7165 $\pm$ 0.0179 [0.694, 0.742]	0.2450 $\pm$ 0.0407 [0.183, 0.2]
NodeResGNN	0.6945 $\pm$ 0.0509 [0.599, 0.740]	0.7207 $\pm$ 0.0259 [0.689, 0.763]	0.2650 $\pm$ 0.0661 [0.158, 0.3]
NodeCrossGNN	0.6963 $\pm$ 0.0433 [0.626, 0.753]	0.7198 $\pm$ 0.0178 [0.706, 0.754]	0.3000 $\pm$ 0.0580 [0.233, 0.4]
GraphResGNN	0.7223 $\pm$ 0.0367 [0.653, 0.762]	0.6934 $\pm$ 0.0458 [0.609, 0.737]	0.3117 $\pm$ 0.0746 [0.167, 0.4]
GraphCrossGNN	0.6864 $\pm$ 0.0465 [0.595, 0.717]	0.7097 $\pm$ 0.0309 [0.668, 0.763]	0.3017 $\pm$ 0.0750 [0.183, 0.4]

表 5: Supplementary robustness benchmark results. Cells show mean $\pm$ std [min, max] over five folds. Bold: best mean per dataset.

Model	MUTAG	AIDS	Mutagenicity
PlainGNN	0.7236 $\pm$ 0.0486 [0.676, 0.811]	0.8455 $\pm$ 0.0257 [0.800, 0.870]	0.7814 $\pm$ 0.0235 [0.749, 0.8]
NodeResGNN	0.7343 $\pm$ 0.0734 [0.649, 0.865]	0.8690 $\pm$ 0.0354 [0.800, 0.897]	0.7897 $\pm$ 0.0139 [0.766, 0.8]
NodeCrossGNN	0.7397 $\pm$ 0.0676 [0.676, 0.865]	0.8735 $\pm$ 0.0412 [0.795, 0.915]	0.8033 $\pm$ 0.0159 [0.776, 0.8]
GraphResGNN	0.7290 $\pm$ 0.0585 [0.676, 0.838]	0.9160 $\pm$ 0.0121 [0.892, 0.927]	0.8022 $\pm$ 0.0220 [0.770, 0.8]
GraphCrossGNN	0.7129 $\pm$ 0.0539 [0.649, 0.811]	0.8710 $\pm$ 0.0412 [0.800, 0.927]	0.8029 $\pm$ 0.0182 [0.774, 0.8]




图 3: 活跃数据集包上的基准测试。每个柱表示平均最佳测试准确率，柱顶数字标出精确均值，误差线显示折间标准差。

表 6: Winner summary with max/min fold accuracy and parameter count for each dataset.

Dataset	Winner	Mean Acc	Max Acc	Min Acc	Best Epoch	Params
PROTEINS	GraphResGNN	0.7223	0.7623	0.6532	58.8	51208
DD	NodeResGNN	0.7207	0.7627	0.6894	25.4	22530
ENZYMES	GraphResGNN	0.3117	0.3750	0.1667	91.4	52248
MUTAG	NodeCrossGNN	0.7397	0.8649	0.6757	88.2	34434
AIDS	GraphResGNN	0.9160	0.9275	0.8925	83.8	57928
Mutagenicity	NodeCrossGNN	0.8033	0.8247	0.7756	131.2	35330




图 4: 定义交叉残差路由实际价值的准确率增量。正值表示交叉设计的优势，负值表示对应的普通或残差替代方案仍然更强。

图 3 和图 4 从互补角度阐明同一点：交叉残差路由通常优于普通堆叠，但并非始终强于最佳残差替代方案。

生物学核心数据集结果

主生物基准结果报告于表 4。面向主题的解释锚定在蛋白质导向核心数据集中。这些数据承载了本文的主要实质性分量，因此这里的解释刻意比补充包更加详细。

残差复用仍是所报告套件中最强的默认家族。残差变体在 PROTEINS、DD、ENZYMES 和 AIDS 上数值排名第一。GraphResGNN 在 PROTEINS (0.7223 ± 0.0367)、ENZYMES (0.3117 ± 0.0746) 和 AIDS (0.9160 ± 0.0121) 上领先，而 NodeResGNN 在

DD (0.7207 ± 0.0259) 上领先。重点不在于每次残差领先幅度很大，而在于残差模型在相同五折协议下、跨核心生物任务反复保持在或接近顶部。值得注意的是，许多数值领先是有限度的：配对统计检验（见表 12 和表 13）显示大多数成对架构比较未达常规显著性 ($p < 0.05$)，这一模式本身即具有信息量——它表明在受控协议下，架构级别的差异小于划分级别的变异性。

交叉残差设计具有选择性强度，而非普遍占优。交叉变体在 MUTAG 和 Mutagenicity 上数值排名第一。更重要的是，最佳交叉变体在大多数已完成数据集上击败了 PlainGNN。因此，交叉路由明显不仅是设计上的新奇事物，但证据不支持“交叉普遍优于残差复用”这一更强声明。这一更窄的解读对可靠性至关重要，因为它同时匹配均值结果和所观察到的划分级变异。统计上显著的少数成对比较（例如，PROTEINS 上 SAGEConv 下 GraphResGNN > GraphCrossGNN, $p = 0.031$ ；DD 上 SAGEConv 下 NodeCrossGNN > GraphCrossGNN, $p = 0.027$ ）均涉及图级交叉变体输给残差或节点级交叉模型——表明图级交叉设计是家族中更脆弱的元素。

节点级交叉比图级交叉更可靠。跨已完成数据集，NodeCrossGNN 在数值上超越 NodeResGNN 的次数多于 GraphCrossGNN 超越 GraphResGNN 的次数。这表明在当前研究中，交换中间节点级状态是更鲁棒的交叉残差设计，而图级交叉路由对数据集更敏感，其在若干算子-数据集组合上相比图级残差复用的优势在统计上显著为负方向（见表 12 和表 13）。

普通堆叠遭受深度诱导信号坍塌，但并非一致更差。PlainGNN 在 PROTEINS 和 DD 上保持竞争力，但在最终套件中从未在数据集上领先，通常被残差或交叉残差变体超越。在 GCNConv 下的 ENZYMES 和 AIDS 上，PlainGNN 与最佳残差变体之间的差距具有统计显著性 (ENZYMES + GINConv: $p = 0.002$; AIDS + GCNConv: $p = 0.039$)，这与“普通堆叠的主导模式压制了具有判别力的中层结构信息，而单纯更深传播不足以弥补”的解释一致。

PROTEINS、DD 和 ENZYMES 的主题聚焦结果

PROTEINS. GraphResGNN 数值领先 (0.7223 ± 0.0367)，相比 PlainGNN 的优势为 $+0.017$ ，在大多数算子级比较中未达统计显著性（例如 GCNConv: $p = 0.375$, Cohen's $d = +0.45$ ，小到中等效应）。这表明尾部保留残差路由——重复注入图级摘要——提供有限但一致的收益，与“GraphResGNN 比普通堆叠保存了更多历史结构信号”的解释一致，同时不宣称普遍优势。最佳交叉变体 NodeCrossGNN (0.6963 ± 0.0433) 在该数据集上仍低于 GraphResGNN。

DD. NodeResGNN (0.7207 ± 0.0259) 和 NodeCrossGNN (0.7198 ± 0.0178) 几乎持平 ($\Delta = 0.0009$ ，在任何算子下均不显著)。实践解读是节点级历史结构信号保存在大型稀疏蛋白质图上很重要——增加交叉分支交换既不帮助也不损害。这是一个值得报告的零结果：它表明交叉分支通路在 DD 上不引入破坏性干预，但也不提供在其他数据集上所观察到的选择性增益。

ENZYMES. 交叉变体在数值上变得更具吸引力。GraphCrossGNN 达到 0.3017 ± 0.0750 , NodeCrossGNN 达到 0.3000 ± 0.0580 , 均明显高于 PlainGNN 的 0.2450 ± 0.0407 (在 GINConv 下具有统计显著性: NodeCrossGNN vs PlainGNN $p = 0.009$, GraphResGNN vs PlainGNN $p = 0.002$)。即便如此, GraphResGNN 仍数值领先 (0.3117 ± 0.0746)。然而, 所有模型的绝对准确率仍然较低 (最佳模型仅比 6 类随机基线 16.7% 高出约 15 个百分点), 表明 3 维输入特征和 600 张图的样本量创造了一个具有挑战性的制度, 其中表示学习本质上充满噪声。因此, ENZYMES 结果应被解读为相对排序的证据, 而非绝对任务掌握的证据。




图 5: 已完成主题导向 TU 数据集的聚焦比较。模式是混合而非单边的: 图级残差细化在 PROTEINS 和 ENZYMES 上最强, 而 DD 偏好节点级复用, NodeCrossGNN 保持竞争力但非主导。

设计空间中的性能权衡

表 7 汇总了全部 24 个数据集-算子组合的优胜者计数。GraphResGNN 在 24 个组合中的 12 个 (50%) 上取得了最高峰值准确率, 是最频繁的优胜者。NodeCrossGNN 是第二强的架构, 取得 6 次优胜 (25%), 且在 DD 上显著统治了四种算子中的三种 (GATConv、SAGEConv、GINConv)。NodeResGNN 取得 3 次优胜 (PROTEINS/GCNConv、MUTAG/GCNConv、Mutagenicity/SAGEConv), PlainGNN 取得 2 次 (均在 MUTAG 上), GraphCrossGNN 取得 1 次 (MUTAG/GATConv)。

表 7: 全部 24 个数据集-算子组合上的优胜者计数 (仅 GCNConv)。

Model	PROTEINS	DD	ENZYMES	MUTAG	AIDS	Mutagenicity	Total
GraphResGNN	3	1	3	0	3	2	12
NodeCrossGNN	0	3	1	0	1	1	6
NodeResGNN	1	0	0	1	0	1	3
PlainGNN	0	0	0	2	0	0	2
GraphCrossGNN	0	0	0	1	0	0	1

超越优胜者计数, 各架构在跨数据集一致性上存在系统性差异 (表 8)。GraphCrossGNN 尽管仅赢得一个组合, 却是排名最稳定的设计 (排名标准差 0.75), 在任何数据集

上从未低于第四名。GraphResGNN 虽然是最频繁的优胜者，但在 MUTAG 上跌至第五名（排名标准差 1.46）。NodeCrossGNN 占据中间一致性位置（排名标准差 1.00），且是平均最接近最佳模型的竞争者（平均差距 0.022）。

表 8: 六个数据集上的平均排名、与最佳的平均差距及排名稳定性 (GCNConv)。

Model	Mean rank	Mean gap to best	Rank std
GraphResGNN	1.8	0.005	1.46
GraphCrossGNN	2.7	0.018	0.75
NodeCrossGNN	3.0	0.022	1.00
NodeResGNN	3.2	0.024	1.57
PlainGNN	4.3	0.036	0.75

DD 案例对于理解交叉残差交互何时有帮助尤为说明性强。DD 是生物核心中最大且最稀疏的蛋白质图（1,178 张图，89 维特征），NodeCrossGNN 在四种算子中的三种下胜出。这表明双分支节点级交换在图大且稀疏时特别有效——互补并行通路可以保存在重复传播下单分支会压制的具有判别力的结构信号。相比之下，在全局上下文占主导的较小、较稠密的图（如 AIDS）上，GraphResGNN 的顺序图条件块结构是更有效的策略。

机制解释：准确率、一致性与表示连续性

上述基准模式描绘了一个设计空间，其中峰值准确率、跨数据集一致性和表示连续性并不对齐。这种张力在深度扩展分析中最为清晰可见。

在线性化普通更新下，重复消息传递多次应用相同的传播算子 $\mathbf{S}$ ，因此 ℓ 层后的隐藏状态形式为 $\mathbf{H}^{(\ell)} = \mathbf{S}^\ell \mathbf{X}$ ，越来越压制非主导频谱分量——这是标准的过度平滑趋势。残差复用改变了这一行为：在下一步传播前复用上一隐藏状态，产生了低阶和高阶传播项的多项式混合，使模型在仍受益于更深传播的同时，能够保存中层结构信息。

$L = 8$ 处的深度扩展 CKA 结果（图 6）揭示了一个引人注目的模式，挑战了“更强的表示连续性应预测更好的性能”这一简单直觉。NodeResGNN 在深层实现了最高的平均 CKA (0.968)，然而它表现出跨数据集最大的性能波动（排名标准差 1.57），且仅赢得 24 个组合中的 3 个。GraphResGNN 尽管平均 CKA 最低 (0.942)，却是最频繁的优胜者 (12/24)。这意味着层间的激进表示变化，当配合通过顺序图条件块的图级上下文重新注入时，可以是一种生产性而非破坏性的设计特征——GraphResGNN 的块使用累积的图级上下文有意地在每个阶段重塑表示，而这种重塑虽然在降低层间相似性，却在大多数数据集上产生了更具判别力的最终表示。

GraphCrossGNN 占据了一个具有启发意义的中间位置：它在复用变体中实现了第二高的深层平均 CKA (0.952)，同时是最排名一致的表现者（排名标准差 0.75）。其带有交叉摘要交换的配对块结构似乎提供了足够的表示连续性以保持跨数据集稳定，同时

仍然允许足够的表示变化以保持竞争力。NodeCrossGNN 同样维持了中间的 CKA 值和中间排名一致性，确认了跨分支交换不会破坏表示的稳定性。

综合来看，这些结果表明 CR-GNN 设计空间由一种三维张力定义：激进重塑表示的架构（GraphResGNN）实现最高峰值准确率，但排名跨数据集不一致；最忠实地保存表示的架构（NodeResGNN）实现最强的连续性，但性能波动大；平衡这些力量的架构（GraphCrossGNN、NodeCrossGNN）实现最一致（尽管不是最峰值）的性能。实践启示是：复用拓扑的选择应由实践者对风险的容忍度引导——峰值准确率至关重要且数据集特征充分理解时选择 GraphResGNN；跨多样数据集的一致、可预测性能是优先事项时选择 GraphCrossGNN。

补充鲁棒性数据集结果

补充鲁棒性结果报告于表 5。补充包强化了权衡模式。NodeCrossGNN 在 MUTAG (GATConv 算子) 和 Mutagenicity (GATConv) 上最强，而 GraphResGNN 在 AIDS 上保持最强。跨数据集一致性模式仍然成立：没有单一架构支配所有补充数据集，峰值准确率与一致性之间的选择取决于具体的数据集-算子上下文。

门控消融结果

门控消融检验了残差注入的自适应控制对于所观察到的架构优势是否必要。在最强的图级残差目标 (AIDS + GraphResGNN + GINConv) 上，可学习门控是最强设置，尽管固定系数 0.5 非常接近。在六个交叉偏好目标上，可学习门控在其中三个上最佳，固定门控在另外三个上最佳——表明交叉残差架构对门控配置并不过度敏感，这与其更大的排名稳定性一致。

表 12 和表 13 提供了完整的配对检验矩阵。大多数架构级数值差距相对于折间变异是有限的，这与本文关于复用拓扑之间的差异是真实但有条件的解释一致。

残差路由结果

残差路由分析为权衡框架增加了一个机制维度。四个代表性目标在相同的五折协议下比较了可学习、Top-k 和稀疏路由模式。最清晰的信号是，中等阈值 (0.05) 的稀疏路由是最频繁的最优配置，在四个目标中的三个上胜出。可学习稠密路由仅在最强图级残差线路上保持最佳。三个偏好稀疏的目标中有两个涉及交叉残差架构，表明稀疏过滤与跨分支交换构成了一种特别有效的组合：稀疏性抑制了原本会作为噪声累积的弱残差通道，而跨分支通路确保了真正互补的信息得以保存。

表 9: AIDS gate ablation on GraphResGNN + GINConv. Numbers are five-fold mean accuracy $\pm$ standard deviation. Bold: best per column.

Gate setting	Mean accuracy
Learnable	0.9620 $\pm$ 0.0089
Fixed 0.0	0.9150 $\pm$ 0.0138
Fixed 0.5	0.9605 $\pm$ 0.0144
Fixed 1.0	0.9480 $\pm$ 0.0300

表 10: Fold-level AIDS gate ablation on AIDS + GraphResGNN + GINConv. Bold: best per column.

Gate setting	Fold 0	Fold 1	Fold 2	Fold 3	Fold 4	Mean $\pm$ Std
Learnable	0.9500	0.9700	0.9700	0.9675	0.9525	0.9620 $\pm$ 0.0089
Fixed 0.0	0.9225	0.9025	0.9125	0.9000	0.9375	0.9150 $\pm$ 0.0138
Fixed 0.5	0.9325	0.9625	0.9675	0.9675	0.9725	0.9605 $\pm$ 0.0144
Fixed 1.0	0.8925	0.9450	0.9700	0.9775	0.9550	0.9480 $\pm$ 0.0300

残差参数扫描结果

额外的路由设置细化了而非改变了这一模式。最强 Top-k 比例因目标而异，证实不存在全局最优保留水平。激进稀疏（0.10）损害了最强的图级残差目标，准确率显著下降，强化了稀疏性的收益取决于适当阈值这一条件性。

深度扩展与表示相似性

为进一步检验深度如何影响表示动力学，我们将隐藏状态相似性分析从 $L = 1$ 扩展到 $L = 8$ 层（PROTEINS 数据集，GCNConv 算子）。图 6 展示了每种模型在相邻深度阶段之间的 CKA 相似性，图 7 展示了对应的余弦相似性。

呈现了若干模式。第一，更深堆叠在所有五种架构中一致降低了相邻阶段相似性，确认深度诱导的表示分歧是一个普遍现象。第二，在 $L = 2-3$ 时，所有架构均保持相对较高的 CKA，与早期层捕获广泛共享的局部结构一致。在 $L = 8$ 时，排序变为：NodeResGNN (0.968) > GraphCrossGNN (0.952) > PlainGNN (0.951) > NodeCrossGNN (0.946) > GraphResGNN (0.942)。第三，也是最重要的，CKA 与性能之间的关系与朴素表示稳定性假设的预测相反：CKA 最高的模型（NodeResGNN）仅赢得 3/24 的组合，而 CKA 最低的模型（GraphResGNN）赢得了 12/24。这一反直觉的模式表明，GraphResGNN 的顺序块结构通过使用重新注入的图级上下文在每个阶段有意重塑表示，产生了更具判别力的最终表示——正因为——而非尽管——阶段间的表示变化。

图 8 进一步显示，随着深度扩展，不同架构的最深层梯度范数表现各异。PlainGNN 的最深层梯度范数随深度增加而退化比残差家族更快，而 NodeResGNN 和 NodeCross-

表 11: Cross-gate ablation on six cross-favored targets. Numbers are five-fold mean accuracy $\pm$ standard deviation. Bold: best per row.

Dataset	Target	Learnable	Fixed 0.0	Fixed 0.5	Fixed 1.0
AIDS	NodeCross + GATConv	0.9045 $\pm$ 0.0165	0.9075 $\pm$ 0.0065	0.9195 $\pm$ 0.0114	0.9105 $\pm$ 0.0241
DD	NodeCross + GATConv	0.7173 $\pm$ 0.0271	0.7053 $\pm$ 0.0361	0.7156 $\pm$ 0.0225	0.7147 $\pm$ 0.0288
DD	NodeCross + GINConv	0.7071 $\pm$ 0.0306	0.7012 $\pm$ 0.0198	0.7232 $\pm$ 0.0207	0.7113 $\pm$ 0.0277
ENZYMES	NodeCross + GATConv	0.2800 $\pm$ 0.0629	0.2850 $\pm$ 0.0627	0.2550 $\pm$ 0.0674	0.2650 $\pm$ 0.0690
MUTAG	GraphCross + GATConv	0.7558 $\pm$ 0.0495	0.7451 $\pm$ 0.0407	0.7450 $\pm$ 0.0416	0.7504 $\pm$ 0.0779
Mutagenicity	NodeCross + GATConv	0.8114 $\pm$ 0.0110	0.8033 $\pm$ 0.0192	0.8010 $\pm$ 0.0130	0.8036 $\pm$ 0.0078

GNN 即使在 $L = 8$ 时也保持更稳定的梯度信号。图级变体(GraphResGNN 和 GraphCrossGNN) 处于中间位置, 其中 GraphResGNN 在图级模型中表现出最稳定的梯度剖面。综合来看, 这些深度扩展结果——从浅层单层配置到深层八层堆叠——强化了本文的中心机制叙述: 残差复用减缓了更深配置下的表示坍塌和梯度退化, 而交叉残差交换不会引入破坏此稳定效应的干扰。




图 6: $L = 1$ 到 $L = 8$ 各层数下相邻深度阶段之间的 CKA 相似性。每个子图展示一个模型, 曲线对应不同层数。CKA 越高表示跨深度的表示连续性越强。

表 12: Paired t -tests for main biological benchmark datasets. Cells: Δ (Cohen's d , p).
Bold: $p < 0.05$ ($n=5$ folds).

Dataset	Comparison	GCNConv	GATConv	SAGEConv	
PROTEINS	NodeRes – Plain	+0.012 (+0.55, 0.286)	+0.000 (+0.00, 0.999)	+0.006 (+0.31, 0.524)	+0.006
	NodeCross – Plain	-0.008 (-0.28, 0.571)	-0.011 (-0.22, 0.647)	-0.002 (-0.07, 0.881)	-0.002
	GraphRes – Plain	+0.004 (+0.45, 0.375)	+0.015 (+0.48, 0.345)	+0.030 (+1.69, 0.019)	+0.030
	GraphCross – Plain	-0.001 (-0.02, 0.961)	-0.008 (-0.24, 0.623)	+0.004 (+0.24, 0.622)	+0.004
	NodeCross – NodeRes	-0.020 (-0.53, 0.302)	-0.011 (-0.19, 0.690)	-0.008 (-0.72, 0.181)	-0.008
	GraphCross – GraphRes	-0.005 (-0.15, 0.751)	-0.023 (-2.18, 0.008)	-0.026 (-1.47, 0.031)	-0.026
	GraphRes – NodeRes	-0.007 (-0.26, 0.588)	+0.015 (+0.37, 0.459)	+0.023 (+0.75, 0.171)	+0.023
	NodeCross – GraphCross	-0.007 (-0.49, 0.337)	-0.003 (-0.10, 0.838)	-0.005 (-0.21, 0.659)	-0.005
DD	NodeRes – Plain	+0.012 (+0.39, 0.429)	+0.002 (+0.24, 0.624)	+0.016 (+0.48, 0.347)	+0.016
	NodeCross – Plain	+0.019 (+0.55, 0.286)	+0.035 (+0.90, 0.115)	+0.023 (+0.87, 0.124)	+0.023
	GraphRes – Plain	+0.030 (+0.64, 0.223)	+0.020 (+0.50, 0.326)	+0.021 (+0.91, 0.112)	+0.021
	GraphCross – Plain	+0.024 (+0.87, 0.123)	+0.019 (+0.46, 0.357)	+0.004 (+0.19, 0.699)	+0.004
	NodeCross – NodeRes	+0.008 (+0.43, 0.395)	+0.033 (+0.88, 0.121)	+0.007 (+0.64, 0.226)	+0.007
	GraphCross – GraphRes	-0.007 (-0.23, 0.637)	-0.002 (-0.11, 0.815)	-0.017 (-2.82, 0.003)	-0.017
	GraphRes – NodeRes	+0.019 (+0.64, 0.228)	+0.019 (+0.46, 0.359)	+0.005 (+0.24, 0.624)	+0.005
	NodeCross – GraphCross	-0.004 (-0.31, 0.526)	+0.016 (+1.07, 0.075)	+0.019 (+1.53, 0.027)	+0.019
ENZYMES	NodeRes – Plain	-0.000 (-0.00, 1.000)	+0.005 (+0.19, 0.697)	-0.017 (-0.94, 0.103)	-0.017
	NodeCross – Plain	+0.003 (+0.09, 0.847)	+0.032 (+0.45, 0.369)	+0.007 (+0.24, 0.614)	+0.007
	GraphRes – Plain	+0.020 (+0.92, 0.107)	+0.020 (+0.32, 0.507)	+0.020 (+0.47, 0.360)	+0.020
	GraphCross – Plain	+0.020 (+0.55, 0.280)	+0.007 (+0.08, 0.875)	+0.020 (+0.33, 0.502)	+0.020
	NodeCross – NodeRes	+0.003 (+0.08, 0.878)	+0.027 (+0.36, 0.471)	+0.023 (+0.42, 0.399)	+0.023
	GraphCross – GraphRes	-0.000 (-0.01, 0.981)	-0.013 (-0.21, 0.672)	+0.000 (+0.00, 1.000)	-0.000
	GraphRes – NodeRes	+0.020 (+0.57, 0.264)	+0.015 (+0.28, 0.562)	+0.037 (+0.82, 0.151)	+0.037
	NodeCross – GraphCross	-0.017 (-0.47, 0.355)	+0.025 (+0.68, 0.211)	-0.013 (-0.40, 0.444)	-0.013




图 7: $L = 1$ 到 $L = 8$ 各层数下相邻深度阶段之间的余弦相似性。模式与 CK A 结果相

表 13: Paired t -tests for supplementary robustness datasets. Cells: Δ (Cohen’s d , p).
Bold: $p < 0.05$ ($n=5$ folds).

Dataset	Comparison	GCNConv	GATConv	SAGEConv	
MUTAG	NodeRes – Plain	+0.011 (+0.29, 0.545)	+0.000 (+0.00, 1.000)	-0.016 (-0.40, 0.416)	-0
	NodeCross – Plain	+0.016 (+0.36, 0.477)	+0.005 (+0.09, 0.850)	+0.005 (+0.15, 0.758)	+0
	GraphRes – Plain	+0.005 (+0.09, 0.864)	+0.011 (+0.33, 0.513)	-0.011 (-0.10, 0.839)	-0
	GraphCross – Plain	-0.011 (-0.20, 0.683)	+0.027 (+0.59, 0.262)	-0.022 (-0.28, 0.576)	-0
	NodeCross – NodeRes	+0.005 (+0.10, 0.836)	+0.005 (+0.10, 0.845)	+0.022 (+0.33, 0.516)	+0
	GraphCross – GraphRes	-0.016 (-0.34, 0.515)	+0.016 (+0.37, 0.467)	-0.011 (-0.26, 0.613)	+0
	GraphRes – NodeRes	-0.005 (-0.12, 0.808)	+0.011 (+0.17, 0.742)	+0.005 (+0.08, 0.881)	-0
	NodeCross – GraphCross	+0.027 (+0.71, 0.186)	-0.022 (-0.61, 0.240)	+0.027 (+0.53, 0.310)	+0
AIDS	NodeRes – Plain	+0.023 (+1.19, 0.062)	+0.010 (+0.89, 0.112)	+0.018 (+0.86, 0.125)	+0
	NodeCross – Plain	+0.028 (+1.06, 0.083)	+0.018 (+0.80, 0.144)	+0.020 (+1.52, 0.022)	+0
	GraphRes – Plain	+0.070 (+2.41, 0.005)	+0.025 (+1.57, 0.041)	+0.028 (+2.45, 0.004)	+0.0
	GraphCross – Plain	+0.025 (+0.94, 0.089)	+0.013 (+1.10, 0.068)	+0.018 (+1.16, 0.067)	+0
	NodeCross – NodeRes	+0.005 (+0.41, 0.420)	+0.008 (+0.52, 0.311)	+0.003 (+0.14, 0.778)	+0
	GraphCross – GraphRes	-0.045 (-1.46, 0.043)	-0.013 (-0.66, 0.218)	-0.010 (-0.44, 0.398)	-0
	GraphRes – NodeRes	+0.047 (+2.62, 0.002)	+0.015 (+1.19, 0.063)	+0.010 (+0.46, 0.370)	+0
	NodeCross – GraphCross	-0.003 (-0.10, 0.848)	+0.005 (+0.44, 0.387)	+0.003 (+0.20, 0.682)	-0
Mutagenicity	NodeRes – Plain	+0.004 (+0.26, 0.597)	+0.011 (+0.95, 0.101)	+0.014 (+0.93, 0.106)	+0
	NodeCross – Plain	+0.011 (+0.68, 0.201)	+0.020 (+1.05, 0.079)	+0.013 (+0.86, 0.127)	+0
	GraphRes – Plain	+0.019 (+1.24, 0.050)	+0.008 (+0.57, 0.273)	+0.012 (+0.62, 0.237)	+0
	GraphCross – Plain	+0.016 (+0.85, 0.131)	+0.009 (+0.46, 0.366)	+0.012 (+0.49, 0.333)	+0
	NodeCross – NodeRes	+0.006 (+0.26, 0.588)	+0.009 (+0.69, 0.195)	-0.001 (-0.13, 0.787)	+0
	GraphCross – GraphRes	-0.003 (-0.30, 0.545)	+0.002 (+0.08, 0.874)	+0.000 (+0.00, 0.999)	-0
	GraphRes – NodeRes	+0.015 (+0.87, 0.125)	-0.003 (-0.27, 0.583)	-0.003 (-0.18, 0.714)	+0
	NodeCross – GraphCross	-0.005 (-0.35, 0.476)	+0.010 (+0.50, 0.324)	+0.001 (+0.10, 0.832)	+0




图 8: 所有五种架构在 PROTEINS (GCNConv) 上的最深层梯度 L2 范数随层数 ($L = 1$ 至 $L = 8$) 的变化。残差家族在深层维持更稳定的梯度信号, 而 PlainGNN 表现出最陡峭的下降。图级变体处于中间位置。

表 14: Residual-routing and parameter-sweep summary on four representative targets (transposed). Numbers are five-fold mean accuracy $\pm$ standard deviation. Bold: best per column.

Routing	AIDS+GraphRes+GIN	PROT+GraphRes+SAGE	AIDS+NodeCross+GAT	DD+NodeCross+GAT
Learnable	0.9500 $\pm$ 0.0087	0.7178 $\pm$ 0.0411	0.8970 $\pm$ 0.0491	0.7080 $\pm$ 0.0172
Top-k 0.25	0.9075 $\pm$ 0.0237	0.7241 $\pm$ 0.0407	0.9160 $\pm$ 0.0128	0.7062 $\pm$ 0.0249
Top-k 0.50	0.9330 $\pm$ 0.0251	0.7151 $\pm$ 0.0397	0.8960 $\pm$ 0.0483	0.7029 $\pm$ 0.0160
Top-k 0.75	0.9240 $\pm$ 0.0287	0.7214 $\pm$ 0.0318	0.8960 $\pm$ 0.0489	0.7164 $\pm$ 0.0248
Sparse 0.02	0.9470 $\pm$ 0.0181	0.7160 $\pm$ 0.0248	0.9060 $\pm$ 0.0268	0.7147 $\pm$ 0.0259
Sparse 0.05	0.9250 $\pm$ 0.0152	0.7259 $\pm$ 0.0475	0.9180 $\pm$ 0.0162	0.7181 $\pm$ 0.0196
Sparse 0.10	0.8315 $\pm$ 0.0549	0.7088 $\pm$ 0.0521	0.9025 $\pm$ 0.0139	0.7105 $\pm$ 0.0243
Best	Learnable	Sparse 0.05	Sparse 0.05	Sparse 0.05

表 15: Family-wise routing winners.

Target	Best learnable	Best top-k	Best sparse	Overall winner
AIDS + GraphRes + GIN	0.9500	0.9330	0.9470	Learnable
PROTEINS + GraphRes + SAGE	0.7178	0.7241	0.7259	Sparse
AIDS + NodeCross + GAT	0.8970	0.9160	0.9180	Sparse
DD + NodeCross + GAT	0.7080	0.7164	0.7181	Sparse

探索性敏感性分析

在 PROTEINS、DD 和 ENZYMES 上针对深度、dropout 和学习率的辅助敏感性检验不会实质性改变主要结论。在 PROTEINS 和 DD 上，温和的调参变化影响两个交叉变体之间的差距，但它们不会推翻“残差基线保持更强的默认参考”这一更广泛的结论。在 ENZYMES 上，验证信号明显更嘈杂，且局部有希望的设置在最终五折平均下未能复现原始全量交叉结果。这些检验为透明性而报告，但不应被视为与重复划分基准和针对性消融同等水平的证据。

4 讨论

本研究的主要实证信息是，CR-GNN 设计空间揭示了峰值准确率、跨数据集一致性和表示连续性之间的系统性权衡——当仅通过单一胜者通吃指标比较架构时，这些权衡是不可见的。GraphResGNN 获胜最频繁（50% 的组合），但深层表示连续性最弱，且在特定数据集上存在离群性能。NodeResGNN 实现了最佳的表示连续性（ $L = 8$ 时 CKA 0.968），但性能波动最大。交叉残差架构（NodeCrossGNN、GraphCrossGNN）在两个维度上均占据中间位置，其中 GraphCrossGNN 成为排名最一致的设计。因此，本文的贡献不在于声明一个单一最佳架构，而在于使这些权衡得以定量可见的受控比较框架。

通向高性能的两条路径

数据支持在 CR-GNN 设计空间内存在两条通向强图分类性能的独特路径。

路径 1：基于图级上下文的激进表示重塑 (GraphResGNN)。 GraphResGNN 链接了三个图条件块，每个块接收前一块的池化图嵌入作为条件信号。该设计产生了最低的层间 CKA 值 ($L = 8$ 时为 0.942) ——表明阶段间存在实质性的表示变化——却在大多数数据集-算子组合上实现了最高的原始准确率。其机制似乎是：在每个块处重新注入图级上下文，创造了有意的、结构化的表示重塑：模型的目标不是跨深度保存表示，而是使用累积的全局信息逐步细化表示。该策略在全局图级上下文具有较强的判别力时最为有效（如 AIDS、ENZYMES、PROTEINS），但当局部结构基序是主导信号时可能失败（如 MUTAG，GraphResGNN 排名第五）。

路径 2：具有跨分支交换的平衡表示连续性 (GraphCrossGNN、NodeCrossGNN)。 交叉残差架构维持了 CKA 的中间值，同时实现了跨数据集最一致的排名。GraphCrossGNN 尤其在任何数据集上从未低于第四名（排名标准差 0.75），使其成为数据集特征不确定或跨多样任务的稳定性能比单数据集峰值准确率更受重视时最安全的架构选择。NodeCrossGNN 在 DD 上的统治地位（3/4 算子）进一步证明了双分支节点级交换在大而稀疏的蛋白质图上特别有效——互补并行通路可以保存在单分支下会被压制的具有判别力的结构信号。因此，交叉残差通路提供了一种针对激进表示重塑可能伴随的脆弱性的“保险”。

这两条路径的存在具有实践含义：GraphResGNN 与交叉残差变体之间的选择应由实践者优先考虑单任务峰值准确率（选择 GraphResGNN）还是跨多样、可能异构的数据集的一致性能（选择 GraphCrossGNN），或者是否专门处理大型稀疏图和基于注意力的算子（选择 NodeCrossGNN）来决定。

节点级与图级复用产生不同的权衡剖面

节点级与图级复用之间的区分具有实践重要性，并且与权衡框架存在交互。GraphResGNN 和 GraphCrossGNN 携带比其节点级对应物更多的参数（例如，在 PROTEINS 上 GraphResGNN $\approx 51k$ vs. NodeResGNN $\approx 23k$ ），但这种参数优势并非均匀转化：GraphResGNN 在 PROTEINS 和 ENZYMES 上排名第一，但在 MUTAG 上排名第五——其中更轻量的节点级模型表现更好。这表明信息流拓扑而非参数数量是性能-一致性权衡的主要决定因素。NodeCrossGNN 尽管使用的参数少于 GraphResGNN，却是第二获胜最多的架构（6/24 组合），且它是通过拓扑而非容量实现这一点的。

为何 ENZYMES 对所有架构仍保持困难

所有模型在 ENZYMES 上的绝对性能都很差：最佳模型（GraphResGNN，0.333）仅比 6 类随机基线（16.7%）高出约 16 个百分点。若干因素共同导致：仅 600 张图和 3 维输入特征；6 类结构创造了比基准其余部分主导的二元任务更难的决策边界；以及

生物核心中最大的折级标准差 (± 0.100)。ENZYMES 结果最好被解读为”即使在嘈杂、低数据制度下架构排序仍然一致”的证据,而非”任何架构都能很好地解决该任务”的证据。

残差路由与稀疏性调节权衡

路由分析揭示,路由策略可以移动性能-一致性权衡。中等阈值 (0.05) 的稀疏路由在四个代表性目标中的三个上最优,且这三个目标中有两个涉及交叉残差架构。这指向一个机制层面的协同效应:稀疏性抑制了原本会随深度作为噪声累积的弱残差通道,而跨分支通路确保了真正互补的信息通过替代路线得以保存。可学习稠密路由在最强图级残差目标 (AIDS + GraphResGNN + GINConv) 上保持最佳,其中丰富的历史上下文受益于未经过滤的复用。实践指导是:将稀疏路由与交叉残差架构结合以获得平衡、一致的性能;在特征明确的数据集上最大化峰值准确率时,将可学习稠密路由与图级残差架构结合使用。

深度扩展证据与 CKA-性能悖论

深度扩展分析 (图 6-8) 记录了一个挑战”更强的表示连续性应预测更好的性能”这一直觉假设的发现。NodeResGNN 在 $L = 8$ 时实现了最高的 CKA (0.968), 但仅赢得 3/24 组合, 且排名波动最大。GraphResGNN 实现了最低的 CKA (0.942), 却赢得了 12/24 组合。这种”CKA-性能悖论”表明深度阶段间的表示变化本质上并非有害——当通过图条件块重新注入等机制结构化时, 它可以具有生产性。相反, 过于忠实地保存表示 (如 NodeResGNN 所做的) 可能限制模型在每个深度阶段将其表示适应任务特定结构的能力。交叉残差变体占据了一个富有成效的中间位置: 足够的连续性以避免 PlainGNN 的脆弱性, 足够的变化以保持与 GraphResGNN 的竞争力。

证据层次与研究局限

最强的证据来自五折基准和针对性五折消融。较旧的单折敏感性扫描仅对优化解释有用。第二个局限是统计功效: 每个组合仅有五个配对观测, 检验对中小效应 (Cohen's $d < 0.5$) 的检测能力有限。这并不削弱本文的结论, 但意味着架构比较应被理解为在受控条件下的数值排序, 而非统计占优的陈述。第三个局限是基线范围: 基准包含代表性基线, 但并非意图穷尽覆盖所有近期方法的排行榜。第四个局限是数据集规模: 虽然数据集是生物分子且有意义的, 但它们仍是中等规模的基准数据集。因此, 本研究支持关于受控图分类行为和设计权衡的结论, 而非关于大规模可扩展性或直接生物学发现的结论。第五个专门针对深度扩展分析的局限是, 该分析仅在一个数据集-算子组合 (PROTEINS, GCNConv) 上进行; 将其扩展至其他数据集和算子将检验 CKA-性能悖论的普遍性。

未来方向

最重要的扩展是检验权衡框架是否能泛化到更大的图基准和更丰富的生物学输入。CKA-性能悖论——表示连续性最弱的架构实现了最高的峰值准确率——值得在多样领域进行进一步研究，以确定它是深度 GNN 设计空间的普遍属性，还是特定于本研究所涉及的生物分子设定。交叉残差加稀疏路由构成特别有效组合这一发现也应在更广泛的任务上进行检验，其中图拓扑必须与更强的领域监督相结合。

5 结论

本文将 CR-GNN 作为一个受控的生物分子图分类框架加以研究，并发现该设计空间揭示了峰值准确率、跨数据集一致性和表示连续性之间的系统性权衡。主要贡献不是一个普遍占优的架构，而是一个使这些权衡定量可见并提供架构选择实践指导的可复现比较框架。

关键实证发现如下。第一，GraphResGNN 最频繁地实现了最高的峰值准确率（24 个数据集-算子组合中的 50%），但深层表示连续性最弱（ $L = 8$ 时 CKA 0.942），排名波动最大（标准差 1.46）。第二，NodeCrossGNN 是第二强的架构（25% 的组合），在 DD 上跨越三种算子占统治地位，且在大而稀疏的图与基于注意力的算子组合上特别有效。第三，GraphCrossGNN 是排名最一致的设计（标准差 0.75），从未低于第四名，使其在数据集特征不确定时是最安全的架构选择。第四，深度扩展分析记录了一个“CKA-性能悖论”：表示连续性最高的架构（NodeResGNN，CKA 0.968）在复用变体中获胜最少，而连续性最低的架构（GraphResGNN）获胜最多。这挑战了“更强的表示稳定性必然产生更好的性能”这一假设。

路由分析提供了机制层面的证据，表明稀疏路由与交叉残差架构的组合构成了一个特别有效的配置，其中稀疏模式（阈值 0.05）在四个代表性目标中的三个上最优。这种协同效应——稀疏性抑制弱通道，而跨分支交换保存互补信息——代表了未来 GNN 架构发展的一个实用设计原则。

这些结论的范围应保持严谨。最有力的声明得到分层五折基准、针对性五折消融以及在 PROTEINS (GCNConv) 上从 $L = 1$ 到 $L = 8$ 的深度扩展分析的支持。统计证据（表 12 和表 13）确认了架构级效应相对于折间变异是有限的，这与本文以机制为导向而非以排行榜为导向的框架一致。本研究涉及中等规模生物分子基准上的受控图分类行为，其本身并不确立大规模可扩展性或直接生物学可解释性。

在实际层面，本工作提供以下指导：当特征明确的数据集上的峰值准确率是优先事项时，选择 GraphResGNN 搭配可学习稠密路由；当需要跨多样数据集的稳定可预测性能时，选择 GraphCrossGNN 搭配稀疏路由；当处理大而稀疏的图时，选择 NodeCrossGNN 搭配 GATConv。这些结果将 CR-GNN 定位为一个实用设计空间，并为未来在更丰富的生物学输入、更大规模基准以及本文所记录权衡可被进一步检验和精化的图学习设定上的工作提供了方法论基础。

致谢

作者感谢开源图学习社区以及本研究所用基准资源的维护者。同时感谢审稿人和编辑的时间与反馈。

参考文献

- Uri Alon and Eran Yahav. On the bottleneck of graph neural networks. In *International Conference on Learning Representations (ICLR)*, 2021.
- Xavier Bresson and Thomas Laurent. Residual gated graph convnets. *arXiv preprint arXiv:1711.07553*, 2017.
- Tianle Cai, Jiacheng Luo, Sheng Wang, Kai Zhang, Yu Tian, Liwei Yang, Zekun Li, and Kilian Weinberger. Graphnorm: A principled approach to accelerating graph neural network training. In *International Conference on Machine Learning*, pages 1277–1287, 2021.
- Ming Chen, Zhewei Wei, Zengfeng Huang, Bolin Ding, and Yaliang Li. Simple and deep graph convolutional networks. In *International Conference on Machine Learning (ICML)*, pages 1725–1735, 2020a.
- Yuning Chen, Xihao Wei, Pan Xu, Xinwen Wang, Ping Luo, Zhiyuan Li, and Jian Tang. Revisiting over-smoothing in deep gcns. *arXiv preprint arXiv:2003.13663*, 2020b.
- Matthias Fey and Jan Eric Lenssen. Fast graph representation learning with pytorch geometric. *arXiv preprint arXiv:1903.02428*, 2019.
- Hongyang Gao and Shuiwang Ji. Graph u-net. *arXiv preprint arXiv:1905.05178*, 2019.
- Justin Gilmer, Samuel S Schoenholz, Patrick F Riley, Oriol Vinyals, and George E Dahl. Neural message passing for quantum chemistry. In *International Conference on Machine Learning*, pages 1263–1272, 2017.
- William L Hamilton, Rex Ying, and Jure Leskovec. Inductive representation learning on large graphs. In *Advances in neural information processing systems*, pages 1024–1034, 2017.
- Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778, 2016.

- Thomas N Kipf and Max Welling. Semi-supervised classification with graph convolutional networks. *arXiv preprint arXiv:1609.02907*, 2016.
- Johannes Klicpera, Alan Bojchevski, and Stephan Günnemann. Combining label propagation and simple models out-performs graph neural networks. *arXiv preprint arXiv:1810.05997*, 2018.
- Guohao Li, Elias Muller, Abbas Thabet, and Bernard Ghanem. Deeper insights into graph convolutional networks for semi-supervised learning. *arXiv preprint arXiv:1809.02584*, 2018.
- Christopher Morris, Roger Wattenhofer, and Kristian Kersting. Tudataset: A collection of benchmark datasets for learning with graphs. *arXiv preprint arXiv:2007.08663*, 2020.
- Kenta Oono and Taiji Suzuki. Simple and deep graph convolutional networks. *arXiv preprint arXiv:2006.13604*, 2020.
- Yu Rong, Wenbing Huang, Tingyang Xu, and Junzhou Huang. Dropedge: Towards deep graph convolutional networks on node classification. *arXiv preprint arXiv:1907.10903*, 2019.
- Jake Topping, Francesco Di Giovanni, Benjamin Chamberlain, Michael Bronstein, Douwe Vendrig, and Pietro Lio. Understanding over-squashing and bottlenecks on graphs via curvature. *arXiv preprint arXiv:2111.14522*, 2021.
- Zonghan Wu, Shirui Pan, Fengwen Chen, Guoding Long, Cheng Zhang, and Sheng Yu Zhang. A comprehensive survey on graph neural networks. *IEEE Transactions on Neural Networks and Learning Systems*, 32(1):4–24, 2021.
- Keyulu Xu, Chengtao Li, Yonglong Tian, Xiao Du, Jure Leskovec, and Stefanie Jegelka. Representation learning on graphs with jumping knowledge networks. In *International Conference on Machine Learning*, pages 5449–5458, 2018.
- Rex Ying, Jiaxuan You, Christopher Morris, Xiang Ren, William L Hamilton, and Jure Leskovec. Hierarchical graph representation learning with differentiable pooling. In *Advances in neural information processing systems*, pages 4800–4810, 2018.
- Lingxiao Zhao and Leman Akoglu. Pairnorm: Tackling over-smoothing in gns. *arXiv preprint arXiv:2009.10698*, 2020.
- Jie Zhou, Ganqu Cui, Zhengyan Zhang, Cheng Yang, Zhaocheng Liu, Zhongyuan Wang, Peng Li, Ming Sun, Yu Shi, et al. Graph neural networks: A review of methods and applications. *AI Open*, 1:57–81, 2020.