

交叉残差图神经网络用于生物分子图分类： 残差路由的实证研究

付小琴*

摘要

研究背景。图神经网络广泛用于蛋白质和分子的图分类任务，但更深层的消息传递会模糊具有判别力的局部结构，而标准跳跃连接未能阐明跨分支历史交换是否比普通残差复用提供更好的权衡。该问题在生物分子图分类中尤为突出，因为有效的判别证据可能同时依赖于局部结构基序和图级上下文，而信息流拓扑的选择会显著影响所学表示的质量。

研究方法。本文将交叉残差图神经网络（CR-GNN）作为一个受控比较框架加以研究，该框架在共享的图分类主干网络下评估了普通堆叠、节点级残差复用、节点级交叉残差交换、图级残差传播和图级交叉摘要交换五种设计。基准测试围绕具有生物学意义的蛋白质导向核心数据集和补充分子鲁棒性数据集展开，所有结果均采用分层五折交叉验证，报告平均最佳测试准确率和折间标准差。此外，我们组织了门控机制、残差路由模式和残差参数扫描等针对性实验，并结合探索性敏感性分析，以分离出所观察到的架构模式背后的机制。

研究结果。在分层五折评估下，残差复用在整个生物分子基准测试套件中依然是更强的默认架构家族，而交叉残差路由相比普通堆叠持续改进，并在特定数据集上提供选择性增益而非统一优势。在生物学核心数据集中，图级残差传播在若干关键蛋白质导向基准上数值领先，而节点级残差复用在较大的稀疏蛋白质图上领先。交叉残差变体在所选分子数据集上成为排名第一的设计，这些数据集中稀有判别基序的保存尤为重要。针对性路由分析进一步揭示路由设计对性能有实质性影响：可学习稠密路由在最佳图级残差配置上保持最强，而温和稀疏路由在交叉导向目标上频繁展现出优势，这表明历史信息在复用前如何被过滤至少与复用路径是否存在同等重要。

研究结论。CR-GNN 最好被理解为一个受控的生物分子图分类设计空间，而非一个普遍占优的架构。实证证据支持一个有边界的结论：交叉残差交互有用但有条件性，残差复用依然是更强的默认参考，而路由策略是性能的重要决定因素。本文的贡献不在于单一的优胜架构，而在于一个可复现的比较框架，该框架揭示了残差路由何时以及如何发挥作用。

*柳州铁道职业技术学院铁路机车与车辆学院，广西柳州 545000

目录	2
----	---

目录

1 引言	3
2 材料与方法	5
3 结果	11
4 讨论	22
5 结论	25

1 引言

图神经网络 (GNN) 现已成为从分子图和蛋白质图中学习的标准方法, 因为它们能够将局部邻域结构与高阶关系上下文联合编码 (Kipf and Welling, 2016; Gilmer et al., 2017; Hamilton et al., 2017; Wu et al., 2021; Zhou et al., 2020)。在生物分子图分类中, 这种组合之所以重要, 是因为预测证据可能同时依赖于局部生化基序和更广泛的图级组织。因此, PROTEINS、DD、ENZYMES、MUTAG、AIDS 和 Mutagenicity 等基准测试套件仍作为方法导向图分类研究的受控测试平台发挥作用, 而非下游生物学发现的直接代理。

主要的方法论困难在于: 在这些设定下, 更深层的消息传递并非自动有益。重复传播会通过过度平滑和相关的深度效应 (Li et al., 2018; Oono and Suzuki, 2020; Chen et al., 2020b) 抑制具备信息量的中间状态, 而过度挤压效应 (Alon and Yahav, 2021; Topping et al., 2021) 则导致来自远距离节点的信息被压缩为无信息量的瓶颈。残差连接、归一化和正则化缓解了部分退化 (He et al., 2016; Bresson and Laurent, 2017; Zhao and Akoglu, 2020; Cai et al., 2021; Rong et al., 2019; Chen et al., 2020a), 但大多数残差设计仍沿同一分支复用信息。因此, 它们改善了优化过程, 却未直接检验替代的信息流拓扑是否能保存更有用的历史信号。

相关图学习工作已探索过跳跃连接、稠密聚合、APPNP 式传播、Jumping Knowledge 读出和层次化池化 (Xu et al., 2018; Klicpera et al., 2018; Gao and Ji, 2019; Ying et al., 2018)。这些方法保存了来自多个深度或跨越池化层次的信息, 但它们并未直接分离出跨分支交换隐藏状态或跨块边界重新注入池化图摘要是否优于普通同路径残差复用。这正是本文所填补的、更具体的研究缺口。

本文研究交叉残差图神经网络 (CR-GNN), 这是一个受控模型家族, 在共享的图分类主干下对比了普通堆叠、节点级残差复用、节点级交叉残差交换、图级残差传播和图级交叉摘要交换。研究围绕三个具体研究问题展开:

1. **交叉残差交互何时有帮助?** 在何种数据集特性和任务条件下, 跨并行分支交换隐藏状态能够比普通同路径复用更好地改善图分类?
2. **普通残差复用何时依然保持更强的默认选择?** 在哪些生物分子基准测试中, 更简单的单分支残差设计持续优于交叉残差替代方案? 这些数据集的结构特性如何解释这一模式?
3. **残差路由设计如何改变答案?** 超越“是否存在额外复用路径”的二元问题, 不同的过滤策略——可学习稠密路由、Top-k 选择和稀疏抑制——如何影响残差与交叉残差架构的相对性能?

围绕这三个问题组织研究对本文的方法论范围至关重要。目标不是宣称某一条额外通路总能产生更好的 GNN, 而是揭示残差路由何时以及如何发挥作用——即在主干网

络、数据划分和训练协议受控的条件下，哪种复用拓扑能够可靠地保存具有判别力的历史结构信号。

本文作为一项以机制为导向的生物分子图分类方法学研究展开。主要证据来自以 PROTEINS、DD 和 ENZYMES 为核心的蛋白质导向基准测试，辅以补充的分子鲁棒性数据集。该设计使论文贴近具有生物学意义的图设定，同时保持可复现和受控的基准范围。因此，后续章节从架构动机出发，进入共同的方法论设定，再到确认性基准结果、针对性消融实验和支持性敏感性分析。这一递进是有意为之：基准测试首先建立实证模式，门控和路由研究随后检验该模式是否可以通过残差信息向前传递的方式来解释。

主要贡献

本文的主要贡献如下：

- **复用拓扑的受控比较框架。**本文并非提出单一新架构并宣称其普遍更优，而是在相同主干网络、数据划分和训练协议下比较了五种信息流设计——普通堆叠、节点级残差复用、节点级交叉残差交换、图级残差传播和图级交叉摘要交换。该受控设置将复用拓扑的效果与模型容量、算子选择或训练超参数等混淆因素隔离开来，使得我们可以追问某种复用策略何时有帮助，而非仅关注它是否在平均意义上胜出。
- **条件性而非普遍性增益的实证证据。**在六个生物分子数据集的分层五折评估下，残差复用（NodeResGNN、GraphResGNN）依然是最可靠的默认选择，但其领先交叉残差变体的幅度有限且并不一致。交叉残差路由在大多数数据集上相比普通堆叠提供了明显改善，并在所选分子基准（如 MUTAG 和 Mutagenicity）上成为排名第一的设计。整体模式是选择性受益而非普遍占优：额外跨分支通路的价值取决于数据集特性，没有任何单一架构在所有数据集上排名第一。
- **路由级别的机制分析。**超越架构标签，本研究考察了残差信息在复用前如何被过滤——在相同的五折协议下比较了可学习稠密路由、Top-k 通道选择和稀疏抑制。结果表明路由策略是目标依赖的：可学习稠密路由在最佳图级残差配置上保持最强，而温和稀疏路由在交叉导向目标上往往表现出优势。这一发现将讨论从“我们是否应该添加残差路径？”重新框定为“历史信息在向前传递时应如何被过滤？”
- **节点级与图级复用的实践性区分。**信息复用的位置至少与复用是否存在同等重要。节点级交叉交换（NodeCrossGNN）是跨数据集中更稳定的交叉导向设计，而图级交叉路由（GraphCrossGNN）对数据集特性更敏感，在若干算子-数据集组合下其性能在统计上显著优于对应的图级残差基线。这一区别为实践者在复用策略之间的选择提供了实用的指导。

2 材料与方法

本节定义共同的图分类设定、CR-GNN 架构家族、基准测试包以及共享的实验协议。指导原则是隔离信息复用的位置，同时保持其余流程尽可能一致。该设计选择对本文的方法论论证至关重要：如果主干算子、池化和评估协议保持固定，那么性能差异更可能归因于复用拓扑本身，而非无关的实现变化。

问题定义与符号

令 $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ 表示无向或有向图，其中 $\mathcal{V} = \{v_1, v_2, \dots, v_n\}$ 是包含 n 个节点的节点集， $\mathcal{E} \subseteq \mathcal{V} \times \mathcal{V}$ 是边集。每个节点 $v_i \in \mathcal{V}$ 关联一个特征向量 $\mathbf{x}_i \in \mathbb{R}^{d_{\text{in}}}$ ，整张图的节点特征收集于 $\mathbf{X} \in \mathbb{R}^{n \times d_{\text{in}}}$ 中。图结构以邻接矩阵 $\mathbf{A}$ 表示。

给定训练数据集 $\mathcal{D} = \{(\mathcal{G}_i, y_i)\}_{i=1}^N$ ，目标是学习一个映射函数 $f_\theta: \mathcal{G} \rightarrow \hat{y}$ ，用于预测未见图的标签。本研究在同一图分类流程下比较五种架构：

- **PlainGNN**: 无显式状态复用的顺序消息传递
- **NodeResGNN**: 单分支节点级残差复用
- **NodeCrossGNN**: 双分支节点级交叉交换
- **GraphResGNN**: 跨顺序块的图级残差传播
- **GraphCrossGNN**: 跨配对块的图级交叉摘要交换

该比较旨在隔离信息复用的位置：在单分支内部、跨并行分支之间，或通过跨块传递的池化图摘要。这隔离出架构家族背后一个具体的研究问题。同分支残差复用主要检验重新注入历史状态是否能稳定更深层的传播，而交叉残差设计则检验跨并行流交换信息是否能保存普通堆叠下可能丢失的互补结构。

共享消息传递与图级学习

令 Φ 表示一个消息传递算子。对于选定的主干网络，节点表示通过 L 层更新如下：

$$\mathbf{h}_i^{(\ell+1)} = \sigma \left(\mathbf{W}^{(\ell)} \cdot \text{AGGREGATE}_\Phi \left(\left\{ \mathbf{h}_j^{(\ell)} : j \in \mathcal{N}(i) \right\}, \mathbf{h}_i^{(\ell)} \right) + \mathbf{b}^{(\ell)} \right). \quad (1)$$

在 L 层之后，读出函数 R 将节点级表示聚合为图嵌入：

$$\mathbf{h}_\mathcal{G} = R \left(\left\{ \mathbf{h}_i^{(L)} : i = 1, \dots, n \right\} \right). \quad (2)$$

分类器产生：

$$\hat{\mathbf{y}} = \text{softmax}(\mathbf{W}_{\text{clf}} \mathbf{h}_\mathcal{G} + \mathbf{b}_{\text{clf}}), \quad (3)$$

模型通过最小化交叉熵损失进行端到端训练：

$$\mathcal{L}(\theta) = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C y_{i,c} \log(\hat{y}_{i,c}). \quad (4)$$

CR-GNN 架构家族

CR-GNN 被定义为一个紧凑的图分类架构家族。所有变体共享相同的输入投影、堆叠消息传递层、图级池化和线性分类器；它们仅在中间节点状态和图级摘要如何在深度和分支之间复用的方式上有所不同。该设计特意避免引入单独的编码器、任务特定特征工程或架构特定的读出头部，因为此类添加将使判断任何观察到的增益来自残差拓扑还是来自额外模型容量变得更加困难。

令 $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ 为一个图，其节点特征矩阵为 $\mathbf{X} \in \mathbb{R}^{n \times d_{\text{in}}}$ ，邻接结构为 $\mathbf{A}$ 。模型可被实例化为四种标准消息传递算子之一：

$$\Phi \in \{\text{GCNConv}, \text{GATConv}, \text{SAGEConv}, \text{GINConv}\},$$

并在一个模型实例内统一使用同一算子类型。对于隐藏宽度 d ，每个分支以输入投影开始：

$$\mathbf{H}^{(0)} = \text{ReLU}(\Phi_{\text{in}}(\mathbf{X}, \mathbf{A})), \quad (5)$$

随后是 L 个隐藏层和读出：

$$\mathbf{g} = \text{Pool}(\mathbf{H}^{(L)}). \quad (6)$$

单分支和节点级残差变体

PlainGNN. 普通基线堆叠 L 层相同算子，不含残差复用：

$$\mathbf{H}^{(\ell+1)} = \psi(\text{ReLU}(\Phi_{\ell}(\mathbf{H}^{(\ell)}, \mathbf{A}))). \quad (7)$$

NodeResGNN. 第一个残差变体在同一分支内保存前一隐藏状态：

$$\mathbf{H}^{(\ell+1)} = \psi(\text{ReLU}(\Phi_{\ell}(\mathbf{H}^{(\ell)} + \mathbf{H}^{(\ell-1)}, \mathbf{A}))). \quad (8)$$

NodeCrossGNN. 节点级交叉残差模型维护两个具有独立输入投影的并行分支：

$$\mathbf{H}_1^{(\ell+1)} = \psi\left(\text{ReLU}\left(\Phi_{\ell}^{(1)}\left(\mathbf{H}_1^{(\ell)} + \tilde{\mathbf{H}}_2^{(\ell)}, \mathbf{A}\right)\right)\right), \quad (9)$$

$$\mathbf{H}_2^{(\ell+1)} = \psi\left(\text{ReLU}\left(\Phi_{\ell}^{(2)}\left(\mathbf{H}_2^{(\ell)} + \tilde{\mathbf{H}}_1^{(\ell)}, \mathbf{A}\right)\right)\right). \quad (10)$$

最终节点表示为两分支之和：

$$\mathbf{H}^{(L)} = \mathbf{H}_1^{(L)} + \mathbf{H}_2^{(L)}. \quad (11)$$

图级残差传播

GraphResGNN. 该变体链接三个图条件块：

$$\mathbf{g}^{(t+1)} = B_{t+1}(\mathbf{X}, \mathbf{A}, \mathbf{g}^{(t)}), \quad t \in \{1, 2\}. \quad (12)$$




图 1: 节点级 CR-GNN 架构。三列分别比较普通堆叠（左）、同分支残差复用（中）和双分支交叉残差交换（右）。在交叉残差设计中，每个分支不仅复用自身的先前状态，还复用对侧分支在前一层的状态，残差路由器控制跨分支注入的强度和稀疏度。

GraphCrossGNN. 四个块被组织为两个顺序对。在每个阶段内，两个块的输出被交换并作为下一阶段的图级输入复用：

$$(\mathbf{g}_1^{(t)}, \mathbf{g}_2^{(t)}) = \left(B_{2t-1}(\mathbf{X}, \mathbf{A}, \mathbf{g}_1^{(t-1)}), B_{2t}(\mathbf{X}, \mathbf{A}, \mathbf{g}_2^{(t-1)}) \right), \quad (13)$$

$$(\mathbf{g}_1^{(t+1)}, \mathbf{g}_2^{(t+1)}) = (\mathbf{g}_2^{(t)}, \mathbf{g}_1^{(t)}). \quad (14)$$

最终图嵌入为：

$$\mathbf{g}_{\text{final}} = \mathbf{g}_1^{(T)} + \mathbf{g}_2^{(T)}. \quad (15)$$

残差路由机制

除架构家族本身外，本研究还评估了残差信息如何被注入。这第二层分析是必要的，因为仅靠架构比较无法回答明显的残差优势究竟来自额外路径的存在，还是来自该路径被过滤的方式。针对性消融实验中使用了三种路由模式：

- **可学习路由：**稠密残差注入，由自适应门控调制。
- **Top-k 路由：**仅保留最强残差通道后再注入。
- **稀疏路由：**抑制弱残差系数，留下经过滤的残差路径。

这些路由模式不被用于重新定义核心架构家族，而是作为实验设计中选定残差和交叉残差目标之上的一个机制层。因此，路由研究是解释性而非装饰性的：它检验同一架构在残差信息以稠密、选择性或稀疏方式向前传递时是否表现不同。




图 2: 图级 CR-GNN 架构。三列分别比较普通图级堆叠 (左)、顺序图级残差传播 (中) 和跨配对块的交叉摘要交换 (右)。在交叉残差设计中, 共享残差状态和残差路由器控制并行块序列之间的图级信息交换, 可用四种路由模式: 固定、可学习、Top-k 和稀疏残差。

数据集

为在具有生物学意义的设定下检验所提出的架构, 基准测试被组织为一个统一的两层体系。

主生物基准测试包含 PROTEINS、DD 和 ENZYMES (Fey and Lenssen, 2019; Morris et al., 2020)。补充鲁棒性测试包包含 MUTAG、AIDS 和 Mutagenicity。该组织方式使主生物学声明聚焦于蛋白质导向数据集, 同时仍在额外分子图上检验结构鲁棒性。

PROTEINS PROTEINS 包含蛋白质的图表示, 其中节点表示二级结构元素, 边编码它们之间的邻域关系。任务为二值图分类。该数据集包含 1,113 张图, 2 个类别, 每节点 3 维输入特征。

DD DD 是一个蛋白质结构数据集, 其中每张图对应一个蛋白质, 节点表示氨基酸或结构相关单元, 通过邻近性导出的边连接。任务为二值分类。DD 包含 1,178 张图, 2 个类别, 89 维输入特征。

ENZYMES ENZYMES 是一个 6 类酶分类基准, 包含 600 张图和 3 维输入特征。它在保持酶导向生物学解释的同时, 仍可与研究中其他图分类基准直接比较。

所有活跃数据集通过统一基准接口使用 (Fey and Lenssen, 2019; Morris et al., 2020)。我们保持预处理尽可能轻量, 在最终协议中不引入任务特定的特征工程、图增强或边重设计。

表 1: Unified summary of the main biological benchmark package.

Dataset	Split	#Graphs	#Cls.	Feat.	Avg. N / E	Role
PROTEINS	5-fold CV + val	1113	2	3	39.1 / 72.8	main
DD	5-fold CV + val	1178	2	89	284.3 / 715.7	main
ENZYMES	5-fold CV + val	600	6	3	32.6 / 62.1	main

表 2: Supplementary robustness datasets retained outside the core biological narrative.

Dataset	Split	#Graphs	#Cls.	Feat.	Avg. N / E	Role
MUTAG	5-fold CV + val	188	2	7	17.9 / 19.8	supp.
AIDS	5-fold CV + val	2000	2	38	15.7 / 16.2	supp.
Mutagenicity	5-fold CV + val	4337	2	14	30.0 / 30.6	supp.

所有报告结果遵循相同的分层两阶段评估设计:

- **外评估:** 在图级别的分层五折交叉验证
- **内验证:** 从训练折中抽取的分层验证子集, 验证比例为 0.1

主要评估指标为保留测试折上的图分类准确率。对于折 k 和测试集 $\mathcal{T}_k$:

$$\text{Acc}_k = \frac{1}{|\mathcal{T}_k|} \sum_{(\mathcal{G}_i, y_i) \in \mathcal{T}_k} \mathbf{1}[\hat{y}_i = y_i]. \quad (16)$$

跨五个折, 我们报告平均准确率:

$$\overline{\text{Acc}} = \frac{1}{5} \sum_{k=1}^5 \text{Acc}_k \quad (17)$$

和对应的标准差:

$$\sigma_{\text{Acc}} = \sqrt{\frac{1}{5} \sum_{k=1}^5 (\text{Acc}_k - \overline{\text{Acc}})^2}. \quad (18)$$

比较方法与主干算子

论文面向的完整基准比较了九种方法。CR-GNN 家族包含五个模型: PlainGNN、NodeResGNN、NodeCrossGNN、GraphResGNN 和 GraphCrossGNN。四个外部基线也包含在基准测试包中: GraphSAGEBaseline、GINBaseline、JKNetBaseline 和 APP-NPBaseline。这些基线旨在将受控比较锚定在具有不同传播或聚合行为的代表性图分类家族上, 而非宣称穷尽覆盖所有近期排行榜方法。

每种方法在四种消息传递算子下评估:

- **GCNConv**

- GATConv
- GINConv
- SAGEConv

训练配置与实现细节

所有模型均在 PyTorch Geometric (Fey and Lenssen, 2019) 中实现，并在统一协议下训练。所有 CR-GNN 变体和外部基线共享的主干网络使用隐藏维度 $d = 64$ ， $L = 4$ 层消息传递层，每层激活后和最终分类器前应用 $p = 0.5$ 的 dropout。最后一层消息传递后，节点表示通过全局均值池化聚合，单个线性层将所得图嵌入映射至类别 logits。不应用批归一化或层归一化；唯一正则化为 dropout 和权重衰减。

训练使用 Adam 优化器，初始学习率 5×10^{-3} ，权重衰减 1×10^{-4} 。当验证损失连续 15 轮未改善时，学习率衰减为原来的 0.5 (ReduceLROnPlateau)，最低学习率为 1×10^{-5} 。每次运行最多训练 200 轮，批次大小为 256 张图。当验证损失连续 60 轮未改善时触发早停。梯度被裁剪至最大 L_2 范数 2.0。损失函数为标准交叉熵。

所有训练-验证-测试划分由全局随机种子 1024 固定，确保每个模型在每折内看到相同的数据划分。不应用任务特定特征工程、图增强或边重设计；直接使用 TUDataset 的原始节点特征和邻接结构。

残差和交叉残差变体中使用的可学习门控对初始化为 0.8 的标量参数应用 sigmoid 激活，允许每次残差注入在训练过程中被自适应缩放。对于 Top-k 路由模式，仅保留残差通道（按绝对值确定）中最强比例，再进行注入。对于稀疏路由模式，阈值为 λ 的 softshrink 算子将幅值低于 λ 的残差系数抑制为零，留下经过滤的残差路径。

实验设计

实证研究旨在将确认性五折证据与探索性支持分析分开。最新基准评估了六个数据集、九种方法、四种消息传递算子和五外折，统一在一个协议下。该完整矩阵提供了贯穿全文的主要比较，基准表格直接放置在对应的结果小节中，使每项实证声明能够在原地得到支持。

基准分为两个层次。生物核心由 PROTEINS、DD 和 ENZYMES 组成，锚定本文的主要生物分子解释。补充鲁棒性包将分析扩展至 MUTAG、AIDS 和 Mutagenicity。该划分使核心声明保持聚焦，同时仍检验结论在额外分子图设置上是否保持稳定。

针对性消融实验围绕引言中提出的三个研究问题，通过受控机制实验展开：

1. **Q1: 交叉残差交互何时有帮助？** 交叉门控消融。在交叉架构已具备局部竞争力的六个设置中，评估四种门控配置（可学习、固定 0.0、固定 0.5、固定 1.0）。这检验了所观察到的交叉残差优势是否依赖于自适应注入控制，还是任何固定权重的

额外路径都能产生类似增益。该比较隔离了交叉残差收益的来源：自适应过滤还是结构性通路添加。

2. **Q2: 普通残差复用何时依然保持更强的默认选择？** 门控消融。在最强图级残差目标 (AIDS + GraphResGNN + GINConv) 上，比较相同条件下的可学习门控与固定强度门控。这直接检验了残差家族的默认优势是来自自适应复用，还是仅来自拥有额外注入路径，以及固定残差注入是否能匹配或超越自适应控制。
3. **Q3: 残差路由设计如何改变答案？** 残差路由消融。在四个代表性目标（涵盖残差导向和交叉导向设置）上比较可学习稠密路由、三种保留比例 (0.25, 0.5, 0.75) 的 Top-k 通道选择和三种阈值 (0.02, 0.05, 0.10) 的稀疏抑制，均采用相同五折协议。这将分析从架构标签——模型被称为“残差”还是“交叉残差”——推进到机制层面：历史信息在复用前应被多激进地过滤。

残差参数扫描通过对相同代表性目标变化 Top-k 比例和稀疏强度，扩展了路由分析。旧有的单折深度、dropout 和学习率敏感性扫描仅作为探索性支持分析保留。在最终解释中，五折最新版本运行被视为确认性证据，而单折扫描仅用于描述优化趋势，而非支撑主要声明。

评估指标与统计报告

主要指标为保留测试折上的图分类准确率。主基准和针对性消融结果以五折平均准确率与标准差报告。在最终论文中，五折最新版本实验被视为主要确认性证据，而较旧的单折参数扫描仅作为支持性探索分析使用。

3 结果

本节分四个层次报告最终实证证据：完整基准、对最强残差模式的机制导向解释、针对性门控与残差路由研究，以及探索性敏感性分析。证据层次明确：主基准和针对性消融使用最新的分层五折结果，报告为平均最佳测试准确率 $\pm$ 折间标准差，而较旧的敏感性扫描仅作为支持性趋势分析保留。这一分离至关重要，因为本文的主要声明旨在建立在重复划分证据之上，而非一次有利运行之上。

整体基准性能

最终基准在统一协议下评估了六个数据集、九种方法、四种算子和五个外折。因此，正文将基准表格置于它们所支持的具体声明旁边，而非将表格证据单独列入附录。该呈现方式是有意为之：本文主张有限制的实证结论，所以表格证据被放置在每项声明被提出和解释的位置。

表 3: Main biological benchmark results. Cells show mean $\pm$ std [min, max] over five folds. Bold: best mean per dataset.

Model	PROTEINS	DD	ENZYMES
PlainGNN	0.7053 $\pm$ 0.0271 [0.667, 0.735]	0.7165 $\pm$ 0.0179 [0.694, 0.742]	0.2450 $\pm$ 0.0407 [0.183, 0.2]
NodeResGNN	0.6945 $\pm$ 0.0509 [0.599, 0.740]	0.7207 $\pm$ 0.0259 [0.689, 0.763]	0.2650 $\pm$ 0.0661 [0.158, 0.3]
NodeCrossGNN	0.6963 $\pm$ 0.0433 [0.626, 0.753]	0.7198 $\pm$ 0.0178 [0.706, 0.754]	0.3000 $\pm$ 0.0580 [0.233, 0.4]
GraphResGNN	0.7223 $\pm$ 0.0367 [0.653, 0.762]	0.6934 $\pm$ 0.0458 [0.609, 0.737]	0.3117 $\pm$ 0.0746 [0.167, 0.4]
GraphCrossGNN	0.6864 $\pm$ 0.0465 [0.595, 0.717]	0.7097 $\pm$ 0.0309 [0.668, 0.763]	0.3017 $\pm$ 0.0750 [0.183, 0.4]

表 4: Supplementary robustness benchmark results. Cells show mean $\pm$ std [min, max] over five folds. Bold: best mean per dataset.

Model	MUTAG	AIDS	Mutagenicity
PlainGNN	0.7236 $\pm$ 0.0486 [0.676, 0.811]	0.8455 $\pm$ 0.0257 [0.800, 0.870]	0.7814 $\pm$ 0.0235 [0.749, 0.8]
NodeResGNN	0.7343 $\pm$ 0.0734 [0.649, 0.865]	0.8690 $\pm$ 0.0354 [0.800, 0.897]	0.7897 $\pm$ 0.0139 [0.766, 0.8]
NodeCrossGNN	0.7397 $\pm$ 0.0676 [0.676, 0.865]	0.8735 $\pm$ 0.0412 [0.795, 0.915]	0.8033 $\pm$ 0.0159 [0.776, 0.8]
GraphResGNN	0.7290 $\pm$ 0.0585 [0.676, 0.838]	0.9160 $\pm$ 0.0121 [0.892, 0.927]	0.8022 $\pm$ 0.0220 [0.770, 0.8]
GraphCrossGNN	0.7129 $\pm$ 0.0539 [0.649, 0.811]	0.8710 $\pm$ 0.0412 [0.800, 0.927]	0.8029 $\pm$ 0.0182 [0.774, 0.8]

总体而言，三张表显示出一致的层次关系。残差复用仍是蛋白质导向核心中更强的默认家族，交叉残差路由在补充分子数据集上变得选择性有用，而优胜者摘要确认没有任何单一复杂度趋势能单独解释结果。均值和标准差的组合在此处同样重要：若干差距是有限而非巨大，这正说明为何本文将结果解释为受控的相对稳定模式，而非某一设计普遍占优的证据。




图 3: 活跃数据集包上的基准测试。每个柱表示平均最佳测试准确率，柱顶数字标出精确均值，误差线显示折间标准差。

表 5: Winner summary with max/min fold accuracy and parameter count for each dataset.

Dataset	Winner	Mean Acc	Max Acc	Min Acc	Best Epoch	Params
PROTEINS	GraphResGNN	0.7223	0.7623	0.6532	58.8	51208
DD	NodeResGNN	0.7207	0.7627	0.6894	25.4	22530
ENZYMES	GraphResGNN	0.3117	0.3750	0.1667	91.4	52248
MUTAG	NodeCrossGNN	0.7397	0.8649	0.6757	88.2	34434
AIDS	GraphResGNN	0.9160	0.9275	0.8925	83.8	57928
Mutagenicity	NodeCrossGNN	0.8033	0.8247	0.7756	131.2	35330




图 4: 定义交叉残差路由实际价值的准确率增量。正值表示交叉设计的优势，负值表示对应的普通或残差替代方案仍然更强。

图 3 和图 4 从互补角度阐明同一点：交叉残差路由通常优于普通堆叠，但并非始终强于最佳残差替代方案。

生物学核心数据集结果

主生物基准结果报告于表 3。面向主题的解释锚定在蛋白质导向核心数据集中。这些数据承载了本文的主要实质性分量，因此这里的解释刻意比补充包更加详细。

残差复用仍是所报告套件中最强的默认家族。残差变体在 PROTEINS、DD、ENZYMES 和 AIDS 上数值排名第一。GraphResGNN 在 PROTEINS (0.7223 ± 0.0367)、ENZYMES (0.3117 ± 0.0746) 和 AIDS (0.9160 ± 0.0121) 上领先，而 NodeResGNN 在

DD (0.7207 ± 0.0259) 上领先。重点不在于每次残差领先幅度很大，而在于残差模型在相同五折协议下、跨核心生物任务反复保持在或接近顶部。值得注意的是，许多数值领先是有限度的：配对统计检验（见表 9 和表 10）显示大多数成对架构比较未达常规显著性 ($p < 0.05$)，这一模式本身即具有信息量——它表明在受控协议下，架构级别的差异小于划分级别的变异性。

交叉残差设计具有选择性强度，而非普遍占优。交叉变体在 MUTAG 和 Mutagenicity 上数值排名第一。更重要的是，最佳交叉变体在大多数已完成数据集上击败了 PlainGNN。因此，交叉路由明显不仅是设计上的新奇事物，但证据不支持“交叉普遍优于残差复用”这一更强声明。这一更窄的解读对可靠性至关重要，因为它同时匹配均值结果和所观察到的划分级变异。统计上显著的少数成对比较（例如，PROTEINS 上 SAGEConv 下 GraphResGNN > GraphCrossGNN, $p = 0.031$ ；DD 上 SAGEConv 下 NodeCrossGNN > GraphCrossGNN, $p = 0.027$ ）均涉及图级交叉变体输给残差或节点级交叉模型——表明图级交叉设计是家族中更脆弱的元素。

节点级交叉比图级交叉更可靠。跨已完成数据集，NodeCrossGNN 在数值上超越 NodeResGNN 的次数多于 GraphCrossGNN 超越 GraphResGNN 的次数。这表明在当前研究中，交换中间节点级状态是更鲁棒的交叉残差设计，而图级交叉路由对数据集更敏感，其在若干算子-数据集组合上相比图级残差复用的优势在统计上显著为负方向（见表 9 和表 10）。

普通堆叠遭受深度诱导信号坍塌，但并非一致更差。PlainGNN 在 PROTEINS 和 DD 上保持竞争力，但在最终套件中从未在数据集上领先，通常被残差或交叉残差变体超越。在 GCNConv 下的 ENZYMES 和 AIDS 上，PlainGNN 与最佳残差变体之间的差距具有统计显著性 (ENZYMES + GINConv: $p = 0.002$; AIDS + GCNConv: $p = 0.039$)，这与“普通堆叠的主导模式压制了具有判别力的中层结构信息，而单纯更深传播不足以弥补”的解释一致。

PROTEINS、DD 和 ENZYMES 的主题聚焦结果

PROTEINS. GraphResGNN 数值领先 (0.7223 ± 0.0367)，相比 PlainGNN 的优势为 $+0.017$ ，在大多数算子级比较中未达统计显著性（例如 GCNConv: $p = 0.375$, Cohen's $d = +0.45$ ，小到中等效应）。这表明尾部保留残差路由——重复注入图级摘要——提供有限但一致的收益，与“GraphResGNN 比普通堆叠保存了更多历史结构信号”的解释一致，同时不宣称普遍优势。最佳交叉变体 NodeCrossGNN (0.6963 ± 0.0433) 在该数据集上仍低于 GraphResGNN。

DD. NodeResGNN (0.7207 ± 0.0259) 和 NodeCrossGNN (0.7198 ± 0.0178) 几乎持平 ($\Delta = 0.0009$ ，在任何算子下均不显著)。实践解读是节点级历史结构信号保存在大型稀疏蛋白质图上很重要——增加交叉分支交换既不帮助也不损害。这是一个值得报告的零结果：它表明交叉分支通路在 DD 上不引入破坏性干预，但也不提供在其他数据集上所观察到的选择性增益。

ENZYMES. 交叉变体在数值上变得更具吸引力。GraphCrossGNN 达到 0.3017 ± 0.0750 , NodeCrossGNN 达到 0.3000 ± 0.0580 , 均明显高于 PlainGNN 的 0.2450 ± 0.0407 (在 GINConv 下具有统计显著性: NodeCrossGNN vs PlainGNN $p = 0.009$, GraphResGNN vs PlainGNN $p = 0.002$)。即便如此, GraphResGNN 仍数值领先 (0.3117 ± 0.0746)。然而, 所有模型的绝对准确率仍然较低 (最佳模型仅比 6 类随机基线 16.7% 高出约 15 个百分点), 表明 3 维输入特征和 600 张图的样本量创造了一个具有挑战性的制度, 其中表示学习本质上充满噪声。因此, ENZYMES 结果应被解读为相对排序的证据, 而非绝对任务掌握的证据。




图 5: 已完成主题导向 TU 数据集的聚焦比较。模式是混合而非单边的: 图级残差细化在 PROTEINS 和 ENZYMES 上最强, 而 DD 偏好节点级复用, NodeCrossGNN 保持竞争力但非主导。

残差优势的机制解释

若将残差复用视为有效传播滤波器的变化, 而非仅是优化技巧, 上述基准模式更易于理解。在线性化普通更新下, 重复消息传递多次应用相同的传播算子 $\mathbf{S}$, 因此 ℓ 层后的隐藏状态形式为 $\mathbf{H}^{(\ell)} = \mathbf{S}^\ell \mathbf{X}$ 。在该设置下, 更深的传播越来越压制非主导频谱分量, 这是标准的过度平滑趋势。该解释并不取代实证结果, 而是为”为什么残差家族在单独更深消息传递无帮助时仍可能保持更强”提供缺失的直觉。

残差复用改变了这一行为。若残差线路在下一步传播前复用前一隐藏状态, 更新不再对应单一纯 $\mathbf{S}$ 的幂。相反, 它产生低阶和高阶传播项的多项式混合。在实践中, 模型不再被迫在固定深度下仅依赖最深平滑阶次; 它可以在仍受益于更深传播的同时, 保存来自较早层的更多中层结构信息。该解释与”NodeResGNN 和 GraphResGNN 跨生物学核心保持比 PlainGNN 更强的默认参考”这一实证事实一致。

数据集特定的优胜者模式也与此机制视角一致。在 PROTEINS 和 ENZYMES 上, 最强模型是 GraphResGNN, 表明重新注入图级摘要可以稳定有用的全局上下文, 而不迫使模型完全依赖更深的传播幂次。而在 DD 上, NodeResGNN 保持领先, 表明更轻量的节点级复用是在较大稀疏蛋白质图上保存具有判别力的中间结构的更有效方式。两种情况下, 关键在于: 最佳残差模型之所以有效, 不是因为它们更深, 而是因为它们降低了最高传播阶次的支配效应。

此机制解释也澄清了为什么交叉设计有竞争力但并非一致占优。交叉残差交换创造了额外信息通路，但这些额外通路并不自动产生比普通残差复用更好的频谱权衡。主题导向结果表明 NodeCrossGNN 通常是更稳定的交叉变体，而图级交叉交换对制度更敏感。因此，主要比较不应被解读为“更多通路总是更好”。一个更有防守性的解读是：收益取决于所增加的通路是保存了具有信息量的结构，还是引入了数据集不奖励的不稳定交互。

针对性路由实验进一步强化了该论点。在架构比较识别出强残差和交叉导向目标后，下一个问题是多少历史信息应被前传，以及该信息应被多选择性地过滤。路由结果表明，稠密可学习复用在最佳图级残差线路上保持最强，而温和稀疏路由在代表性交叉导向目标上通常最强。这正是若残差通路因调节有效传播混合而有用时所预期的行为类型：某些目标受益于历史信号的稠密保存，而其他目标则受益于在弱残差通道累积前抑制它们。因此，消融实验服务于方法论目的。它们表明所报告的增益在基准阶段后并非未被解释，而是可以通过对复用机制本身的受控变化进行探测。

该解释的范围应保持严谨。上述论证是一种解释性机制，而非对本文中非线性训练模型的完整定理。它抽象掉了激活函数、优化动力学和算子特定细节。即便如此，它有助于将基准层级连接到一个连贯的实证故事：残差复用保持更强的默认选择，因为它比普通堆叠更可靠地减缓表示坍塌；而交叉残差交互在额外交换通路保存任务相关信息时有用，而非仅增加复杂度。

补充鲁棒性数据集结果

补充鲁棒性结果报告于表 4。补充包在不改变主要结论的前提下扩展了生物核心以外的范围。NodeCrossGNN 在 MUTAG 和 Mutagenicity 上最强，而 GraphResGNN 在 AIDS 上保持最强。该模式保留本文的主要边界声明：交叉残差交互具有选择性实践价值，但残差家族在整个套件中始终是更可靠的默认参考。

门控消融结果

门控消融旨在主基准已识别出强目标配置后，检验残差注入的自适应控制是否有用。在最强图级残差线路 AIDS + GraphResGNN + GINConv 上，可学习门控与固定门控之间的比较是对自适应图级复用的最干净直接检验。表 6 显示可学习门控是最强设置，尽管固定系数 0.5 非常接近。交叉门控消融将相同的比较扩展到交叉架构已局部受偏好的六个设置。换言之，门控研究回答了一个基准表格未解决的问题：如果复用有帮助，收益来自自适应控制还是仅来自以任意固定权重添加另一条注入路径？

表 9 和表 10 提供了跨数据集和算子的所有架构比较的完整配对检验矩阵。总体模式确认大多数架构间的数值差距相对于折间变异是有限的：在配对 t 检验和 Wilcoxon 符号秩检验下，仅一小部分比较达到 $p < 0.05$ 。这与本文的有限解释一致——复用拓扑之间的差异是真实但有条件的，没有单一架构在所有设置中占优。

表 6: AIDS gate ablation on GraphResGNN + GINConv. Numbers are five-fold mean accuracy $\pm$ standard deviation. Bold: best per column.

Gate setting	Mean accuracy
Learnable	0.9620 $\pm$ 0.0089
Fixed 0.0	0.9150 $\pm$ 0.0138
Fixed 0.5	0.9605 $\pm$ 0.0144
Fixed 1.0	0.9480 $\pm$ 0.0300

表 7: Fold-level AIDS gate ablation on AIDS + GraphResGNN + GINConv. Bold: best per column.

Gate setting	Fold 0	Fold 1	Fold 2	Fold 3	Fold 4	Mean $\pm$ Std
Learnable	0.9500	0.9700	0.9700	0.9675	0.9525	0.9620 $\pm$ 0.0089
Fixed 0.0	0.9225	0.9025	0.9125	0.9000	0.9375	0.9150 $\pm$ 0.0138
Fixed 0.5	0.9325	0.9625	0.9675	0.9675	0.9725	0.9605 $\pm$ 0.0144
Fixed 1.0	0.8925	0.9450	0.9700	0.9775	0.9550	0.9480 $\pm$ 0.0300

折级表格有用是因为它显示了鲁棒性来自何处：可学习门控不仅在平均上强，而且在五个 AIDS 折上保持持续高水平，不依赖某一异常有利的划分。更全面的交叉门控表格也使混合模式更容易逐目标检查。因此，预期的解释是受约束的。门控研究不需要证明可学习门控在每个目标上都是最佳。相反，相关问题是自适应控制在所选残差和交叉残差设置中是否通常比固定注入强度更鲁棒。表 8 显示可学习门控在六个交叉偏好目标中的三个上是最佳的，而固定门控在其他三个目标上保持竞争力甚至可能更优。这支持的是鲁棒性声明，而非普遍最优声明。

残差路由结果

残差路由分析是本文的主要机制扩展。四个代表性目标在相同的五折协议下比较了可学习、Top-k 和稀疏路由模式。最清晰的总体信号是不存在普遍优胜者。表 11 显示可学习在最强图级残差线路 (AIDS + GraphResGNN + GINConv) 上保持最佳，但稀疏路由在四个代表性目标中的三个上是最强的，其中 `sparse_0p05` 成为最一致的稀疏设置。表格将精确的参数级比较保留在正文中，因此读者可以直接看到稀疏优势不是模糊的家族级趋势，而是反复出现的、目标级的结果。这大大降低了过度解释单一均值的风险，因为比较是在若干目标和路由设置上重复的，而非从某一个孤立的基准单元格推断而来。

这一模式支持了一个比仅靠架构基准更精确的结论。重要的问题不仅是历史信息是否被复用，还包括该信息在复用前被多激进地过滤。表 12 按路由家族压缩了结果：稀疏家族在四个代表性目标中的三个上最强，而可学习家族在最佳图级残差线路上保持最强。

表 8: Cross-gate ablation on six cross-favored targets. Numbers are five-fold mean accuracy $\pm$ standard deviation. Bold: best per row.

Dataset	Target	Learnable	Fixed 0.0	Fixed 0.5	Fixed 1.0
AIDS	NodeCross + GATConv	0.9045 $\pm$ 0.0165	0.9075 $\pm$ 0.0065	0.9195 $\pm$ 0.0114	0.9105 $\pm$ 0.0241
DD	NodeCross + GATConv	0.7173 $\pm$ 0.0271	0.7053 $\pm$ 0.0361	0.7156 $\pm$ 0.0225	0.7147 $\pm$ 0.0288
DD	NodeCross + GINConv	0.7071 $\pm$ 0.0306	0.7012 $\pm$ 0.0198	0.7232 $\pm$ 0.0207	0.7113 $\pm$ 0.0277
ENZYMES	NodeCross + GATConv	0.2800 $\pm$ 0.0629	0.2850 $\pm$ 0.0627	0.2550 $\pm$ 0.0674	0.2650 $\pm$ 0.0690
MUTAG	GraphCross + GATConv	0.7558 $\pm$ 0.0495	0.7451 $\pm$ 0.0407	0.7450 $\pm$ 0.0416	0.7504 $\pm$ 0.0779
Mutagenicity	NodeCross + GATConv	0.8114 $\pm$ 0.0110	0.8033 $\pm$ 0.0192	0.8010 $\pm$ 0.0130	0.8036 $\pm$ 0.0078

残差参数扫描结果

额外路由设置 `topk_0p75` 和 `sparse_0p1` 细化了而非改变了先前结果。表 11 显示最强 Top-k 比例因目标而异，这表明 Top-k 路由不受某一全局最优保留水平支配。稀疏扫描也显示了一个清晰的失败模式：激进稀疏可能损害本来很强的残差线路，尤其是在最强图级残差目标上，其中 `sparse_0p1` 降至 0.8315 ± 0.0549 。

深度扩展与表示相似性

为进一步检验深度如何影响每种架构的表示动力学，我们将隐藏状态相似性分析从 $L = 4$ 层扩展到 $L = 1$ 至 $L = 8$ 层（PROTEINS 数据集，GCNConv 算子）。图 6 展示了每种模型在所有八个层数下相邻深度阶段之间的 CKA 相似性，图 7 展示了对应的余弦相似性。此比较呈现出以下若干模式。

第一，在所有五种架构中，更深堆叠一致降低了相邻阶段相似性，确认深度诱导的表示分歧是一个普遍现象，而非特定复用策略的产物。第二，在超越最浅层的每个深度配置下，残差和交叉残差变体均表现出系统性地高于 PlainGNN 的 CKA 值，且差距随层数增加而扩大——在 $L = 8$ 时，PlainGNN 的最终 CKA 过渡明显低于所有四种复用变体。在极浅深度（ $L = 2-3$ ）下，所有架构均保持相对较高的相似性，这与早期层捕获广泛共享的局部结构的预期一致。这与第 3 节的机制解释一致：残差复用跨深度保存更多历史信号，且此保存效应随深度增加而更加显著。第三，节点级交叉变体（NodeCrossGNN）在所有层数下均保持与 NodeResGNN 可比的 CKA 值，表明跨分支交换在更深配置下也不会破坏表示连续性。

图 8 进一步显示，随着深度扩展，不同架构的最深层梯度范数表现各异。PlainGNN 的最深层梯度范数随深度增加而退化比残差家族更快，而 NodeResGNN 和 NodeCrossGNN 即使在 $L = 8$ 时也保持更稳定的梯度信号。图级变体（GraphResGNN 和 GraphCrossGNN）处于中间位置，其中 GraphResGNN 在图级模型中表现出最稳定的梯度剖面。综合来看，这些深度扩展结果——从浅层单层配置到深层八层堆叠——强化了本文的中心机制叙述：残差复用减缓了更深配置下的表示坍塌和梯度退化，而交叉残差交换不会引

表 9: Paired t -tests for main biological benchmark datasets. Cells: Δ (Cohen's d , p).**Bold:** $p < 0.05$ ($n=5$ folds).

Dataset	Comparison	GCNConv	GATConv	SAGEConv	
PROTEINS	NodeRes – Plain	+0.012 (+0.55, 0.286)	+0.000 (+0.00, 0.999)	+0.006 (+0.31, 0.524)	+0.006 (+0.31, 0.524)
	NodeCross – Plain	-0.008 (-0.28, 0.571)	-0.011 (-0.22, 0.647)	-0.002 (-0.07, 0.881)	-0.002 (-0.07, 0.881)
	GraphRes – Plain	+0.004 (+0.45, 0.375)	+0.015 (+0.48, 0.345)	+0.030 (+1.69, 0.019)	+0.030 (+1.69, 0.019)
	GraphCross – Plain	-0.001 (-0.02, 0.961)	-0.008 (-0.24, 0.623)	+0.004 (+0.24, 0.622)	+0.004 (+0.24, 0.622)
	NodeCross – NodeRes	-0.020 (-0.53, 0.302)	-0.011 (-0.19, 0.690)	-0.008 (-0.72, 0.181)	-0.008 (-0.72, 0.181)
	GraphCross – GraphRes	-0.005 (-0.15, 0.751)	-0.023 (-2.18, 0.008)	-0.026 (-1.47, 0.031)	-0.026 (-1.47, 0.031)
	GraphRes – NodeRes	-0.007 (-0.26, 0.588)	+0.015 (+0.37, 0.459)	+0.023 (+0.75, 0.171)	+0.023 (+0.75, 0.171)
	NodeCross – GraphCross	-0.007 (-0.49, 0.337)	-0.003 (-0.10, 0.838)	-0.005 (-0.21, 0.659)	-0.005 (-0.21, 0.659)
DD	NodeRes – Plain	+0.012 (+0.39, 0.429)	+0.002 (+0.24, 0.624)	+0.016 (+0.48, 0.347)	+0.016 (+0.48, 0.347)
	NodeCross – Plain	+0.019 (+0.55, 0.286)	+0.035 (+0.90, 0.115)	+0.023 (+0.87, 0.124)	+0.023 (+0.87, 0.124)
	GraphRes – Plain	+0.030 (+0.64, 0.223)	+0.020 (+0.50, 0.326)	+0.021 (+0.91, 0.112)	+0.021 (+0.91, 0.112)
	GraphCross – Plain	+0.024 (+0.87, 0.123)	+0.019 (+0.46, 0.357)	+0.004 (+0.19, 0.699)	+0.004 (+0.19, 0.699)
	NodeCross – NodeRes	+0.008 (+0.43, 0.395)	+0.033 (+0.88, 0.121)	+0.007 (+0.64, 0.226)	+0.007 (+0.64, 0.226)
	GraphCross – GraphRes	-0.007 (-0.23, 0.637)	-0.002 (-0.11, 0.815)	-0.017 (-2.82, 0.003)	-0.017 (-2.82, 0.003)
	GraphRes – NodeRes	+0.019 (+0.64, 0.228)	+0.019 (+0.46, 0.359)	+0.005 (+0.24, 0.624)	+0.005 (+0.24, 0.624)
	NodeCross – GraphCross	-0.004 (-0.31, 0.526)	+0.016 (+1.07, 0.075)	+0.019 (+1.53, 0.027)	+0.019 (+1.53, 0.027)
ENZYMES	NodeRes – Plain	-0.000 (-0.00, 1.000)	+0.005 (+0.19, 0.697)	-0.017 (-0.94, 0.103)	-0.017 (-0.94, 0.103)
	NodeCross – Plain	+0.003 (+0.09, 0.847)	+0.032 (+0.45, 0.369)	+0.007 (+0.24, 0.614)	+0.007 (+0.24, 0.614)
	GraphRes – Plain	+0.020 (+0.92, 0.107)	+0.020 (+0.32, 0.507)	+0.020 (+0.47, 0.360)	+0.020 (+0.47, 0.360)
	GraphCross – Plain	+0.020 (+0.55, 0.280)	+0.007 (+0.08, 0.875)	+0.020 (+0.33, 0.502)	+0.020 (+0.33, 0.502)
	NodeCross – NodeRes	+0.003 (+0.08, 0.878)	+0.027 (+0.36, 0.471)	+0.023 (+0.42, 0.399)	+0.023 (+0.42, 0.399)
	GraphCross – GraphRes	-0.000 (-0.01, 0.981)	-0.013 (-0.21, 0.672)	+0.000 (+0.00, 1.000)	-0.000 (+0.00, 1.000)
	GraphRes – NodeRes	+0.020 (+0.57, 0.264)	+0.015 (+0.28, 0.562)	+0.037 (+0.82, 0.151)	+0.037 (+0.82, 0.151)
	NodeCross – GraphCross	-0.017 (-0.47, 0.355)	+0.025 (+0.68, 0.211)	-0.013 (-0.40, 0.444)	-0.013 (-0.40, 0.444)

入破坏此稳定效应的干扰。

表 10: Paired t -tests for supplementary robustness datasets. Cells: Δ (Cohen’s d , p).
Bold: $p < 0.05$ ($n=5$ folds).

Dataset	Comparison	GCNConv	GATConv	SAGEConv	
MUTAG	NodeRes – Plain	+0.011 (+0.29, 0.545)	+0.000 (+0.00, 1.000)	-0.016 (-0.40, 0.416)	-0.016
	NodeCross – Plain	+0.016 (+0.36, 0.477)	+0.005 (+0.09, 0.850)	+0.005 (+0.15, 0.758)	+0.005
	GraphRes – Plain	+0.005 (+0.09, 0.864)	+0.011 (+0.33, 0.513)	-0.011 (-0.10, 0.839)	-0.011
	GraphCross – Plain	-0.011 (-0.20, 0.683)	+0.027 (+0.59, 0.262)	-0.022 (-0.28, 0.576)	-0.022
	NodeCross – NodeRes	+0.005 (+0.10, 0.836)	+0.005 (+0.10, 0.845)	+0.022 (+0.33, 0.516)	+0.022
	GraphCross – GraphRes	-0.016 (-0.34, 0.515)	+0.016 (+0.37, 0.467)	-0.011 (-0.26, 0.613)	-0.011
	GraphRes – NodeRes	-0.005 (-0.12, 0.808)	+0.011 (+0.17, 0.742)	+0.005 (+0.08, 0.881)	+0.005
	NodeCross – GraphCross	+0.027 (+0.71, 0.186)	-0.022 (-0.61, 0.240)	+0.027 (+0.53, 0.310)	+0.027
AIDS	NodeRes – Plain	+0.023 (+1.19, 0.062)	+0.010 (+0.89, 0.112)	+0.018 (+0.86, 0.125)	+0.018
	NodeCross – Plain	+0.028 (+1.06, 0.083)	+0.018 (+0.80, 0.144)	+0.020 (+1.52, 0.022)	+0.020
	GraphRes – Plain	+0.070 (+2.41, 0.005)	+0.025 (+1.57, 0.041)	+0.028 (+2.45, 0.004)	+0.028
	GraphCross – Plain	+0.025 (+0.94, 0.089)	+0.013 (+1.10, 0.068)	+0.018 (+1.16, 0.067)	+0.018
	NodeCross – NodeRes	+0.005 (+0.41, 0.420)	+0.008 (+0.52, 0.311)	+0.003 (+0.14, 0.778)	+0.003
	GraphCross – GraphRes	-0.045 (-1.46, 0.043)	-0.013 (-0.66, 0.218)	-0.010 (-0.44, 0.398)	-0.010
	GraphRes – NodeRes	+0.047 (+2.62, 0.002)	+0.015 (+1.19, 0.063)	+0.010 (+0.46, 0.370)	+0.010
	NodeCross – GraphCross	-0.003 (-0.10, 0.848)	+0.005 (+0.44, 0.387)	+0.003 (+0.20, 0.682)	+0.003
Mutagenicity	NodeRes – Plain	+0.004 (+0.26, 0.597)	+0.011 (+0.95, 0.101)	+0.014 (+0.93, 0.106)	+0.014
	NodeCross – Plain	+0.011 (+0.68, 0.201)	+0.020 (+1.05, 0.079)	+0.013 (+0.86, 0.127)	+0.013
	GraphRes – Plain	+0.019 (+1.24, 0.050)	+0.008 (+0.57, 0.273)	+0.012 (+0.62, 0.237)	+0.012
	GraphCross – Plain	+0.016 (+0.85, 0.131)	+0.009 (+0.46, 0.366)	+0.012 (+0.49, 0.333)	+0.012
	NodeCross – NodeRes	+0.006 (+0.26, 0.588)	+0.009 (+0.69, 0.195)	-0.001 (-0.13, 0.787)	-0.001
	GraphCross – GraphRes	-0.003 (-0.30, 0.545)	+0.002 (+0.08, 0.874)	+0.000 (+0.00, 0.999)	+0.000
	GraphRes – NodeRes	+0.015 (+0.87, 0.125)	-0.003 (-0.27, 0.583)	-0.003 (-0.18, 0.714)	-0.003
	NodeCross – GraphCross	-0.005 (-0.35, 0.476)	+0.010 (+0.50, 0.324)	+0.001 (+0.10, 0.832)	+0.001




图 6: $L = 1$ 到 $L = 8$ 各层数下相邻深度阶段之间的 CKA 相似性。每个子图展示一个

表 11: Residual-routing and parameter-sweep summary on four representative targets (transposed). Numbers are five-fold mean accuracy $\pm$ standard deviation. Bold: best per column.

Routing	AIDS+GraphRes+GIN	PROT+GraphRes+SAGE	AIDS+NodeCross+GAT	DD+NodeCross+GAT
Learnable	0.9500 $\pm$ 0.0087	0.7178 $\pm$ 0.0411	0.8970 $\pm$ 0.0491	0.7080 $\pm$ 0.0172
Top-k 0.25	0.9075 $\pm$ 0.0237	0.7241 $\pm$ 0.0407	0.9160 $\pm$ 0.0128	0.7062 $\pm$ 0.0249
Top-k 0.50	0.9330 $\pm$ 0.0251	0.7151 $\pm$ 0.0397	0.8960 $\pm$ 0.0483	0.7029 $\pm$ 0.0160
Top-k 0.75	0.9240 $\pm$ 0.0287	0.7214 $\pm$ 0.0318	0.8960 $\pm$ 0.0489	0.7164 $\pm$ 0.0248
Sparse 0.02	0.9470 $\pm$ 0.0181	0.7160 $\pm$ 0.0248	0.9060 $\pm$ 0.0268	0.7147 $\pm$ 0.0259
Sparse 0.05	0.9250 $\pm$ 0.0152	0.7259 $\pm$ 0.0475	0.9180 $\pm$ 0.0162	0.7181 $\pm$ 0.0196
Sparse 0.10	0.8315 $\pm$ 0.0549	0.7088 $\pm$ 0.0521	0.9025 $\pm$ 0.0139	0.7105 $\pm$ 0.0243
Best	Learnable	Sparse 0.05	Sparse 0.05	Sparse 0.05

表 12: Family-wise routing winners.

Target	Best learnable	Best top-k	Best sparse	Overall winner
AIDS + GraphRes + GIN	0.9500	0.9330	0.9470	Learnable
PROTEINS + GraphRes + SAGE	0.7178	0.7241	0.7259	Sparse
AIDS + NodeCross + GAT	0.8970	0.9160	0.9180	Sparse
DD + NodeCross + GAT	0.7080	0.7164	0.7181	Sparse

Cosine similarity vs depth across layer counts ($L=1-8$) — PROTEINS (GCNConv)




图 7: $L = 1$ 到 $L = 8$ 各层数下相邻深度阶段之间的余弦相似性。模式与 CKA 结果相互印证：更深堆叠在所有架构上均减少相邻阶段余弦相似性，PlainGNN 在较高层数下表现出最陡峭的下降。负值表示相邻阶段之间的反相关表示。




图 8: 所有五种架构在 PROTEINS (GCNConv) 上的最深层梯度 L2 范数随层数 ($L = 1$ 至 $L = 8$) 的变化。残差家族在深层维持更稳定的梯度信号，而 PlainGNN 表现出最陡峭的下降。图级变体处于中间位置。

探索性敏感性分析

在 PROTEINS、DD 和 ENZYMES 上针对深度、dropout 和学习率的辅助敏感性检验不会实质性改变主要结论。在 PROTEINS 和 DD 上，温和的调参变化影响两个交叉变体之间的差距，但它们不会推翻“残差基线保持更强的默认参考”这一更广泛的结论。在 ENZYMES 上，验证信号明显更嘈杂，且局部有希望的设置在最终五折平均下未能复现原始全量交叉结果。这些检验为透明性而报告，但不应被视为与重复划分基准和针对性消融同等水平的证据。

4 讨论

主要实证信息现在比早期草稿更加精确。交叉残差路由相对于普通堆叠通常有益，但相对于残差基线的增益是有条件的且依赖数据集。因此，当前证据支持将 CR-GNN 视为一个有意义的生物分子图分类设计空间，而非一个普遍占优的模型家族。这一框架对于解读本文的长处和局限均至关重要：贡献在于识别可复现的复用机制层次，而非宣称一个新的普遍最佳模型。

交叉残差增益是有条件的

基准结果不支持“交叉残差交互应取代残差复用作为默认选择”这一最强可能的声明。相反，它们支持一个更窄的陈述：交叉残差设计通常优于普通堆叠，并能在特定数据集上提供选择性增益——尤其在如 MUTAG 和 Mutagenicity 上，稀有判别基序保存至关重要——但普通残差复用在整个生物分子测试包中依然是更强的默认家族。这一

更窄的结论更有说服力，因为它与五折均值 $\pm$ 标准差报告以及配对统计检验（表 9 和表 10）保持一致，而非与孤立的最高增益保持一致。

数据集级模式具有信息量。在 NodeCrossGNN 领先的 MUTAG 上，任务涉及小型分子图（平均 18 个节点），其中局部结构基序（例如特定化学子结构）携带强判别信号。跨分支交换可能在此通过保存单分支在重复传播下倾向于压制的稀有基序而有所帮助——一种通过互补并行通路保存稀有判别基序的形式。在 Mutagenicity 上，更大的样本量（4,337 张图）降低了划分级方差，使 NodeCrossGNN 的优势（相比 NodeResGNN +0.014）更加稳定，尽管在统计上依然有限。而在 AIDS 上，GraphResGNN 的强数值领先（0.9160 vs. NodeCrossGNN 的 0.8735）表明，当图级上下文占主导时，通过顺序图条件块的尾部保留残差路由是更有效的策略。这种条件模式——当局部基序稀有且具有判别力时交叉有帮助，当全局上下文占主导时残差有帮助——是本文的核心实证观察。

节点级和图级复用表现不同

节点级与图级信息复用之间的区分同样具有实践重要性。节点级交叉交换是更稳定的交叉导向设计，而图级交叉路由对数据集制度更敏感，且并不始终匹配最强图级残差线路。这表明复用的位置至少与额外复用路径的存在同等重要。值得注意的是，GraphResGNN 和 GraphCrossGNN 比其节点级对应物携带更多参数（例如，在 PROTEINS 上 GraphResGNN $\approx$ 51k vs. NodeResGNN $\approx$ 23k 参数，见表 5），因为链接多个图条件块增加了总参数预算。GraphResGNN 的数值领先并不与其参数优势等比例扩展——它在 PROTEINS 和 ENZYMES 上排名第一，但在 DD 和 MUTAG 上被更轻的节点级模型超越——这一事实表明信息流拓扑而非参数数量才是相对性能的更重要决定因素。

为何 ENZYMES 对所有架构都保持困难

一个显著结果是，所有模型在 ENZYMES 上的绝对性能都很差：最佳模型（GraphResGNN， 0.3117 ± 0.0746 ）仅比 6 类随机基线（16.7%）高出约 15 个百分点。若干因素可能共同导致：首先，ENZYMES 仅有 600 张图，3 维输入特征，使表示学习极具挑战性，内验证划分（10%）嘈杂；其次，6 类结构创造了比二元任务更难的决策边界，而二元任务主导了其余基准测试套件；第三，所观察到的折间标准差（ ± 0.075 ）是生物核心中最大的，表明高划分敏感性。这并不否定相对排序——残差家族依然领先——但它限制了仅从 ENZYMES 得出的任何架构级结论的强度。ENZYMES 结果最好被解读为“尾部保留残差路由在嘈杂、低数据制度下提供相对稳定性”的证据，而非“任何架构都能很好地解决该任务”的证据。

残差路由是机制叙事的一部分

残差路由消融为架构主比较添加了重要限定。问题不仅是残差信息是否应被复用，还包括它应以稠密、稀疏还是 Top-k 选择的方式被复用——一个选择性残差过滤而非二元复用的问题。当前结果表明路由策略是目标依赖的：可学习稠密路由在最佳图级残差线路上保持最强，其中尾部保留残差路由受益于丰富的历史上下文；而温和稀疏路由在交叉导向设置上频繁表现出优势，其中抑制弱残差通道可减少主导模式压制并防止未过滤的跨分支信号累积。这将本文从简单的架构排名练习转向了架构与路由共同解释的机制研究。

深度扩展分析（图 6-8）为此机制叙事添加了另一维度。通过将隐藏状态相似性和梯度分析从 $L = 4$ 层扩展到 $L = 8$ 层，我们发现残差家族在保存表示连续性方面的优势并不局限于主基准中使用的默认深度——它随深度增加而增强。PlainGNN 的相邻阶段 CKA 随深度下降比任何残差或交叉残差变体都更陡峭，其最深层梯度范数下降更快。NodeResGNN 和 NodeCrossGNN 在所有测试深度下保持可比的表示稳定性，确认跨分支交换在更深配置下也不会引入破坏性干扰。这些深度扩展证据支持了本文的中心声明：残差复用是更鲁棒的默认策略，而交叉残差交互提供一个互补通路，不会削弱残差连接的稳定效应。

证据层次与研究局限

本文中最强的证据来自五折 LATEST 基准和五折针对性消融。相比之下，较旧的单折敏感性扫描仅对优化解释有用，不应被视为同类的定量证据。第二个局限是统计功效：配对显著性检验（表 9 和表 10）显示，在五折评估下，大多数架构级数值差距未达 $p < 0.05$ 。每个数据集-算子组合仅有五个配对观测，检验对中小效应（Cohen's $d < 0.5$ ）的检测能力有限。这并不削弱本文的有限制结论，但意味着“X 强于 Y”的声明应被理解为在受控条件下观察到的数值排序，而非统计占优的陈述。未来采用更多折数或重复随机子采样的工作将提供更精细的成对比较。第三个局限是基线范围。基准包含代表性残差、传播和聚合基线，但并非意图穷尽覆盖所有近期图分类方法的排行榜。本文旨在支持在稳定协议下对复用拓扑的受控比较。第四个局限是数据集规模与任务范围：虽然数据集是生物分子或分子的，且生物核心有意义，但它们仍是中等规模的图分类基准数据集。因此，本研究支持关于受控图分类行为的结论，而非关于大规模可扩展性、直接生物学发现、组学整合或任务特定生物学解释的结论。

未来方向

下一步研究是在更丰富的生物学输入下检验相同的信息流思想，例如序列衍生嵌入、本体注释或表达相关信号。另一重要扩展是在更大规模的图基准上评估相同的受控复用问题，使当前的机制导向结论能够超越现有中等规模设置得到检验。同时，本文引

入的残差路由视角可扩展至更广泛的生物分子图任务，其中图拓扑必须与更强的领域监督而非仅基准评估相结合。

5 结论

本文将 CR-GNN 作为一个受控的生物分子图分类框架加以研究，而非宣称普遍模型优越性。最终证据支持一个更窄但更强的结论：交叉残差交互有用，但残差变体在报告的基准测试套件中依然是更强的默认家族，而增益在数据集制度和路由策略两方面均具有条件性。

因此，主要贡献不是一个普遍占优的架构，而是一个受控的信息流机制和残差路由策略比较，揭示了残差路由何时以及如何发挥作用。在生物核心中，GraphResGNN 通过尾部保留残差路由——重复注入图级摘要——在 PROTEINS 和 ENZYMES 上数值领先，而 NodeResGNN 通过节点级历史结构信号保存在 DD 上领先。交叉残差变体在 MUTAG 和 Mutagenicity 上提供选择性增益，其中通过互补并行通路的稀有判别基序保存最为重要，但它们并不取代残差基线作为主要参考点。重要的是，大多数架构间数值差距相对于折间变异是有限度的；仅在部分成对比较中达到 $p < 0.05$ ，这强化了本文的有限解释。

路由分析进一步深化了该结论。可学习稠密路由在最佳图级残差线路上保持最强，而温和稀疏路由（选择性残差过滤）在交叉导向设置上频繁有效。这表明实践中的问题不仅是额外残差路径是否存在，更是历史信息在复用前如何被过滤。因此，针对性路由结果有助于解释为何基准层次是混合而非单边的：额外复用路径的收益取决于它保存了任务相关结构，还是通过未过滤的信号累积引入了主导模式压制。

该结论的范围应保持严谨。本文中最强的声明得到分层五折基准和针对性五折消融的支持，而较旧的敏感性扫描仅具有支持性。统计证据（表 9 和表 10）具有信息量，正因为它确认了在受控协议下架构级效应是有限度的——这一模式与本文机制导向而非排行榜导向的框架一致。同样，本研究探讨的是中等规模生物分子和分子基准上的受控图分类行为；它本身并不确立大规模可扩展性或直接生物学可解释性。

综合而言，这些结果将 CR-GNN 定位为一个实用的生物分子图分类设计空间，并为未来关于更丰富生物学输入、更大规模基准以及残差复用必须与更强领域监督相协调的图学习设置的后续工作提供了方法论基础。

致谢

作者感谢开源图学习社区以及本研究所用基准资源的维护者。同时感谢审稿人和编辑的时间与反馈。

参考文献

- Uri Alon and Eran Yahav. On the bottleneck of graph neural networks. In *International Conference on Learning Representations (ICLR)*, 2021.
- Xavier Bresson and Thomas Laurent. Residual gated graph convnets. *arXiv preprint arXiv:1711.07553*, 2017.
- Tianle Cai, Jiacheng Luo, Sheng Wang, Kai Zhang, Yu Tian, Liwei Yang, Zekun Li, and Kilian Weinberger. Graphnorm: A principled approach to accelerating graph neural network training. In *International Conference on Machine Learning*, pages 1277–1287, 2021.
- Ming Chen, Zhewei Wei, Zengfeng Huang, Bolin Ding, and Yaliang Li. Simple and deep graph convolutional networks. In *International Conference on Machine Learning (ICML)*, pages 1725–1735, 2020a.
- Yuning Chen, Xihao Wei, Pan Xu, Xinwen Wang, Ping Luo, Zhiyuan Li, and Jian Tang. Revisiting over-smoothing in deep gcns. *arXiv preprint arXiv:2003.13663*, 2020b.
- Matthias Fey and Jan Eric Lenssen. Fast graph representation learning with pytorch geometric. *arXiv preprint arXiv:1903.02428*, 2019.
- Hongyang Gao and Shuiwang Ji. Graph u-net. *arXiv preprint arXiv:1905.05178*, 2019.
- Justin Gilmer, Samuel S Schoenholz, Patrick F Riley, Oriol Vinyals, and George E Dahl. Neural message passing for quantum chemistry. In *International Conference on Machine Learning*, pages 1263–1272, 2017.
- William L Hamilton, Rex Ying, and Jure Leskovec. Inductive representation learning on large graphs. In *Advances in neural information processing systems*, pages 1024–1034, 2017.
- Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778, 2016.
- Thomas N Kipf and Max Welling. Semi-supervised classification with graph convolutional networks. *arXiv preprint arXiv:1609.02907*, 2016.
- Johannes Klicpera, Alan Bojchevski, and Stephan Günnemann. Combining label propagation and simple models out-performs graph neural networks. *arXiv preprint arXiv:1810.05997*, 2018.

- Guohao Li, Elias Muller, Abbas Thabet, and Bernard Ghanem. Deeper insights into graph convolutional networks for semi-supervised learning. *arXiv preprint arXiv:1809.02584*, 2018.
- Christopher Morris, Roger Wattenhofer, and Kristian Kersting. Tdataset: A collection of benchmark datasets for learning with graphs. *arXiv preprint arXiv:2007.08663*, 2020.
- Kenta Oono and Taiji Suzuki. Simple and deep graph convolutional networks. *arXiv preprint arXiv:2006.13604*, 2020.
- Yu Rong, Wenbing Huang, Tingyang Xu, and Junzhou Huang. Dropedge: Towards deep graph convolutional networks on node classification. *arXiv preprint arXiv:1907.10903*, 2019.
- Jake Topping, Francesco Di Giovanni, Benjamin Chamberlain, Michael Bronstein, Douwe Vendrig, and Pietro Lio. Understanding over-squashing and bottlenecks on graphs via curvature. *arXiv preprint arXiv:2111.14522*, 2021.
- Zonghan Wu, Shirui Pan, Fengwen Chen, Guoding Long, Cheng Zhang, and Sheng Yu Zhang. A comprehensive survey on graph neural networks. *IEEE Transactions on Neural Networks and Learning Systems*, 32(1):4–24, 2021.
- Keyulu Xu, Chengtao Li, Yonglong Tian, Xiao Du, Jure Leskovec, and Stefanie Jegelka. Representation learning on graphs with jumping knowledge networks. In *International Conference on Machine Learning*, pages 5449–5458, 2018.
- Rex Ying, Jiaxuan You, Christopher Morris, Xiang Ren, William L Hamilton, and Jure Leskovec. Hierarchical graph representation learning with differentiable pooling. In *Advances in neural information processing systems*, pages 4800–4810, 2018.
- Lingxiao Zhao and Leman Akoglu. Pairnorm: Tackling over-smoothing in gns. *arXiv preprint arXiv:2009.10698*, 2020.
- Jie Zhou, Ganqu Cui, Zhengyan Zhang, Cheng Yang, Zhaocheng Liu, Zhongyuan Wang, Peng Li, Ming Sun, Yu Shi, et al. Graph neural networks: A review of methods and applications. *AI Open*, 1:57–81, 2020.